

机器学习复习资料
2025-2026 学年

邹华老师课程

2025 年 12 月 21 日

目录

1	第 1 讲概论	7
1.1	机器学习基本概念	7
1.1.1	定义	7
1.1.2	样本空间与标记空间	7
1.1.3	数据集合	7
1.1.4	张量 (Tensor)	7
1.1.5	假设空间与模型	7
1.1.6	学习策略 (学习准则)	7
1.1.7	优化算法	8
1.1.8	机器学习三要素	8
1.2	机器学习分类	8
1.2.1	按样本标记分类	8
1.2.2	按学习方式分类	9
1.2.3	按建模方式分类	9
1.3	主要挑战	9
2	第 2 讲模型选择与评估	10
2.1	监督学习的计算理论	10
2.1.1	经验误差与泛化误差	10
2.1.2	k 近邻算法 (kNN)	10
2.2	误差构成与过拟合	10
2.2.1	过拟合与欠拟合	10
2.2.2	模型复杂度与泛化能力	11
2.3	模型验证与测试	11
2.3.1	数据集划分	11
2.3.2	交叉验证	11
2.4	模型的性能度量	12

2.4.1	分类问题的性能度量	12
2.4.2	回归问题的性能度量	13
2.5	模型的比较检验	13
3	第 3 讲线性判别分析	14
3.1	线性回归及其推广	14
3.1.1	线性回归基本模型	14
3.1.2	线性回归学习准则	14
3.2	对数几率回归分类器 (Logistic Regression, LR)	16
3.2.1	基本概念	16
3.2.2	学习策略	17
3.3	线性判别分析 (LDA)	18
3.3.1	判别函数概念	18
3.3.2	三个判别类型 (考点重点)	18
3.3.3	Fisher 判别的求解 (P33 核心公式)	20
3.3.4	决策区域与正负侧 (考点重点)	21
3.3.5	解题步骤 (计算题)	22
3.3.6	模型小结	22
3.3.7	多类分类例题详解 (考点重点)	23
3.4	多分类学习	24
3.4.1	多分类策略	24
3.4.2	Softmax 回归 (多分类对数几率回归)	24
4	第 4 讲贝叶斯分类器	25
4.1	贝叶斯决策理论基础	25
4.1.1	概率基础	25
4.1.2	机器学习中的概率解释	26
4.2	最小错误率贝叶斯分类	27
4.2.1	基本思想	27
4.2.2	二分类问题的决策规则	27
4.3	最小风险贝叶斯分类 (考点重点)	28
4.3.1	风险与损失函数	28
4.3.2	最小风险决策规则 (P21 核心内容)	28
4.3.3	二分类问题的风险决策	28
4.4	类条件概率的参数估计	29
4.4.1	最大似然估计 (MLE)	29
4.4.2	高斯分布的参数估计	30
4.5	朴素贝叶斯分类器	31
4.5.1	基本假设	31
4.5.2	分类决策	32

4.5.3	参数估计	33
4.6	简单 EM 算法	34
4.6.1	基本思想	34
4.6.2	收敛性	35
4.6.3	模型小结	35
5	第 5 讲支持向量机	36
5.1	间隔与支持向量	36
5.1.1	支持向量机的基本思想	36
5.1.2	间隔的概念	36
5.1.3	支持向量	37
5.1.4	最大间隔分类器	38
5.2	对偶问题	38
5.2.1	Lagrange 对偶	38
5.2.2	决策函数	39
5.3	软间隔与正则化	42
5.3.1	软间隔的基本思想	42
5.3.2	软间隔的优化问题	43
5.3.3	对偶问题	43
5.3.4	支持向量的分类	43
5.3.5	正则化视角	43
5.4	核方法	44
5.4.1	核技巧的基本思想	44
5.4.2	常用核函数	44
5.4.3	非线性 SVM 的决策函数	44
5.5	模型小结	46
6	第 6 讲决策树	46
6.1	基本流程	47
6.1.1	决策树的基本模型	47
6.1.2	决策树生成算法	47
6.2	划分选择	47
6.2.1	信息熵	47
6.2.2	信息增益 (ID3 算法)	48
6.2.3	信息增益率 (C4.5 算法)	48
6.2.4	基尼指数 (CART 算法)	49
6.2.5	三种划分准则的对比	49
6.3	剪枝处理	49
6.3.1	剪枝的基本思想	49
6.4	连续与缺失值	50

6.4.1	连续值处理	50
6.4.2	缺失值处理	50
6.5	决策树用于回归	50
6.5.1	回归树的基本思想	50
6.5.2	CART 回归树的划分准则	50
6.5.3	回归树的构建过程	51
6.6	决策树构建例题（考点：贷款申请问题）	51
6.7	模型小结	56
7	第 7 讲集成学习	57
7.1	个体与集成	57
7.1.1	集成学习的基本概念	57
7.1.2	集成学习的组合方式	57
7.1.3	投票分类器	57
7.1.4	集成学习可能带来的好处	58
7.2	Boosting	58
7.2.1	Boosting 的基本思想	58
7.2.2	AdaBoost 算法	58
7.3	Bagging 与随机森林	61
7.3.1	Bagging 的基本思想	61
7.3.2	随机森林（Random Forest）	62
7.4	多样性	62
7.4.1	多样性的重要性	62
7.4.2	多样性度量	62
7.4.3	多样性增强	63
7.5	比较和总结	63
7.5.1	主要集成方法的对比	63
7.5.2	主流集成学习方法	64
7.5.3	模型小结	64
8	第 8 讲降维与度量学习	64
8.1	基本概念	64
8.1.1	降维的定义与目的	64
8.1.2	特征提取与特征选择	65
8.1.3	特征的类别	65
8.1.4	用于分类的模式特征的特点	65
8.2	主成分分析（PCA）	65
8.2.1	PCA 的基本思想	65
8.2.2	协方差矩阵与特征值分解	65
8.2.3	PCA 的求解（P62 关键步骤）	66

8.2.4	PCA 的计算步骤	67
8.2.5	矩阵 + 特征向量 (考点重点)	71
8.3	线性判别分析 (LDA) 用于降维	72
8.3.1	LDA 降维的基本思想	72
8.3.2	LDA 的数学形式	72
8.4	多维标度 (MDS)	73
8.4.1	MDS 的基本思想	73
8.4.2	MDS 的计算流程	73
8.5	流形学习	73
8.5.1	流形学习的基本思想	73
8.5.2	常见的流形学习方法	73
8.6	度量学习	74
8.6.1	度量学习的基本思想	74
8.7	模型小结	74
9	第 9 讲聚类	74
9.1	聚类任务	74
9.1.1	聚类的基本概念	74
9.1.2	聚类分析的三要素	75
9.1.3	聚类与分类的区别	75
9.2	性能度量	75
9.2.1	性能度量的基本概念	75
9.2.2	外部指标	75
9.2.3	内部指标	76
9.3	距离计算	76
9.3.1	距离度量的性质	76
9.3.2	常用距离度量	76
9.4	原型聚类	77
9.4.1	原型聚类的基本思想	77
9.4.2	k -均值算法 (考点重点)	77
9.4.3	k -均值算法的优缺点	77
9.4.4	k -均值聚类例题 (考点: P35)	78
9.5	密度聚类	79
9.5.1	密度聚类的基本思想	79
9.6	层次聚类	79
9.6.1	层次聚类的基本思想	79
9.6.2	AGNES 算法	80
9.6.3	层次聚类的特点	80
9.7	模型小结	81

10 第 10 讲神经网络	82
10.1 神经元模型	82
10.1.1 基本结构	82
10.1.2 激活函数	82
10.2 感知机与多层网络	82
10.2.1 感知机 (Perceptron)	82
10.2.2 多层前馈神经网络	82
10.3 误差逆传播算法 (BP 算法)	83
10.3.1 BP 算法的基本思想	83
10.4 神经网络的特性和挑战	83
11 第 11 讲强化学习	84
11.1 强化学习问题基本设置	84
11.1.1 强化学习的基本概念	84
11.1.2 马尔可夫决策过程 (MDP)	84
11.1.3 强化学习的目标	84
11.2 K-摇臂赌博机	85
11.3 有模型学习与免模型学习	85
11.4 强化学习与有监督学习的区别	85
11.5 基于人类反馈的强化学习 (RLHF)	85
11.6 模型小结	86

1 第 1 讲概论

1.1 机器学习基本概念

1.1.1 定义

机器学习：一门学科，致力于研究如何通过计算的手段，利用经验（数据）来改善系统自身的性能，从数据中产生模型（model）。

形式化定义：一个计算机程序，从经验 E 中学习关于某一类任务 T 和性能度量 P 的知识，如果它在 T 中的性能如 P 所度量那样，随着经验 E 的提高而提高。

关系：人工智能 $\supset$ 机器学习 $\supset$ 深度学习 $\supset$ 模式识别

1.1.2 样本空间与标记空间

特征向量： $\mathbf{x}_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(d)})^T$ ，其中 d 为特征维度。

样本空间 X ：所有可能存在的、合理的样本的集合。

标记空间 Y ：样本的分类标签或预测取值的集合。

- 二分类： $Y = \{-1, 1\}$ 或 $Y = \{0, 1\}$ （如：是否患病、是否通过考试）
- k 分类：独热编码（one-hot），如数字 5： $(1, 0, 0, 0, 0, 0, 0, 0, 0, 0)^T$ （10 分类问题）
- 回归：实数值连续区间（如：房价、温度、身高）

例子：判断邮件是否为垃圾邮件。特征向量可以是： $\mathbf{x}$ = (包含“免费”的次数, 包含链接数, 发件人信
标记空间 $Y = \{0, 1\}$ （0= 正常，1= 垃圾）。

1.1.3 数据集合

训练集： $D = \{(\mathbf{x}_1, \mathbf{y}_1), (\mathbf{x}_2, \mathbf{y}_2), \dots, (\mathbf{x}_m, \mathbf{y}_m)\}$ ，其中 $\mathbf{x}_i \in X$ ， $\mathbf{y}_i \in Y$ 。

数据划分：训练集（训练模型） $\rightarrow$ 验证集（调节超参数） $\rightarrow$ 测试集（评估泛化性能）

典型划分比例：训练集 70%，验证集 15%，测试集 15%；或训练集 80%，测试集 20%（无验证集时）

1.1.4 张量（Tensor）

n 阶张量：0 阶 = 标量，1 阶 = 向量，2 阶 = 矩阵，3 阶及以上 = 高维数组（如 RGB 图像为 $3 \times H \times W$ 的 3 阶张量）

1.1.5 假设空间与模型

学习目标：从样本空间 X 到标记空间 Y 的映射 $f: X \rightarrow Y$ ，或条件概率分布 $P(Y|X)$ 。

假设空间 H ：所有可能解的集合，假设 $\approx$ 模型。

学习过程：学习器 A 在假设空间 H 中，根据训练集 D ，选择最优假设 g 使 $g \approx f$ 。

模型表示： $g(\mathbf{x}, \mathbf{w})$ ，其中 $\mathbf{w}$ 为模型参数，学习即优化 $\mathbf{w}$ 。

1.1.6 学习策略（学习准则）

1. 经验风险最小化（ERM）：在训练样本上取得最小的经验误差。

损失函数： $L(\mathbf{w}) = \text{distance}(\mathbf{y}, \hat{\mathbf{y}})$ ，度量预测值与真实值的差异。

常用损失函数：

- L1 损失： $|\hat{y}_i - y_i|$
- L2 损失： $(\hat{y}_i - y_i)^2$
- 铰链损失： $\max(0, 1 - \hat{y}_i y_i)$ （SVM）
- 交叉熵损失： $-y_i \ln \hat{y}_i - (1 - y_i) \ln(1 - \hat{y}_i)$ （二分类）
- 指数损失： $\exp(-\hat{y}_i y_i)$

均方误差 (MSE):

$$MSE = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2$$

2. 结构风险最小化 (SRM): 在经验风险基础上增加正则化约束, 降低模型复杂度, 提升泛化能力。

泛化能力: 模型对新样本的适应能力。

选择原则: 归纳偏置 (对某种假设的偏好)、奥卡姆剃刀 (选择最简单模型)。

1.1.7 优化算法

算法: 最优化损失函数训练模型参数的方法。

常用优化算法:

- 梯度下降法 (Gradient Descent)
- 牛顿法 (Newton Method)
- Lagrange 乘数法 (对偶问题)
- 内点法 (Interior Point Method)

凸优化: 优化凸函数, 在机器学习中常将损失函数设计为凸函数。

1.1.8 机器学习三要素

机器学习方法 = 模型 + 策略 + 算法

- **模型:** 假设空间 (如线性模型、神经网络)
- **策略:** 学习准则 (ERM、SRM)
- **算法:** 优化方法 (梯度下降等)

1.2 机器学习分类

1.2.1 按样本标记分类

- **有监督学习:** 有标签数据, 学习 $X \rightarrow Y$ 映射 (分类、回归)
- **无监督学习:** 无标签, 发现数据隐藏结构 (聚类、降维)
- **半监督学习:** 部分有标签
- **强化学习:** 通过奖励机制学习最优策略

例题

题目：请简述以下几种机器学习范式的区别，并各举一例：

1. 监督学习 (Supervised Learning)
2. 无监督学习 (Unsupervised Learning)
3. 半监督学习 (Semi-supervised Learning)
4. 强化学习 (Reinforcement Learning)

解答：

1. **监督学习：**使用带标签的训练数据学习从输入到输出的映射。例子：垃圾邮件分类（输入：邮件内容，输出：是否为垃圾邮件）。
2. **无监督学习：**从无标签数据中发现隐藏的模式或结构。例子：客户聚类分析（根据购买行为将客户分成不同群体）。
3. **半监督学习：**结合少量有标签数据和大量无标签数据进行学习。例子：图像分类（只有少量图像标注了类别，大部分图像未标注）。
4. **强化学习：**智能体通过与环境交互，根据奖励信号学习最优策略。例子：AlphaGo 下围棋（通过不断对弈，根据胜负结果调整策略）。

例题

题目：在机器学习建模过程中，一般包括哪些主要步骤？

解答：

1. **问题定义：**明确要解决什么问题，是分类、回归还是其他任务
2. **数据收集：**收集相关数据，确保数据质量和数量
3. **数据预处理：**数据清洗（处理缺失值、异常值）、特征工程、数据标准化/归一化
4. **模型选择：**根据问题特点选择合适的算法
5. **模型训练：**划分训练集、验证集、测试集；使用训练集训练模型；使用验证集调整超参数
6. **模型评估：**使用测试集评估模型性能
7. **模型优化：**根据评估结果调整模型或重新训练
8. **模型部署：**将训练好的模型应用到实际场景

1.2.2 按学习方式分类

- **基于实例的学习：**记忆样例，通过相似度泛化（如 kNN）
- **基于模型的学习：**构建模型进行预测

1.2.3 按建模方式分类

- **判别式模型：**学习决策边界，直接预测（逻辑回归、SVM、决策树）
- **生成式模型：**学习数据分布，基于贝叶斯公式计算后验概率（朴素贝叶斯、GMM、GAN）

1.3 主要挑战

- **数据不足：**需要大量训练样本
- **数据不具代表性：**采样偏差导致泛化能力差
- **数据质量差：**错误、异常值、噪声、缺失值
- **无关特征与互相关特征：**特征工程（选择、清洗、提取、构建）
- **过拟合：**模型过于复杂，训练集表现好但测试集差。解决：正则化、增加数据、特征工程
- **欠拟合：**模型过于简单，未学到数据规律。解决：增加模型复杂度、特征工程

2 第 2 讲模型选择与评估

2.1 监督学习的计算理论

2.1.1 经验误差与泛化误差

经验误差 $E_{\text{in}}(g)$: 学到的模型 g 在训练样本 (in-of-sample) 上的损失。训练的目标是使 $E_{\text{in}}(g)$ 尽可能小。

泛化误差 $E_{\text{out}}(g)$: 模型 g 在除了训练样本外的其他所有样本 (out-of-sample) 上的损失。测试过程希望 $E_{\text{out}}(g)$ 接近 $E_{\text{in}}(g)$ 。

核心问题:

1. **模型选择:** 是否可以通过学习实现 $E_{\text{out}}(g) \approx E_{\text{in}}(g)$? (是否可学习?)
2. **模型评估:** 无法获得训练样本外的其他样本, 如何评估 $E_{\text{out}}(g)$?

理解: 理想情况下, 我们希望训练好的模型在训练集上表现好 (经验误差小), 在未知数据上表现也好 (泛化误差小)。如果经验误差小而泛化误差大, 说明模型过拟合了训练数据。

2.1.2 k 近邻算法 (kNN)

工作原理:

1. 给定训练样本集合, 每个样本都有标签
2. 输入新数据, 计算新数据与训练样本的距离
3. 选择距离最近的 k 个样本 (k 一般不大于 20)
4. 投票法: 选择 k 个样本中出现次数最多的类别作为预测结果
5. 平均法 (回归问题): 将 k 个样本的实值输出标记的平均值作为预测结果

特点:

- 优点: 精度高、对异常值不敏感、无数据输入假定
- 缺点: 计算复杂度高、空间复杂度高 (需要存储全部训练数据)
- 适用: 数值型和标称型数据
- 属于 Lazy Learner (懒惰学习器), 训练工作少但识别工作量

距离度量 (闵可夫斯基距离):

$$L_p(\mathbf{x}_i, \mathbf{x}_j) = \left(\sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|^p \right)^{\frac{1}{p}}$$

- $p = 1$: 曼哈顿距离 $L_1 = \sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|$
- $p = 2$: 欧式距离 $L_2 = \sqrt{\sum_{l=1}^n (x_i^{(l)} - x_j^{(l)})^2}$
- $p = \infty$: 切比雪夫距离 $L_\infty = \max_l |x_i^{(l)} - x_j^{(l)}|$

2.2 误差构成与过拟合

2.2.1 过拟合与欠拟合

过拟合 (Overfitting):

- **表现:** $E_{\text{in}}(g)$ 很小, 但 $E_{\text{out}}(g)$ 很大, 即训练集表现好但测试集表现差
- **原因:** 模型过于复杂, 学习了训练数据中的噪声和细节, 失去了泛化能力
- **解决:** 正则化、增加数据量、简化模型、早停 (early stopping)、Dropout 等

欠拟合 (Underfitting):

- 表现: $E_{in}(g)$ 和 $E_{out}(g)$ 都很大, 模型在训练集和测试集上表现都差
- 原因: 模型过于简单, 没有学习到数据中的规律
- 解决: 增加模型复杂度、特征工程、增加训练轮数等

理解: 过拟合和欠拟合本质上是模型复杂度与数据复杂度之间的平衡问题。模型太简单会导致欠拟合, 太复杂会导致过拟合, 需要找到合适的平衡点。

2.2.2 模型复杂度与泛化能力

理想情况下, 随着模型复杂度增加:

- 经验误差 E_{in} 逐渐减小
- 泛化误差 E_{out} 先减小后增大 (形成 U 型曲线)
- 最优模型复杂度是 E_{out} 最小的点

2.3 模型验证与测试

2.3.1 数据集划分

训练集 (Training Set): 用于训练模型, 降低经验误差 E_{in} 。

验证集 (Validation Set): 用于模型选择和超参数调节, 避免在测试集上直接调参导致的信息泄露。

测试集 (Test Set): 用于最终评估模型性能, 估计泛化误差 E_{out} 。

划分原则: 测试集应该在模型训练和调参过程中完全不可见, 才能真实反映模型的泛化能力。

2.3.2 交叉验证

k 折交叉验证 (k -fold Cross Validation):

1. 将数据集 D 随机划分为 k 个大小相似的互斥子集: $D = D_1 \cup D_2 \cup \dots \cup D_k$
2. 每次用 $k - 1$ 个子集作为训练集, 剩余 1 个子集作为验证集
3. 重复 k 次, 得到 k 个验证结果
4. 取 k 次验证结果的平均值作为最终性能评估

留一法 (Leave-One-Out, LOO): k 折交叉验证的特例, k 等于样本数 m 。计算量大但结果更可靠。

留出法 (Hold-out): 直接将数据集划分为训练集和测试集 (通常比例为 7:3 或 8:2)。

理解: 交叉验证可以有效利用有限的的数据, 通过多次划分减少因数据划分随机性带来的评估偏差。

交叉验证的主要作用:

- 充分利用数据: 在数据量有限时, 通过多次划分充分利用所有数据
- 减少评估偏差: 多次交叉验证取平均可以减小随机性带来的偏差
- 模型选择: 比较不同模型或不同超参数设置, 选择最优模型
- 泛化能力估计: 更准确地估计模型在未知数据上的表现

例题

题目：你在一个回归问题上使用了两种模型：线性回归（LR）与支持向量回归（SVR）。使用 5 折交叉验证得到平均 MSE 如下：

模型	Fold1	Fold2	Fold3	Fold4	Fold5
LR	25	28	27	30	26
SVR	20	23	22	21	20

1. 计算两种模型的平均 MSE，并判断哪一个更优。
2. 简述交叉验证的主要作用。

解答：

1. 计算平均 MSE：

- LR 平均 MSE: $\frac{25+28+27+30+26}{5} = 27.2$
- SVR 平均 MSE: $\frac{20+23+22+21+20}{5} = 21.2$
- 因为 SVR 的 MSE 更小，所以 **SVR 更优**

2. 交叉验证的主要作用：

- 充分利用数据：在数据量有限时，通过多次划分充分利用所有数据
- 减少评估偏差：多次交叉验证取平均可以减小随机性带来的偏差
- 模型选择：比较不同模型或不同超参数设置
- 泛化能力估计：更准确地估计模型在未知数据上的表现

2.4 模型的性能度量

2.4.1 分类问题的性能度量

混淆矩阵：二分类问题的混淆矩阵

	预测正例	预测反例
真实正例	TP（真正例）	FN（假反例）
真实反例	FP（假正例）	TN（真反例）

常用指标：

- 准确率（Accuracy）: $Acc = \frac{TP+TN}{TP+TN+FP+FN}$
- 精确率（Precision）: $P = \frac{TP}{TP+FP}$ （预测为正例中真正为正例的比例）
- 召回率（Recall）: $R = \frac{TP}{TP+FN}$ （真实正例中被正确预测的比例，又称查全率）
- F1 值: $F1 = \frac{2PR}{P+R}$ （精确率和召回率的调和平均）

例题

题目：某二分类模型在测试集上的混淆矩阵如下：

	预测正类	预测负类
实际正类	45 (TP)	5 (FN)
实际负例	15 (FP)	35 (TN)

请计算以下指标（保留两位小数）：准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1 值（F1-score）。

解答：

- 准确率: $Acc = \frac{TP+TN}{TP+TN+FP+FN} = \frac{45+35}{100} = 0.80$
- 精确率: $P = \frac{TP}{TP+FP} = \frac{45}{45+15} = 0.75$
- 召回率: $R = \frac{TP}{TP+FN} = \frac{45}{45+5} = 0.90$
- F1 值: $F1 = \frac{2PR}{P+R} = \frac{2 \times 0.75 \times 0.90}{0.75+0.90} = 0.82$

理解:

- 精确率关注”预测的正例中有多少是对的”，用于避免将负例误判为正例
- 召回率关注”所有正例中有多少被找出来了”，用于避免漏掉正例
- F1 值综合考虑精确率和召回率，适用于两者同等重要的场景
- 当精确率和召回率的重要性不同时，可使用 F_β 值: $F_\beta = \frac{(1+\beta^2)PR}{\beta^2 P + R}$

ROC 曲线与 AUC:

- ROC 曲线: 以假正例率 (FPR) 为横轴, 真正例率 (TPR, 即召回率) 为纵轴
- AUC (Area Under Curve): ROC 曲线下的面积, AUC 越大说明分类器性能越好
- AUC = 1: 完美分类器; AUC = 0.5: 随机猜测; AUC < 0.5: 比随机猜测还差

2.4.2 回归问题的性能度量

均方误差 (MSE):

$$MSE = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2$$

均方根误差 (RMSE):

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2}$$

平均绝对误差 (MAE):

$$MAE = \frac{1}{m} \sum_{i=1}^m |\hat{y}_i - y_i|$$

决定系数 R^2 (拟合优度):

$$R^2 = 1 - \frac{SSE}{SST} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

其中 SSE 为残差平方和, SST 为总平方和。 R^2 越接近 1 表明拟合优度越高。

理解:

- MSE 对异常值敏感 (因为平方项放大误差), RMSE 与目标变量同量纲
- MAE 对异常值不敏感, 但优化难度较大 (绝对值不可导)
- R^2 反映模型能够解释的数据方差比例, $R^2 = 1$ 表示完美拟合, $R^2 < 0$ 表示模型不如直接使用均值预测

例子: 预测房价。如果真实房价为 100 万, 预测为 110 万, 则 $MSE = (110 - 100)^2 = 100$, $MAE = |110 - 100| = 10$ 。如果有一个异常值 (真实 200 万, 预测 50 万), MSE 会被放大很多, 而 MAE 相对稳定。

2.5 模型的比较检验

说明: 统计检验方法 (t 检验、McNemar 检验等) 在基础考试中通常不要求详细计算, 了解基本概念即可。重点掌握性能度量指标 (准确率、精确率、召回率、F1 值等) 的计算和应用。

3 第 3 讲线性判别分析

[考点] 考点：P33 页公式，三个判别类型，判断类，分布区域，画图，正侧和负侧

3.1 线性回归及其推广

3.1.1 线性回归基本模型

线性回归：从样本中学习一个线性模型 $g(\mathbf{x})$ 表征自变量（特征）和因变量（标记）之间的关系。

多元线性回归方程：

$$\hat{y}_i = g(\mathbf{x}_i) = w_1 x_{i1} + w_2 x_{i2} + \cdots + w_d x_{id} + w_0 = \mathbf{x}_i^T \mathbf{w} + w_0$$

其中 $\hat{y}_i$ 是回归预测值， $\mathbf{w} = (w_1, \dots, w_d)^T$ 是权重向量， w_0 是偏置项。

矩阵形式：
$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^T & 1 \\ \vdots & \vdots \\ \mathbf{x}_m^T & 1 \end{bmatrix}, \quad \hat{\mathbf{y}} = \mathbf{X}\mathbf{w}。$$

3.1.2 线性回归学习准则

损失函数与代价函数：

- 损失函数：定义在单样本上，度量单个样本的预测误差
- 代价函数：定义在全体样本上，是损失函数在所有训练样本上的平均值
- 本课程不严格区分，统称为 Loss

最小均方误差（MSE）准则：

$$\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} \sum_{i=1}^m (\hat{y}_i - y_i)^2 = \underset{\mathbf{w}}{\operatorname{argmin}} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

解析解（当 $\mathbf{X}^T \mathbf{X}$ 可逆时）：

$$\mathbf{w}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

矩阵形式推导：

- 对代价函数 $J(\mathbf{w}) = \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2 = (\mathbf{X}\mathbf{w} - \mathbf{y})^T (\mathbf{X}\mathbf{w} - \mathbf{y})$ 求导
- 令 $\frac{\partial J}{\partial \mathbf{w}} = 2\mathbf{X}^T (\mathbf{X}\mathbf{w} - \mathbf{y}) = 0$
- 得到正规方程： $\mathbf{X}^T \mathbf{X} \mathbf{w} = \mathbf{X}^T \mathbf{y}$
- 当 $\mathbf{X}^T \mathbf{X}$ 可逆时， $\mathbf{w}^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$

理解：

- 线性回归通过最小化预测值与真实值的平方误差来学习最优参数
- 当特征数 d 很大或样本数 m 很小时， $\mathbf{X}^T \mathbf{X}$ 可能不可逆（奇异），需要正则化
- 正则化方法：岭回归（L2 正则化）、Lasso 回归（L1 正则化）
- 当 $\mathbf{X}^T \mathbf{X}$ 不可逆时，可使用梯度下降法等迭代优化方法

例题

题目：岭回归正则化效果分析。已知某多元线性回归问题中，特征矩阵 $\mathbf{X}$ 存在多重共线性（如两个特征高度相关）。若分别使用普通线性回归和岭回归（Ridge Regression）建模，回答以下问题：

1. 多重共线性会对普通线性回归的参数估计产生什么影响？（从参数稳定性、方差角度说明）
2. 岭回归通过引入正则化项 $\lambda \sum_{j=1}^p w_j^2$ ($\lambda \geq 0$, p 为特征数) 解决该问题，简述正则化项的作用。
3. 当正则化参数 λ 分别取以下值时，分析对岭回归模型参数 w_j 和模型泛化能力的影响： $\lambda = 0$ ； λ 趋近于正无穷。

解答：

1. 多重共线性的影响：

- **参数稳定性：**参数估计变得不稳定，微小的数据变化可能导致参数估计值发生很大变化，参数的标准误差增大
- **方差角度：**参数估计的方差增大， $(\mathbf{X}^T \mathbf{X})^{-1}$ 接近奇异，条件数很大，导致数值计算不稳定

2. 正则化项的作用：

- 控制模型复杂度，防止过拟合
- 解决多重共线性，使参数估计更稳定
- 降低参数估计的方差，提高泛化能力

3. 参数 λ 的影响：

- $\lambda = 0$ ：退化为普通线性回归，如果存在多重共线性，参数估计仍然不稳定，可能过拟合
- $\lambda \rightarrow +\infty$ ：所有参数 w_j 被强制压缩到接近 0，模型变得非常简单，可能欠拟合，泛化能力差
- 最优 λ ：通过交叉验证选择，在欠拟合和过拟合之间找到平衡

例题

题目：已知简单线性回归模型为： $y = w_0 + w_1x + \varepsilon$ ，其中 ε 为误差项。现有一组样本数据如下：

x (自变量)	1	2	3	4	5
y (因变量)	2	4	5	4	5

请使用最小二乘法求解模型参数 w_0 (截距) 和 w_1 (斜率)，并写出关键计算步骤。
解答：

1. 计算均值：

$$\bar{x} = \frac{1+2+3+4+5}{5} = 3, \quad \bar{y} = \frac{2+4+5+4+5}{5} = 4$$

2. 计算协方差和方差：

$$S_{xy} = \frac{1}{5} \sum_{i=1}^5 (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{5} [(-2)(-2) + (-1)(0) + (0)(1) + (1)(0) + (2)(1)] = \frac{6}{5} = 1.2$$

$$S_{xx} = \frac{1}{5} \sum_{i=1}^5 (x_i - \bar{x})^2 = \frac{1}{5} [4 + 1 + 0 + 1 + 4] = 2$$

3. 计算参数：

$$w_1 = \frac{S_{xy}}{S_{xx}} = \frac{1.2}{2} = 0.6$$

$$w_0 = \bar{y} - w_1\bar{x} = 4 - 0.6 \times 3 = 2.2$$

4. 回归方程： $y = 2.2 + 0.6x$

3.2 对数几率回归分类器 (Logistic Regression, LR)

3.2.1 基本概念

问题背景：线性回归输出连续值，但分类问题需要输出类别。需要将线性模型的输出映射到概率空间。

对数几率 (Log Odds)：事件发生概率与不发生概率的比值的对数，即 $\ln \frac{p}{1-p}$ 。

对数几率回归的基本思想：

- 假设线性模型的输出等于对数几率： $\ln \frac{p}{1-p} = \mathbf{w}^T \mathbf{x} + w_0$
- 通过反函数 (sigmoid) 将线性输出映射到 (0, 1) 概率区间
- 使用线性模型进行二分类，通过 sigmoid 函数将线性组合映射到概率空间

对数几率函数 (Logit 函数)：

$$\text{logit}(p) = \ln \frac{p}{1-p} = \mathbf{w}^T \mathbf{x} + w_0$$

sigmoid 函数 (Logistic 函数, 反函数)：

$$p = \sigma(z) = \frac{1}{1 + e^{-z}} = \frac{e^z}{1 + e^z}$$

其中 $z = \mathbf{w}^T \mathbf{x} + w_0$, p 是样本属于正类的概率。

sigmoid 函数的性质:

- 定义域: $(-\infty, +\infty)$, 值域: $(0, 1)$
- 单调递增函数
- 当 $z = 0$ 时, $p = 0.5$
- 当 $z \rightarrow +\infty$ 时, $p \rightarrow 1$; 当 $z \rightarrow -\infty$ 时, $p \rightarrow 0$
- 关于点 $(0, 0.5)$ 中心对称

决策规则:

- 当 $p > 0.5$ (即 $z > 0$) 时, 预测为正类
- 当 $p < 0.5$ (即 $z < 0$) 时, 预测为负类
- 决策边界: $z = \mathbf{w}^T \mathbf{x} + w_0 = 0$, 即 $p = 0.5$

理解: 对数几率回归将线性模型的输出通过 sigmoid 函数压缩到 $(0, 1)$ 区间, 解释为样本属于正类的概率。相比线性回归, 它更适合分类任务, 因为输出是概率且可解释。

例子: 预测学生是否通过考试。输入特征: 学习时间、作业完成率、出勤率。输出: 通过概率 p 。如果 $p > 0.5$, 预测为”通过”; 否则预测为”不通过”。

3.2.2 学习策略

最大似然估计 (MLE): 对于二分类问题, 假设样本标签 $y_i \in \{0, 1\}$, 样本 $\mathbf{x}_i$ 属于正类的概率为 $p_i = \sigma(\mathbf{w}^T \mathbf{x}_i + w_0)$ 。

似然函数:

$$L(\mathbf{w}) = \prod_{i=1}^m p_i^{y_i} (1 - p_i)^{1-y_i}$$

对数似然函数:

$$\ln L(\mathbf{w}) = \sum_{i=1}^m [y_i \ln p_i + (1 - y_i) \ln(1 - p_i)]$$

损失函数: 使用负对数似然 (交叉熵损失)

$$L(\mathbf{w}) = - \sum_{i=1}^m [y_i \ln p_i + (1 - y_i) \ln(1 - p_i)]$$

其中 $p_i = \sigma(\mathbf{w}^T \mathbf{x}_i + w_0) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x}_i + w_0)}}$ 是样本 i 属于正类的概率。

优化:

- 无法得到解析解, 通常使用梯度下降法求解
- 需要计算损失函数对 $\mathbf{w}$ 的梯度
- 可以使用牛顿法、拟牛顿法等更高级的优化方法
- 支持正则化 (L1 或 L2 正则化) 防止过拟合

例题

交叉熵损失评估分类器性能

题目：5 个样本的真实标签为 $\{1, 0, 1, 0, 1\}$ 。分类器 A 预测概率为 $\{0.9, 0.01, 0.95, 0.03, 0.99\}$ ，分类器 B 预测概率为 $\{0.85, 0.45, 0.75, 0.55, 0.7\}$ 。计算两个分类器的平均交叉熵损失。

解：

单样本交叉熵损失： $L_i = -[y_i \ln p_i + (1 - y_i) \ln(1 - p_i)]$

平均交叉熵损失： $\bar{L} = \frac{1}{m} \sum_{i=1}^m L_i$

分类器 A 计算示例（样本 1： $y_1 = 1, p_1 = 0.9$ ）：

$$L_1 = -(1 \times \ln 0.9 + 0 \times \ln 0.1) = -\ln 0.9 \approx 0.105$$

分类器 A： $\bar{L}_A = -\frac{1}{5}[(1 \ln 0.9 + 0 \ln 0.1) + (0 \ln 0.01 + 1 \ln 0.99) + (1 \ln 0.95 + 0 \ln 0.05) + (0 \ln 0.03 + 1 \ln 0.97) + (1 \ln 0.99 + 0 \ln 0.01)] = 0.207 \times 0.2 = 0.04$

分类器 B： $\bar{L}_B = -\frac{1}{5}[(1 \ln 0.85 + 0 \ln 0.15) + (0 \ln 0.45 + 1 \ln 0.55) + (1 \ln 0.75 + 0 \ln 0.25) + (0 \ln 0.55 + 1 \ln 0.45) + (1 \ln 0.7 + 0 \ln 0.3)] = 2.203 \times 0.2 = 0.44$

结论： $\bar{L}_A = 0.04 < \bar{L}_B = 0.44$ ，分类器 A 更优。

注意：信息论中 $\log$ 取 2 为底，机器学习中常用 $\ln$ （便于求导）。

3.3 线性判别分析（LDA）

3.3.1 判别函数概念

判别函数：用于分类的函数 $g(\mathbf{x})$ ，根据函数值的符号或大小来判断样本类别。

线性判别函数：

$$g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$$

决策规则：

- 如果 $g(\mathbf{x}) > 0$ ，则判断为类别 ω_1 （正侧）
- 如果 $g(\mathbf{x}) < 0$ ，则判断为类别 ω_2 （负侧）
- 如果 $g(\mathbf{x}) = 0$ ，则位于决策边界上

理解：决策边界 $g(\mathbf{x}) = 0$ 是一个超平面，将特征空间划分为两个区域。 $\mathbf{w}$ 是垂直于决策边界的向量，指向正侧方向。

例子：在 2 维空间中， $g(\mathbf{x}) = w_1 x_1 + w_2 x_2 + w_0 = 0$ 是一条直线。直线的一侧（正侧）判断为 ω_1 类，另一侧（负侧）判断为 ω_2 类。

3.3.2 三个判别类型（考点重点）

三种判别方法的对比：

1. 线性判别函数（Linear Discriminant Function）

定义：直接使用线性函数 $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$ 进行分类，通过参数 $\mathbf{w}$ 和 w_0 定义决策边界。

特点：形式简单，但需要预先确定参数或通过其他方法学习参数。

2. Fisher 线性判别（Fisher's Linear Discriminant）

定义：通过最大化类间散度与类内散度之比来确定最优的投影方向 $\mathbf{w}$ ，然后构造线性判别函数。

目标：寻找一个投影方向 $\mathbf{w}$ ，使得投影后两类样本的类间散度最大，类内散度最小。

类间散度矩阵 S_b ：

$$S_b = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T$$

其中 $\boldsymbol{\mu}_1$ 、 $\boldsymbol{\mu}_2$ 分别是两类样本的均值向量。

类内散度矩阵 S_w ：

$$S_w = S_1 + S_2 = \Sigma_1 + \Sigma_2$$

其中 Σ_1 、 Σ_2 分别是两类样本的协方差矩阵。

Fisher 准则（广义瑞利商）：

$$J(\mathbf{w}) = \frac{\mathbf{w}^T S_b \mathbf{w}}{\mathbf{w}^T S_w \mathbf{w}}$$

目标：最大化 $J(\mathbf{w})$ ，即最大化类间散度与类内散度之比。

特点：有明确的优化准则（Fisher 准则），可以从数据中自动学习最优的 $\mathbf{w}$ ，理论基础扎实。

3. 最小平方误差（MSE）线性判别

定义：基于最小化平方误差准则来确定判别函数参数： $\min \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$ ，其中 $\mathbf{y}$ 是编码后的类别标签（如 +1 和 -1）。

特点：与线性回归类似，将分类问题转化为回归问题，计算简单，但理论上不如 Fisher 判别严谨。

总结：

- 三种方法最终都得到线性判别函数 $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0$
- 区别在于如何确定参数 $\mathbf{w}$ 和 w_0
- Fisher 判别是理论基础最扎实的方法，是考试重点
- 三种方法都可以用于二分类，决策规则相同： $g(\mathbf{x}) > 0$ 为正类， $g(\mathbf{x}) < 0$ 为负类

例题

向量投影计算 (LDA 基础)

题目: 计算向量 $(3, 2)$ 在直线 $3t_1 - t_2 = 0$ 下的投影。

解:

步骤 1: 确定方向向量

对于直线 $At_1 + Bt_2 + C = 0$:

- 法向量: $(A, B) = (3, -1)$
- 方向向量: $(-B, A) = (1, 3)$

所以 $\mathbf{w} = (1, 3)^T$ 。

步骤 2: 归一化为单位向量

$$\|\mathbf{w}\| = \sqrt{1^2 + 3^2} = \sqrt{10}$$

$$\mathbf{w}_0 = \frac{\mathbf{w}}{\|\mathbf{w}\|} = \left(\frac{\sqrt{10}}{10}, \frac{3\sqrt{10}}{10} \right)^T$$

步骤 3: 计算投影

向量 $\mathbf{u} = (3, 2)^T$ 在单位向量 $\mathbf{w}_0$ 上的投影坐标:

$$\text{投影坐标} = \mathbf{u} \cdot \mathbf{w}_0 = (3, 2) \cdot \left(\frac{\sqrt{10}}{10}, \frac{3\sqrt{10}}{10} \right) = \frac{9\sqrt{10}}{10}$$

重要公式:

- 直线 $At_1 + Bt_2 + C = 0$ 的方向向量: $(-B, A)$
- 向量 $\mathbf{u}$ 在单位向量 $\mathbf{v}$ 上的投影: $\mathbf{u} \cdot \mathbf{v}$
- 投影向量: $(\mathbf{u} \cdot \mathbf{v}) \times \mathbf{v}$

3.3.3 Fisher 判别的求解 (P33 核心公式)

Fisher 准则的等价形式: 最大化广义瑞利商 $J(\mathbf{w}) = \frac{\mathbf{w}^T S_b \mathbf{w}}{\mathbf{w}^T S_w \mathbf{w}}$ 等价于:

约束优化问题:

$$\max_{\mathbf{w}} \quad \mathbf{w}^T S_b \mathbf{w} \quad (1)$$

$$\text{s.t.} \quad \mathbf{w}^T S_w \mathbf{w} = 1 \quad (2)$$

为什么需要约束: 如果没有约束, $J(\mathbf{w})$ 对 $\mathbf{w}$ 的尺度不敏感 (分子分母同时乘以常数, 比值不变)。约束 $\mathbf{w}^T S_w \mathbf{w} = 1$ 固定了 $\mathbf{w}$ 的尺度, 使优化问题有唯一解。

使用 Lagrange 乘数法求解:

步骤 1: 构造 Lagrange 函数

$$L(\mathbf{w}, \lambda) = \mathbf{w}^T S_b \mathbf{w} - \lambda(\mathbf{w}^T S_w \mathbf{w} - 1)$$

步骤 2: 对 $\mathbf{w}$ 求偏导并令其为零

$$\frac{\partial L}{\partial \mathbf{w}} = 2S_b \mathbf{w} - 2\lambda S_w \mathbf{w} = 0$$

步骤 3: 得到广义特征值问题

$$S_b \mathbf{w} = \lambda S_w \mathbf{w}$$

步骤 4: 求解 (当 S_w 可逆时)

$$S_w^{-1} S_b \mathbf{w} = \lambda \mathbf{w}$$

注意到 $S_b = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^T$ 是秩 1 矩阵, 其唯一非零特征值对应的特征向量方向就是 $S_w^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$ 的方向。

最优解 (P33 关键公式):

$$\mathbf{w}^* = S_w^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = (\Sigma_1 + \Sigma_2)^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$$

偏置项:

$$w_0^* = -\mathbf{w}^{*T} \frac{\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2}{2}$$

偏置项的几何意义: 决策边界 $g(\mathbf{x}) = 0$ 通过两类均值的中心点 $\frac{\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2}{2}$, 所以 $g\left(\frac{\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2}{2}\right) = \mathbf{w}^{*T} \frac{\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2}{2} + w_0^* = 0$, 由此得到偏置项。


理解:

- $\mathbf{w}^*$ 的方向是从 $\boldsymbol{\mu}_2$ 指向 $\boldsymbol{\mu}_1$ (经过 S_w^{-1} 加权), S_w^{-1} 的作用是考虑了两类样本的散布情况
- 当两类协方差矩阵相等时 ($\Sigma_1 = \Sigma_2 = \Sigma$), $S_w = 2\Sigma$, $\mathbf{w}^* \propto \Sigma^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$
- 决策边界垂直于 $\mathbf{w}^*$, 并通过两类均值的中心点, 将特征空间分为两个半空间
- Fisher 判别假设两类数据都服从高斯分布, 且协方差矩阵相同 (或相近), 此时 Fisher 判别等价于贝叶斯最优分类器

3.3.4 决策区域与正负侧 (考点重点)

决策边界: $g(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + w_0 = 0$

决策区域划分:



关键概念:

- 正侧: $g(\mathbf{x}) > 0$ 的区域, 判断为类别 ω_1
- 负侧: $g(\mathbf{x}) < 0$ 的区域, 判断为类别 ω_2
- 决策边界: $g(\mathbf{x}) = 0$, 是一个超平面 (在 2D 中是直线)
- 方向向量 $\mathbf{w}$: 垂直于决策边界, 指向正侧方向
- 分布区域: 正侧和负侧各自形成一个半空间

理解：给定一个样本点 $\mathbf{x}$ ，计算 $g(\mathbf{x})$ 的值。如果 $g(\mathbf{x}) > 0$ ，说明 $\mathbf{x}$ 位于正侧，判断为 ω_1 类；如果 $g(\mathbf{x}) < 0$ ，说明 $\mathbf{x}$ 位于负侧，判断为 ω_2 类。决策边界上的点 $g(\mathbf{x}) = 0$ ，可以任意分配到某一类。

考试要点：

- 能根据给定的 $\mathbf{w}$ 和 w_0 ，判断新样本属于哪一类
- 能画出决策边界，标注正侧和负侧
- 理解 $\mathbf{w}$ 的方向指向正侧

3.3.5 解题步骤（计算题）

给定两类样本数据，求线性判别函数和决策区域：

步骤 1： 计算两类样本的统计量

- 类别 ω_1 ：均值 $\boldsymbol{\mu}_1$ ，协方差矩阵 Σ_1
- 类别 ω_2 ：均值 $\boldsymbol{\mu}_2$ ，协方差矩阵 Σ_2

步骤 2： 计算类内散度矩阵

$$S_w = \Sigma_1 + \Sigma_2$$

步骤 3： 计算权重向量

$$\mathbf{w}^* = S_w^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$$

步骤 4： 计算偏置项

$$w_0^* = -\mathbf{w}^{*T} \frac{\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2}{2}$$

步骤 5： 写出判别函数

$$g(\mathbf{x}) = \mathbf{w}^{*T} \mathbf{x} + w_0^*$$

步骤 6： 确定决策规则和区域

- 决策边界： $g(\mathbf{x}) = 0$
- 正侧 (ω_1 类)： $g(\mathbf{x}) > 0$
- 负侧 (ω_2 类)： $g(\mathbf{x}) < 0$

步骤 7： 对新样本 $\mathbf{x}_{\text{new}}$ 进行分类

- 计算 $g(\mathbf{x}_{\text{new}})$
- 如果 $g(\mathbf{x}_{\text{new}}) > 0$ ，预测为 ω_1 类
- 如果 $g(\mathbf{x}_{\text{new}}) < 0$ ，预测为 ω_2 类

3.3.6 模型小结

模型： 核心参数是投影直线的方向向量 $\mathbf{w}$ 和偏置项 w_0 。

策略（准则）： 最大广义瑞利商 $J = \frac{\mathbf{w}^T S_b \mathbf{w}}{\mathbf{w}^T S_w \mathbf{w}}$ 。

算法： 使用 Lagrange 乘数法求解，得到 $\mathbf{w}^* = S_w^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$ 。

3.3.7 多类分类例题详解（考点重点）

三种方法对比：

- 方法 1（一对多）： $d_i(X)$ 区分 ω_i vs 其他；规则： $d_i > 0$ 且所有 $d_j < 0$ ($j \neq i$)
- 方法 2（成对两分）： $d_{ij}(X)$ 区分 ω_i vs ω_j ；规则：所有 $d_{ij} > 0$ ($j \neq i$)；性质： $d_{ji} = -d_{ij}$
- 方法 3（无 IR 区）： $d_{ij} = d_i - d_j$ ；规则： $d_i = \max\{d_k\}$ （比较大小，非正负号）

判断正负侧方法：

- 方法 1：代入特殊点（如原点）， $d(X) > 0$ 为正侧
- 方法 2：画方向向量 w （系数向量），箭头指向为正侧

例题

例 1：一对多方法

题目：三类判别函数 $d_1(X) = -x_1 + x_2 + 1$, $d_2(X) = x_1 + x_2 - 4$, $d_3(X) = -x_2 + 1$ 。
判断 $X = [7, 5]^T$ 属于哪类？

解：

1. 计算： $d_1 = -1 < 0$, $d_2 = 8 > 0$, $d_3 = -4 < 0$
2. 判断： ω_2 满足 ($d_2 > 0$ 且 $d_1, d_3 < 0$)
3. 结论： $X \in \omega_2$

决策边界： $d_1 = 0 \Rightarrow x_2 = x_1 - 1$; $d_2 = 0 \Rightarrow x_2 = -x_1 + 4$; $d_3 = 0 \Rightarrow x_2 = 1$

分布区域： ω_1 : $d_1 > 0$ 且 $d_2, d_3 < 0$; ω_2 : $d_2 > 0$ 且 $d_1, d_3 < 0$; ω_3 : $d_3 > 0$ 且 $d_1, d_2 < 0$

例题

例 2：成对两分法（已知位置和正负侧）

分类规则： $X \in \omega_i$ 当且仅当所有 $d_{ij} > 0$ ($j \neq i$)

三类判断：

- ω_1 : $d_{12} > 0$ 且 $d_{13} > 0$
- ω_2 : $d_{21} > 0$ 且 $d_{23} > 0$ (即 $d_{12} < 0$ 且 $d_{23} > 0$)
- ω_3 : $d_{31} > 0$ 且 $d_{32} > 0$ (即 $d_{13} < 0$ 且 $d_{23} < 0$)

注意：判断 ω_i 时只需检查以 i 开头的判别函数，不满足任何条件则为 IR 区。

例题

例 3：成对两分法（给定判别函数）

题目： $d_{12}(X) = -x_1 - x_2 + 5$, $d_{13}(X) = -x_1 + 3$, $d_{23}(X) = -x_1 + x_2$ 。判断 $X = [4, 3]^T$ 属于哪类？

解：

1. 计算： $d_{12} = -2$, $d_{13} = -1$, $d_{23} = -1$
2. 求反向： $d_{21} = 2$, $d_{31} = 1$, $d_{32} = 1$ (利用 $d_{ji} = -d_{ij}$)
3. 判断：
 - ω_1 : $d_{12} = -2 < 0$ (不满足)
 - ω_2 : $d_{21} = 2 > 0$ 但 $d_{23} = -1 < 0$ (不满足)
 - ω_3 : $d_{31} = 1 > 0$ 且 $d_{32} = 1 > 0$ (满足)
4. 结论： $X \in \omega_3$

例题

多类情况 3: 无 IR 区

核心: $d_{ij} = d_i - d_j$, 每个类有独立判别函数 $d_i(X) = \mathbf{W}_i^T X$

分类规则: $X \in \omega_i$ 当且仅当 $d_i(X) = \max\{d_k(X)\}$

解题步骤:

1. 计算所有 $d_i(X)$
2. 找最大值
3. 确定类别

注意: 基于大小比较, 非正负号判定。

3.4 多分类学习

问题: LDA 和对数几率回归主要用于二分类, 多分类问题需要扩展。

3.4.1 多分类策略

一对一 (One-vs-One, OvO):

- 对 k 个类别两两配对, 共训练 $\frac{k(k-1)}{2}$ 个二分类器
- 每个分类器只区分两个类别
- 预测时, 所有分类器投票, 得票最多的类别为最终预测结果
- 优点: 每个分类器只需训练两个类别的样本, 训练速度快
- 缺点: 需要训练的分类器数量多, 存储开销大

一对多 (One-vs-Rest, OvR):

- 对每个类别训练一个二分类器: 该类 vs 其他所有类
- 共训练 k 个二分类器
- 预测时, 选择输出概率最大 (或得分最高) 的类别
- 优点: 只需训练 k 个分类器, 存储开销小
- 缺点: 每个分类器需要处理所有样本, 可能存在类别不平衡问题

多对多 (Many-vs-Many, MvM):

- 每次将若干类作为正类, 若干类作为反类
- 常见方法: 纠错输出码 (ECOC)
- 更灵活但设计更复杂

3.4.2 Softmax 回归 (多分类对数几率回归)

Softmax 函数: 将 k 个线性组合 $z_j = \mathbf{w}_j^T \mathbf{x} + w_{j0}$ ($j = 1, 2, \dots, k$) 映射到 k 个类别的概率分布

$$p(y = j | \mathbf{x}) = \frac{e^{z_j}}{\sum_{i=1}^k e^{z_i}} = \frac{\exp(\mathbf{w}_j^T \mathbf{x} + w_{j0})}{\sum_{i=1}^k \exp(\mathbf{w}_i^T \mathbf{x} + w_{i0})}$$

Softmax 函数的性质:

- 输出是概率分布: $\sum_{j=1}^k p(y = j | \mathbf{x}) = 1$
- 每个概率都在 $(0, 1)$ 区间内
- 当 z_j 最大时, 对应类别的概率也最大
- 是 sigmoid 函数在多分类问题上的推广

决策规则: 选择概率最大的类别作为预测结果

$$\hat{y} = \underset{j}{\operatorname{argmax}} p(y = j | \mathbf{x}) = \underset{j}{\operatorname{argmax}} z_j$$

损失函数：使用交叉熵损失（多分类）

$$L(\mathbf{W}) = - \sum_{i=1}^m \sum_{j=1}^k \mathbb{I}[y_i = j] \ln p(y = j | \mathbf{x}_i)$$

其中 $\mathbb{I}[\cdot]$ 是指示函数， $\mathbf{W}$ 包含所有 k 个类别的参数。

单样本多分类交叉熵损失：

$$L = - \sum_{j=1}^K y_j \ln p_j$$

其中 y_j 是真实标签（独热编码）， p_j 是预测概率， K 是类别数。

例题

多分类交叉熵损失计算

题目：10 分类手写数字识别，真实标签为数字“5”（独热编码：[0, 0, 0, 0, 0, 1, 0, 0, 0, 0]）。计算两种预测分布的交叉熵损失：

- 分布 1: [0.1, 0.1, 0, 0, 0, 0.7, 0, 0.1, 0, 0]
- 分布 2: [0.2, 0.3, 0.1, 0, 0, 0.3, 0.1, 0, 0, 0]

解：

公式： $L = - \sum_{j=1}^{10} y_j \ln p_j$ （独热编码下只有真实类项有贡献）

分布 1 计算示例（只有 $y_5 = 1$ ，其余为 0）：

$$L_1 = -(0 \times \ln 0.1 + \cdots + 1 \times \ln 0.7 + \cdots) = -\ln 0.7 \approx 0.3567$$

分布 2: $L_2 = -\ln 0.3 \approx 1.2040$

结论： $L_1 = 0.3567 < L_2 = 1.2040$ ，分布 1 更接近真实分布。

注意：使用 $\ln$ 计算； $0 \times \ln 0 = 0$ （约定）。

理解：Softmax 回归是对数几率回归的多分类推广，通过 softmax 函数将 k 个线性组合映射到 k 个类别的概率分布。每个类别都有自己的参数向量 $\mathbf{w}_j$ 和偏置项 w_{j0} ，通过最大似然估计（或最小化交叉熵）来学习这些参数。

4 第 4 讲贝叶斯分类器

[考点] 考点：P21 页，最小风险最小错误率，细胞识别问题

4.1 贝叶斯决策理论基础

4.1.1 概率基础

概率的定义：设 Ω 是随机试验的基本事件空间（样本空间）， A 为随机事件， $P(A)$ 为定义在所有随机事件组成的集合上的实函数。若 $P(A)$ 满足：

1. 对任一事件 A 有： $0 \leq P(A) \leq 1$
2. $P(\Omega) = 1$
3. 对于两两互斥的事件 $A_1, A_2, \dots$ 有： $P(A_1 + A_2 + \cdots) = P(A_1) + P(A_2) + \cdots$

则称函数 $P(A)$ 为事件 A 的概率。

条件概率：

$$P(A|B) = \frac{P(AB)}{P(B)}$$

为事件 B 发生的条件下事件 A 发生的条件概率。

乘法公式：

$$P(AB) = P(B)P(A|B) = P(A)P(B|A) = P(BA)$$

全概率公式： 设事件 $A_1, A_2, \dots, A_n$ 两两互斥，且 $\bigcup_{i=1}^n A_i = \Omega$ ， $P(A_i) > 0$ ，则对任一事件 B 有：

$$P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$$

贝叶斯公式（定理）： 在全概率公式的条件下，如果 $P(B) > 0$ ，则：

$$P(A_i|B) = \frac{P(A_i)P(B|A_i)}{\sum_{i=1}^n P(A_i)P(B|A_i)} = \frac{P(A_i)P(B|A_i)}{P(B)}$$

理解：

- 如果把 B 视为观察结果（证据）， A_i 视为可能的原因，则：
- $P(A_i)$ 称为**先验概率**：未获得观察结果前，对原因 A_i 的认定（根据经验、专业知识等）
- $P(A_i|B)$ 称为**后验概率**：获得观察结果 B 之后，结合先验知识，计算出的对结果 B 是由原因 A_i 引起的概率
- 贝叶斯公式实现了从先验概率到后验概率的更新

4.1.2 机器学习中的概率解释

设随机样本的特征向量为 $\mathbf{X}$ ，对应的类别变量用 ω 表示：

先验概率 $P(\omega_i)$ ： 根据以前知识和经验得出的、一般情况下样本属于 ω_i 类的概率——属事先猜测，故称先验概率。

后验概率 $P(\omega_i|\mathbf{X})$ ： 在观察到特征向量 $\mathbf{X}$ 后，样本属于 ω_i 类的概率——属事后推断，故称后验概率。

类条件概率 $P(\mathbf{X}|\omega_i)$ ： 在类别 ω_i 已知的条件下，特征向量 $\mathbf{X}$ 出现的概率，也称为似然（likelihood）。

证据因子 $P(\mathbf{X})$ ： 特征向量 $\mathbf{X}$ 出现的概率，由全概率公式计算： $P(\mathbf{X}) = \sum_i P(\omega_i)P(\mathbf{X}|\omega_i)$

贝叶斯公式在分类中的应用：

$$P(\omega_i|\mathbf{X}) = \frac{P(\omega_i)P(\mathbf{X}|\omega_i)}{P(\mathbf{X})} = \frac{P(\omega_i)P(\mathbf{X}|\omega_i)}{\sum_j P(\omega_j)P(\mathbf{X}|\omega_j)}$$

理解： 后验概率 = $\frac{\text{先验概率} \times \text{似然}}{\text{证据因子}}$ 。在分类问题中，我们通常只需要比较后验概率的大小，而 $P(\mathbf{X})$ 对所有类别都相同，所以可以忽略。

4.2 最小错误率贝叶斯分类

4.2.1 基本思想

目标：最小化分类错误率，即选择使后验概率最大的类别。

决策规则：

$$\text{选择类别 } \omega_i, \text{ 如果 } P(\omega_i|\mathbf{X}) = \max_j P(\omega_j|\mathbf{X})$$

等价形式（忽略证据因子 $P(\mathbf{X})$ ）：

$$\text{选择类别 } \omega_i, \text{ 如果 } P(\omega_i)P(\mathbf{X}|\omega_i) = \max_j P(\omega_j)P(\mathbf{X}|\omega_j)$$

理解：

- 最小错误率贝叶斯分类器选择后验概率最大的类别
- 这是理论上的最优的分类器，在给定先验概率和类条件概率的情况下，错误率最小
- 决策边界：当 $P(\omega_i|\mathbf{X}) = P(\omega_j|\mathbf{X})$ 时，两类等后验概率，形成决策边界

4.2.2 二分类问题的决策规则

对于二分类问题（ ω_1 和 ω_2 ），决策规则可以简化为：

形式 1：如果 $P(\omega_1|\mathbf{X}) > P(\omega_2|\mathbf{X})$ ，则判断为 ω_1 类；否则判断为 ω_2 类。

形式 2（似然比检验）：

$$\text{如果 } \frac{P(\mathbf{X}|\omega_1)}{P(\mathbf{X}|\omega_2)} > \frac{P(\omega_2)}{P(\omega_1)}, \text{ 则判断为 } \omega_1 \text{ 类；否则判断为 } \omega_2 \text{ 类。}$$

理解：当似然比大于先验概率比时，选择 ω_1 类。这个形式在计算时更方便，因为只需要比较一个比值。

例题

例 1：细胞识别（最小错误率决策）

题目：细胞识别中， $P(\omega_1) = 0.05$ （病变）， $P(\omega_2) = 0.95$ （正常）。观察值 X 的类条件概率： $p(X|\omega_1) = 0.5$ ， $p(X|\omega_2) = 0.2$ 。试对细胞 X 分类。

解：

方法 1：后验概率法

$$P(\omega_1|X) = \frac{0.5 \times 0.05}{0.5 \times 0.05 + 0.2 \times 0.95} = \frac{0.025}{0.215} \approx 0.116$$

$$P(\omega_2|X) = \frac{0.2 \times 0.95}{0.215} = \frac{0.19}{0.215} \approx 0.884$$

因为 $P(\omega_2|X) > P(\omega_1|X)$ ，所以 $X \in \omega_2$ （正常细胞）。

方法 2：先验 $\times$ 似然法（更简单）

$$p(X|\omega_1)P(\omega_1) = 0.5 \times 0.05 = 0.025$$

$$p(X|\omega_2)P(\omega_2) = 0.2 \times 0.95 = 0.19$$

因为 $p(X|\omega_2)P(\omega_2) > p(X|\omega_1)P(\omega_1)$ ，所以 $X \in \omega_2$ 。

注意：方法 2 避免计算分母 $P(X)$ ，更高效。

4.3 最小风险贝叶斯分类（考点重点）

4.3.1 风险与损失函数

问题背景：在某些应用中，不同类型的分类错误造成的损失不同。例如，将癌症患者误判为健康（漏诊）的损失远大于将健康人误判为癌症（误诊）的损失。

损失函数 $\lambda(\alpha_i|\omega_j)$ ：当真实类别为 ω_j 时，采取决策 α_i （判断为 ω_i 类）所造成的损失。

风险函数 $R(\alpha_i|\mathbf{X})$ ：在观察到特征 $\mathbf{X}$ 后，采取决策 α_i 的期望损失（条件风险）：

$$R(\alpha_i|\mathbf{X}) = \sum_{j=1}^c \lambda(\alpha_i|\omega_j)P(\omega_j|\mathbf{X})$$

其中 c 是类别数。

理解：风险函数是损失函数关于后验概率的加权平均，权重是各类别的后验概率。

4.3.2 最小风险决策规则（P21 核心内容）

决策规则：

采取决策 α_i ，如果 $R(\alpha_i|\mathbf{X}) = \min_j R(\alpha_j|\mathbf{X})$ 即选择风险最小的决策。

理解：

- 最小风险贝叶斯分类器选择条件风险最小的决策
- 当所有错误分类的损失相等时，最小风险决策等价于最小错误率决策
- 损失函数 $\lambda(\alpha_i|\omega_j)$ 通常满足： $\lambda(\alpha_i|\omega_i) = 0$ （正确分类无损失）， $\lambda(\alpha_i|\omega_j) > 0$ （ $i \neq j$ ，错误分类有损失）

4.3.3 二分类问题的风险决策

对于二分类问题，设损失矩阵为：

$$\begin{bmatrix} \lambda(\alpha_1|\omega_1) & \lambda(\alpha_1|\omega_2) \\ \lambda(\alpha_2|\omega_1) & \lambda(\alpha_2|\omega_2) \end{bmatrix} = \begin{bmatrix} 0 & \lambda_{12} \\ \lambda_{21} & 0 \end{bmatrix}$$

其中 λ_{12} 表示将 ω_2 类误判为 ω_1 类的损失， λ_{21} 表示将 ω_1 类误判为 ω_2 类的损失。

条件风险：

$$R(\alpha_1|\mathbf{X}) = \lambda(\alpha_1|\omega_1)P(\omega_1|\mathbf{X}) + \lambda(\alpha_1|\omega_2)P(\omega_2|\mathbf{X}) \quad (3)$$

$$= 0 \cdot P(\omega_1|\mathbf{X}) + \lambda_{12}P(\omega_2|\mathbf{X}) = \lambda_{12}P(\omega_2|\mathbf{X}) \quad (4)$$

$$R(\alpha_2|\mathbf{X}) = \lambda(\alpha_2|\omega_1)P(\omega_1|\mathbf{X}) + \lambda(\alpha_2|\omega_2)P(\omega_2|\mathbf{X}) \quad (5)$$

$$= \lambda_{21}P(\omega_1|\mathbf{X}) + 0 \cdot P(\omega_2|\mathbf{X}) = \lambda_{21}P(\omega_1|\mathbf{X}) \quad (6)$$

决策规则：

如果 $R(\alpha_1|\mathbf{X}) < R(\alpha_2|\mathbf{X})$ ，即 $\lambda_{12}P(\omega_2|\mathbf{X}) < \lambda_{21}P(\omega_1|\mathbf{X})$ ，则判断为 ω_1 类；否则判断为 ω_2 类。

等价形式（使用似然比）：

如果 $\frac{P(\mathbf{X}|\omega_1)}{P(\mathbf{X}|\omega_2)} > \frac{\lambda_{12}P(\omega_2)}{\lambda_{21}P(\omega_1)}$ ，则判断为 ω_1 类；否则判断为 ω_2 类。

理解：与最小错误率决策相比，最小风险决策的阈值从 $\frac{P(\omega_2)}{P(\omega_1)}$ 变为 $\frac{\lambda_{12}P(\omega_2)}{\lambda_{21}P(\omega_1)}$ ，损失函数 λ_{12} 和 λ_{21} 会影响决策边界。

损失函数的特殊情况：

- 对称损失: $\lambda_{12} - \lambda_{22} = \lambda_{21} - \lambda_{11}$ 时, 最小风险决策等价于最小错误率决策
- 0-1 损失: $\lambda_{ii} = 0, \lambda_{ij} = 1 (i \neq j)$ 时, 最小风险决策等价于最小错误率决策

例题

例 2: 细胞识别 (最小风险决策-似然比法)

题目: 同例 1 数据, 损失函数: $L_{11} = 0, L_{12} = 1, L_{21} = 10, L_{22} = 0$ 。根据最小风险决策分类。

解:

步骤 1: 计算阈值

$$\theta_{12} = \frac{(L_{12} - L_{22})P(\omega_2)}{(L_{21} - L_{11})P(\omega_1)} = \frac{(1 - 0) \times 0.95}{(10 - 0) \times 0.05} = \frac{0.95}{0.5} = 1.9$$

步骤 2: 计算似然比

$$l_{12}(X) = \frac{p(X|\omega_1)}{p(X|\omega_2)} = \frac{0.5}{0.2} = 2.5$$

步骤 3: 决策

因为 $l_{12}(X) = 2.5 > \theta_{12} = 1.9$, 所以 $X \in \omega_1$ (病变细胞)。

对比: 例 1 (最小错误率) 判为 ω_2 , 例 2 (最小风险) 判为 ω_1 。原因: $L_{21} = 10$ 很大 (漏检损失高), 决策倾向于判为病变以避免高损失。

例题

例 3: 核酸检测 (最小风险决策-条件风险法)

题目: 核酸检测中, 后验概率 $P(\omega_1|x) = 0.818$ (阴性), $P(\omega_2|x) = 0.182$ (阳性)。损失函数: $\lambda_{11} = 0, \lambda_{12} = 6$ (漏检), $\lambda_{21} = 1$ (误检), $\lambda_{22} = 0$ 。试分类。

解:

计算条件风险

$$R(\alpha_1|x) = \lambda_{11}P(\omega_1|x) + \lambda_{12}P(\omega_2|x) = 0 \times 0.818 + 6 \times 0.182 = 1.092$$

$$R(\alpha_2|x) = \lambda_{21}P(\omega_1|x) + \lambda_{22}P(\omega_2|x) = 1 \times 0.818 + 0 \times 0.182 = 0.818$$

决策: 因为 $R(\alpha_2|x) = 0.818 < R(\alpha_1|x) = 1.092$, 所以判为 ω_2 (阳性)。

理解: 虽然 $P(\omega_1|x) > P(\omega_2|x)$, 但漏检损失 $\lambda_{12} = 6$ 很大, 判为阳性风险更小。

4.4 类条件概率的参数估计

4.4.1 最大似然估计 (MLE)

问题: 在实际应用中, 类条件概率 $P(\mathbf{X}|\omega_i)$ 通常是未知的, 需要从训练数据中估计。

最大似然估计的基本思想: 选择使观测数据出现概率最大的参数值。

似然函数: 对于独立同分布的样本 $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_m$, 似然函数为:

$$L(\theta) = \prod_{i=1}^m P(\mathbf{X}_i|\theta)$$

对数似然函数：

$$\ell(\theta) = \ln L(\theta) = \sum_{i=1}^m \ln P(\mathbf{X}_i|\theta)$$

最大似然估计：

$$\hat{\theta}_{MLE} = \operatorname{argmax}_{\theta} L(\theta) = \operatorname{argmax}_{\theta} \ell(\theta)$$

求解方法：对 $\ell(\theta)$ 关于 θ 求导并令其为零，或使用数值优化方法。

例题

MLE 参数估计

题目：总体概率密度函数 $f(x) = 3\lambda x^2 e^{-\lambda x^3}$ ($x > 0$)， λ 未知。样本 $x_1, \dots, x_m$ ，求 λ 的 MLE。

解：

步骤 1：构造似然函数

$$L(\lambda) = \prod_{i=1}^m 3\lambda x_i^2 e^{-\lambda x_i^3} = 3^m \lambda^m \left(\prod_{i=1}^m x_i^2 \right) \exp \left(-\lambda \sum_{i=1}^m x_i^3 \right)$$

步骤 2：取对数

$$\ln L(\lambda) = m \ln(3\lambda) + \sum_{i=1}^m \ln x_i^2 - \lambda \sum_{i=1}^m x_i^3$$

步骤 3：求导并令为零

$$\frac{d(\ln L)}{d\lambda} = \frac{m}{\lambda} - \sum_{i=1}^m x_i^3 = 0$$

步骤 4：求解

$$\hat{\lambda}_{MLE} = \frac{m}{\sum_{i=1}^m x_i^3}$$

4.4.2 高斯分布的参数估计

假设：类条件概率 $P(\mathbf{X}|\omega_i)$ 服从多元高斯分布：

$$P(\mathbf{X}|\omega_i) = \frac{1}{(2\pi)^{d/2} |\Sigma_i|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{X} - \boldsymbol{\mu}_i)^T \Sigma_i^{-1} (\mathbf{X} - \boldsymbol{\mu}_i) \right)$$

参数估计（最大似然估计）：

$$\hat{\boldsymbol{\mu}}_i = \frac{1}{m_i} \sum_{j=1}^{m_i} \mathbf{X}_j^{(i)}$$

$$\hat{\Sigma}_i = \frac{1}{m_i} \sum_{j=1}^{m_i} (\mathbf{X}_j^{(i)} - \hat{\boldsymbol{\mu}}_i)(\mathbf{X}_j^{(i)} - \hat{\boldsymbol{\mu}}_i)^T$$

其中 m_i 是类别 ω_i 的样本数, $\mathbf{X}_j^{(i)}$ 是类别 ω_i 的第 j 个样本。

理解: 高斯分布的 MLE 估计就是样本均值和样本协方差矩阵。

例题

正态分布模式的贝叶斯决策

题目: 两类 3 维样本, $\omega_1: [1, 0, 1]^T, [1, 0, 0]^T, [0, 0, 0]^T, [1, 1, 0]^T$; $\omega_2: [0, 0, 1]^T, [0, 1, 1]^T, [1, 1, 1]^T, [0, 1, 0]^T$ 。 $P(\omega_1) = P(\omega_2) = 0.5$, 协方差矩阵相等。求判别边界。

解:

步骤 1: 计算均值向量

$$\mathbf{M}_1 = \frac{1}{4} \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix}, \quad \mathbf{M}_2 = \frac{1}{4} \begin{bmatrix} 1 \\ 3 \\ 3 \end{bmatrix}$$

步骤 2: 计算协方差矩阵

$$\mathbf{C} = \frac{1}{16} \begin{bmatrix} 3 & 1 & 1 \\ 1 & 3 & -1 \\ 1 & -1 & 3 \end{bmatrix}, \quad \mathbf{C}^{-1} = \begin{bmatrix} 8 & -4 & -4 \\ -4 & 8 & 4 \\ -4 & 4 & 8 \end{bmatrix}$$

步骤 3: 判别函数 (协方差相等时)

$$d_1(\mathbf{X}) - d_2(\mathbf{X}) = (\mathbf{M}_1 - \mathbf{M}_2)^T \mathbf{C}^{-1} \mathbf{X} - \frac{1}{2} \mathbf{M}_1^T \mathbf{C}^{-1} \mathbf{M}_1 + \frac{1}{2} \mathbf{M}_2^T \mathbf{C}^{-1} \mathbf{M}_2$$

步骤 4: 化简

$$d_1(\mathbf{X}) - d_2(\mathbf{X}) = 8x_1 - 8x_2 - 8x_3 + 4 = 0$$

决策边界: $8x_1 - 8x_2 - 8x_3 + 4 = 0$ (线性判别函数)。

注意: 当协方差矩阵相等时, 判别函数是线性的。

4.5 朴素贝叶斯分类器

4.5.1 基本假设

问题: 当特征维度 d 很大时, 估计 $P(\mathbf{X}|\omega_i) = P(x_1, x_2, \dots, x_d|\omega_i)$ 需要大量数据。

朴素贝叶斯假设: 假设所有特征在给定类别条件下相互独立, 即:

$$P(\mathbf{X}|\omega_i) = P(x_1, x_2, \dots, x_d|\omega_i) = \prod_{j=1}^d P(x_j|\omega_i)$$

理解: 这个假设大大简化了概率估计, 只需要估计每个特征的条件概率 $P(x_j|\omega_i)$, 而

不需要估计联合概率。

例子: 判断邮件是否为垃圾邮件。特征: x_1 = 包含“免费”, x_2 = 包含链接数。朴素贝叶斯假设: $P(\text{包含“免费”且包含链接数}|\text{垃圾邮件}) = P(\text{包含“免费”}|\text{垃圾邮件}) \times P(\text{包含链接数}|\text{垃圾邮件})$ 。虽然这个假设通常不成立 (特征可能相关), 但简化了计算且效果往往不错。

例题

题目: 假设一个二分类问题 (类别 C1 与 C2), 观测特征为 x 。已知如下信息:

项目	C1	C2
先验概率 $P(C_i)$	0.6	0.4
条件概率 $P(x C_i)$	0.5	0.2

请根据贝叶斯定理计算后验概率 $P(C_1|x)$ 和 $P(C_2|x)$, 并判断样本属于哪一类。

解答:

1. 计算证据因子 $P(x)$ (全概率公式):

$$P(x) = P(C_1)P(x|C_1) + P(C_2)P(x|C_2) = 0.6 \times 0.5 + 0.4 \times 0.2 = 0.38$$

2. 计算后验概率 $P(C_1|x)$ (贝叶斯公式):

$$P(C_1|x) = \frac{P(C_1)P(x|C_1)}{P(x)} = \frac{0.6 \times 0.5}{0.38} = 0.789$$

3. 计算后验概率 $P(C_2|x)$:

$$P(C_2|x) = \frac{P(C_2)P(x|C_2)}{P(x)} = \frac{0.4 \times 0.2}{0.38} = 0.211$$

4. 判断类别: 因为 $P(C_1|x) = 0.789 > P(C_2|x) = 0.211$, 所以样本属于 C1 类

4.5.2 分类决策

后验概率:

$$P(\omega_i|\mathbf{X}) = \frac{P(\omega_i) \prod_{j=1}^d P(x_j|\omega_i)}{P(\mathbf{X})} = \frac{P(\omega_i) \prod_{j=1}^d P(x_j|\omega_i)}{\sum_k P(\omega_k) \prod_{j=1}^d P(x_j|\omega_k)}$$

决策规则:

$$\text{选择类别 } \omega_i, \text{ 如果 } P(\omega_i) \prod_{j=1}^d P(x_j|\omega_i) = \max_k P(\omega_k) \prod_{j=1}^d P(x_j|\omega_k)$$

优点:

- 计算简单, 只需要估计每个特征的条件概率
- 对缺失数据不敏感
- 对小样本数据表现良好
- 可以处理多分类问题

例题

身高分类（离散与连续特征）

题目：两类样本各 400 例，身高分布如表。判断 $x_1 = 1.55\text{m}$ 和 $x_2 = 1.58\text{m}$ 的类别。
解：

情况 1：离散值 $x_1 = 1.55\text{m}$

频率估计： $P(X = 1.55|\text{成人}) = 40/400 = 0.1$ ， $P(X = 1.55|\text{少年}) = 73/400 = 0.1825$

决策： $0.1825 > 0.1$ ，所以 $x_1 \in \text{少年}$ 。

情况 2：连续值 $x_2 = 1.58\text{m}$ （表中无此值）

高斯分布估计：用 MLE 估计参数，成人 $\sim N(1.648, 0.006)$ ，少年 $\sim N(1.5, 0.004)$

概率密度：

$$p(1.58|\text{成人}) = \frac{1}{\sqrt{2\pi \times 0.006}} \exp\left(-\frac{(1.58 - 1.648)^2}{2 \times 0.006}\right) \approx 3.21$$

$$p(1.58|\text{少年}) = \frac{1}{\sqrt{2\pi \times 0.004}} \exp\left(-\frac{(1.58 - 1.5)^2}{2 \times 0.004}\right) \approx 3.21$$

决策：概率密度相等， x_2 位于决策边界（ $x = 1.58\text{m}$ 处两类等可能）。

注意：离散值用频率估计，连续值用概率密度函数（高斯分布）估计。

缺点：

- 特征独立性假设通常不成立，可能影响分类性能
- 对输入数据的表达形式敏感

例题

题目：朴素贝叶斯分类器原理分析。

1. 简述朴素贝叶斯（Naïve Bayes）分类器的基本假设。
2. 说明这一假设的优缺点。
3. 其常见变体有哪些？

解答：

1. 基本假设：特征条件独立性假设，即所有特征在给定类别条件下相互独立：

$$P(\mathbf{x}|C_i) = P(x_1, x_2, \dots, x_d|C_i) = \prod_{j=1}^d P(x_j|C_i)$$

2. 优缺点：

- 优点：计算简单、参数少、对小样本效果好、训练速度快、对缺失数据不敏感
- 缺点：假设过强（现实中特征往往相关），可能影响分类性能，对输入数据的表达形式敏感

3. 常见变体：

- 高斯朴素贝叶斯：假设连续特征服从高斯分布，适用于连续型特征
- 多项式朴素贝叶斯：适用于计数型特征（如词频），常用于文本分类
- 伯努利朴素贝叶斯：假设特征是二值的（0 或 1），适用于二值特征

4.5.3 参数估计

离散特征：使用频率估计

$$P(x_j = a|\omega_i) = \frac{\text{类别}\omega_i\text{中特征}j\text{取值为}a\text{的样本数}}{\text{类别}\omega_i\text{的样本总数}}$$

连续特征：假设 $P(x_j|\omega_i)$ 服从高斯分布，使用 MLE 估计均值和方差。

拉普拉斯平滑：为了避免零概率问题（某个特征值在训练集中未出现），使用拉普拉斯平滑：

$$P(x_j = a|\omega_i) = \frac{N_{ia} + \alpha}{N_i + \alpha n_j}$$

其中 N_{ia} 是类别 ω_i 中特征 j 取值为 a 的样本数， N_i 是类别 ω_i 的样本总数， n_j 是特征 j 的可能取值数， α 是平滑参数（通常取 1）。

[考点] 考点：朴素贝叶斯分类器（离散 + 连续属性），西瓜书 P80 页

4.6 简单 EM 算法

4.6.1 基本思想

问题：当存在隐变量（未观测到的变量）时，直接使用 MLE 估计参数很困难。

EM 算法 (Expectation-Maximization)：一种迭代算法，用于含有隐变量的概率模型参数估计。

基本步骤：

1. **E 步 (Expectation)：**根据当前参数估计值，计算隐变量的后验概率（期望）
2. **M 步 (Maximization)：**根据 E 步的结果，最大化对数似然函数，更新参数估计值
3. 重复 E 步和 M 步，直到收敛

理解：EM 算法通过迭代的方式，在不知道隐变量真实值的情况下，估计模型参数。每次迭代都会提高对数似然函数的值（或至少不降低），最终收敛到局部最优解。

例题

[考点] 考点：EM 算法（抛硬币问题）

题目：有两枚硬币 A 和 B，进行 5 组实验，每组抛 10 次。观测数据：第 1 组 5H5T，第 2 组 9H1T，第 3 组 8H2T，第 4 组 4H6T，第 5 组 7H3T。不知道每组用的是哪枚硬币（隐变量）。估计 θ_A 和 θ_B （两枚硬币抛出正面的概率）。

解答：

步骤 1：初始化

$$\theta_A^{(0)} = 0.6, \quad \theta_B^{(0)} = 0.5$$

步骤 2：第一次迭代（E 步）

对第 1 组（5H5T），计算来自硬币 A 或 B 的概率：

- $P(\text{数据}|\theta_A) = 0.6^5 \times 0.4^5 \approx 0.000796$
- $P(\text{数据}|\theta_B) = 0.5^5 \times 0.5^5 = 0.000977$
- $P(\text{硬币 A}|\text{数据}) = \frac{0.000796}{0.000796+0.000977} \approx 0.449$
- $P(\text{硬币 B}|\text{数据}) = 1 - 0.449 = 0.551$

类似地计算其他组的权重（简化：假设已知分配，第 2、3、5 组来自 A，第 1、4 组来自 B）。

步骤 3：第一次迭代（M 步）

如果已知分配（最大似然估计）：

- 硬币 A：第 2 组 9H1T，第 3 组 8H2T，第 5 组 7H3T，总计 24H6T
- 硬币 B：第 1 组 5H5T，第 4 组 4H6T，总计 9H11T
- $\theta_A^{(1)} = \frac{24}{24+6} = 0.80$
- $\theta_B^{(1)} = \frac{9}{9+11} = 0.45$

步骤 4：继续迭代

用 $\theta_A^{(1)}$ 和 $\theta_B^{(1)}$ 重复 E 步和 M 步，直到 $|\theta^{(t+1)} - \theta^{(t)}| < \varepsilon$ 。

核心公式：

- **E 步：** $P(z_i|\mathbf{x}_i, \theta^{(t)}) = \frac{P(\mathbf{x}_i|z_i, \theta^{(t)})P(z_i)}{\sum_z P(\mathbf{x}_i|z, \theta^{(t)})P(z)}$
- **M 步：** $\theta^{(t+1)} = \arg \max_{\theta} \sum_i \sum_{z_i} P(z_i|\mathbf{x}_i, \theta^{(t)}) \ln P(\mathbf{x}_i, z_i|\theta)$

注意：如果知道隐变量，直接用 MLE: $\hat{\theta} = \frac{\text{正面次数}}{\text{总次数}}$ 。不知道时用 EM 算法迭代估计。

4.6.2 收敛性

收敛性：EM 算法一定可以收敛，但可能收敛到局部最优解，而非全局最优。

初值敏感性：EM 算法对初值的选择很敏感，不同的初值可能导致算法收敛到不同的局部最优解。因此，在实际应用中，可能需要尝试多个不同的初值。

收敛判断：当参数估计值的变化小于某个阈值 ε 时，认为算法收敛：

$$|\hat{\theta}^{(t+1)} - \hat{\theta}^{(t)}| < \varepsilon$$

4.6.3 模型小结

模型：核心是后验概率 $P(\omega_i|\mathbf{X}) = \frac{P(\omega_i)P(\mathbf{X}|\omega_i)}{P(\mathbf{X})}$ ，需要估计 $P(\mathbf{X}|\omega_i)$ 的概率分布。

策略（准则）：

- **最小错误率决策：**选择 $P(\omega_i|\mathbf{X})$ 最大的类别
- **最小风险决策：**选择 $R(\alpha_i|\mathbf{X})$ 最小的决策

算法：

- **MLE：**估计概率密度参数 θ
- **朴素贝叶斯：**假设特征独立性，简化参数估计

- EM 算法：含隐变量 Z 的参数估计

5 第 5 讲支持向量机

5.1 间隔与支持向量

5.1.1 支持向量机的基本思想

问题背景：对于线性可分的二分类问题，存在无数个分类超平面都能正确分类。但哪个分类器在未知数据上表现更好？

核心思想：选择具有最大间隔（margin）的分类超平面。这样的分类器对两类样本交汇区域的分类能力更强，稳健性更好，泛化能力更强。

理解：

- ”正中间”的分类器相对更好，但不唯一
- 与两类当前边界越远，对未来两类样本的越界点更少误判
- 最大分隔间隔才是最好”正中间”的判断标准

5.1.2 间隔的概念

缓冲区与间隔：假设二分类训练集线性可分，则分别向两个方向平移分类超平面，在与两个类的数据点首次接触后即停止移动，形成了两个平行超平面。这两个平行超平面在两类数据之间形成了一个无样例数据的缓冲区，这个缓冲区的宽度叫作间隔（margin）。

函数间隔（Functional Margin）：对于给定的训练数据集 T 和超平面 $(\mathbf{w}, b)$ ，定义超平面关于样本点 $(\mathbf{x}_i, y_i)$ 的函数间隔为：

$$\hat{\gamma}_i = y_i(\mathbf{w} \cdot \mathbf{x}_i + b)$$

定义超平面关于训练数据集 T 的函数间隔为：

$$\hat{\gamma} = \min_{i=1, \dots, N} \hat{\gamma}_i$$

理解：

- 函数间隔表示分类的正确性及确信度
- $|\mathbf{w} \cdot \mathbf{x} + b|$ 表示点 $\mathbf{x}$ 距离超平面的远近
- $y(\mathbf{w} \cdot \mathbf{x} + b)$ 的符号表示分类是否正确
- 函数间隔可以按比例缩放（ $\mathbf{w}$ 和 b 同时乘以常数，函数间隔也乘以该常数）

几何间隔（Geometric Margin）：点到超平面的实际距离，即函数间隔除以 $\|\mathbf{w}\|$ ：

$$\gamma_i = \frac{\hat{\gamma}_i}{\|\mathbf{w}\|} = \frac{y_i(\mathbf{w} \cdot \mathbf{x}_i + b)}{\|\mathbf{w}\|}$$

定义超平面关于训练数据集 T 的几何间隔为：

$$\gamma = \min_{i=1, \dots, N} \gamma_i = \frac{\hat{\gamma}}{\|\mathbf{w}\|}$$

点到超平面的距离：

$$d(\mathbf{x}, (\mathbf{w}, b)) = \frac{|\mathbf{w} \cdot \mathbf{x} + b|}{\|\mathbf{w}\|}$$

理解：几何间隔是函数间隔的归一化版本，不随 $\mathbf{w}$ 和 b 的缩放而改变，更能反映实际的间隔大小。

例题

[考点] 考点：函数间隔与几何间隔的计算

题目：给定超平面 $2x_1 + 3x_2 - 6 = 0$ 和样本点：

- 样本 A: $(1, 1)$, 标签 $y_A = +1$
- 样本 B: $(3, 2)$, 标签 $y_B = -1$

计算每个样本的函数间隔和几何间隔。

解答：

步骤 1：确定参数

$$\mathbf{w} = [2, 3]^T, \quad b = -6, \quad \|\mathbf{w}\| = \sqrt{2^2 + 3^2} = \sqrt{13}$$

步骤 2：计算函数间隔

- 样本 A: $\hat{\gamma}_A = y_A(\mathbf{w} \cdot \mathbf{x}_A + b) = 1 \times (2 \times 1 + 3 \times 1 - 6) = -1$
- 样本 B: $\hat{\gamma}_B = y_B(\mathbf{w} \cdot \mathbf{x}_B + b) = (-1) \times (2 \times 3 + 3 \times 2 - 6) = -6$

步骤 3：计算几何间隔

- 样本 A: $\gamma_A = \frac{\hat{\gamma}_A}{\|\mathbf{w}\|} = \frac{-1}{\sqrt{13}}$
- 样本 B: $\gamma_B = \frac{\hat{\gamma}_B}{\|\mathbf{w}\|} = \frac{-6}{\sqrt{13}}$

注意：函数间隔为负表示分类错误。几何间隔是归一化后的实际距离。

例题

[考点] 考点：点到超平面距离的计算

题目：给定超平面 $3x_1 - 4x_2 + 5 = 0$, 计算点 $P = (1, 2)$ 到超平面的距离。

解答：

公式： $d = \frac{|\mathbf{w} \cdot \mathbf{x} + b|}{\|\mathbf{w}\|}$

计算：

- $\mathbf{w} = [3, -4]^T, \quad b = 5, \quad \|\mathbf{w}\| = \sqrt{3^2 + (-4)^2} = 5$
- $d = \frac{|3 \times 1 - 4 \times 2 + 5|}{5} = \frac{|3 - 8 + 5|}{5} = 0$

结果：距离为 0, 说明点在超平面上。

5.1.3 支持向量

定义：距离分类超平面最近的那些样本点，即函数间隔最小的样本点，称为支持向量 (Support Vector)。

性质：

- 支持向量位于间隔边界上 (即平行超平面上)
- 支持向量决定了分类超平面的位置
- 只有支持向量对分类超平面有影响，其他样本点可以被移除而不影响结果

理解：SVM 的名称来源于此——支持向量机，即由支持向量决定的分类机器。这也是 SVM 相比其他方法的一个优点：只依赖少数关键样本。

例子：在二分类问题中，假设有 100 个训练样本，但只有 5 个样本位于间隔边界上，这

5 个样本就是支持向量。即使删除其他 95 个样本，SVM 的分类超平面位置也不会改变。

5.1.4 最大间隔分类器

优化问题：寻找具有最大几何间隔的分类超平面。

原问题（Primal Problem）：

$$\max_{\mathbf{w}, b} \quad \gamma \quad (7)$$

$$\text{s.t.} \quad y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq \hat{\gamma}, \quad i = 1, 2, \dots, N \quad (8)$$

$$\|\mathbf{w}\| = 1 \quad (9)$$

由于函数间隔 $\hat{\gamma}$ 可以任意缩放，为了简化问题，固定 $\hat{\gamma} = 1$ ，则优化问题变为：

$$\max_{\mathbf{w}, b} \quad \frac{1}{\|\mathbf{w}\|} \quad (10)$$

$$\text{s.t.} \quad y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, N \quad (11)$$

等价地，最大化 $\frac{1}{\|\mathbf{w}\|}$ 等价于最小化 $\frac{1}{2}\|\mathbf{w}\|^2$ ：

$$\min_{\mathbf{w}, b} \quad \frac{1}{2}\|\mathbf{w}\|^2 \quad (12)$$

$$\text{s.t.} \quad y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, \dots, N \quad (13)$$

理解：

- 这是一个凸二次规划问题，有全局最优解
- 约束条件 $y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1$ 确保所有样本点都在间隔边界之外（或之上）
- 支持向量满足 $y_i(\mathbf{w} \cdot \mathbf{x}_i + b) = 1$ （约束条件的等号成立）
- 目标函数 $\frac{1}{2}\|\mathbf{w}\|^2$ 是凸函数，便于优化

5.2 对偶问题

5.2.1 Lagrange 对偶

Lagrange 函数：对于优化问题 $\min_{\mathbf{w}, b} \frac{1}{2}\|\mathbf{w}\|^2$ s.t. $y_i(\mathbf{w} \cdot \mathbf{x}_i + b) - 1 \geq 0$ ，构造 Lagrange 函数：

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2}\|\mathbf{w}\|^2 - \sum_{i=1}^N \alpha_i [y_i(\mathbf{w} \cdot \mathbf{x}_i + b) - 1]$$

其中 $\alpha_i \geq 0$ 是 Lagrange 乘数。

对偶问题：根据 KKT 条件，原问题的对偶问题是：

$$\max_{\alpha} \quad \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) \quad (14)$$

$$\text{s.t.} \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (15)$$

$$\alpha_i \geq 0, \quad i = 1, 2, \dots, N \quad (16)$$

KKT 条件:

- 对 $\mathbf{w}$ 和 b 的偏导为零: $\mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$, $\sum_{i=1}^N \alpha_i y_i = 0$
- 互补松弛条件: $\alpha_i [y_i(\mathbf{w} \cdot \mathbf{x}_i + b) - 1] = 0$
- 约束条件: $y_i(\mathbf{w} \cdot \mathbf{x}_i + b) - 1 \geq 0$, $\alpha_i \geq 0$

理解:

- 对偶问题将优化变量从 $\mathbf{w}$ 和 b 变为 α , 变量个数从 $d+1$ 变为 N (样本数)
- 从互补松弛条件可知: 如果 $\alpha_i > 0$, 则 $y_i(\mathbf{w} \cdot \mathbf{x}_i + b) = 1$, 即该样本是支持向量
- 如果 $\alpha_i = 0$, 则该样本不是支持向量, 对分类超平面无影响
- 求解对偶问题后, 可以通过 $\mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$ 恢复 $\mathbf{w}$

5.2.2 决策函数

求解对偶问题得到最优解 α^* 后, 可以构造决策函数:

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b^* \right)$$

其中 b^* 可以通过支持向量计算: $b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}_j)$, j 是任一支持向量的下标。

理解: 决策函数只依赖于支持向量 ($\alpha_i^* > 0$ 的样本), 体现了 SVM 的稀疏性。

例题

[考点] 考点：SVM 决策函数的计算

题目：已知 SVM 已训练完成，支持向量和拉格朗日乘数如下：

- 支持向量 $\mathbf{x}_1 = [1, 1]^T$, $y_1 = +1$, $\alpha_1^* = 0.5$
- 支持向量 $\mathbf{x}_2 = [2, 0]^T$, $y_2 = -1$, $\alpha_2^* = 0.3$

偏置 $b^* = -1$ 。使用线性核，计算测试样本 $\mathbf{x} = [1, 0]^T$ 的分类结果。

解答：

步骤 1：计算权重向量

$$\mathbf{w}^* = \sum_{i=1}^2 \alpha_i^* y_i \mathbf{x}_i = 0.5 \times 1 \times [1, 1]^T + 0.3 \times (-1) \times [2, 0]^T = [-0.1, 0.5]^T$$

步骤 2：计算决策函数值

$$f(\mathbf{x}) = \mathbf{w}^* \cdot \mathbf{x} + b^* = [-0.1, 0.5]^T \cdot [1, 0]^T + (-1) = -1.1$$

步骤 3：分类结果

$$\text{sign}(f(\mathbf{x})) = \text{sign}(-1.1) = -1$$

因此测试样本被分类为负类。

例题

[考点] 考点：硬间隔 SVM 的完整计算过程

题目：硬间隔 SVM 的最优超平面计算。给定二维样本集：

样本	特征 (x_1, x_2)	标签 y
A	(0, 0)	+1
B	(1, 1)	-1
C	(2, 0)	-1

1. 写出线性可分 SVM 的优化目标函数（原始形式）。
2. 将该问题化为拉格朗日对偶问题，求出支持向量与对偶变量 α_i 的非零条件。
3. 求出最优分离超平面方程 $\mathbf{w}^T \mathbf{x} + b = 0$ 。
4. 计算分类间隔的宽度。

解答：

1. 优化目标函数（原始形式）：

对于硬间隔 SVM，原始优化问题为：

$$\min_{\mathbf{w}, b} \quad \frac{1}{2} \|\mathbf{w}\|^2$$

$$\text{s.t.} \quad y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1, \quad i = 1, 2, 3$$

其中 $\mathbf{w} = [w_1, w_2]^T$ 是权重向量（法向量），决定分离超平面的方向； b 是偏置项。

2. 拉格朗日对偶问题：

步骤 1：构建拉格朗日函数

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^3 \alpha_i [y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1]$$

其中 $\alpha_i \geq 0$ 为拉格朗日乘数（对偶变量）。

步骤 2：KKT 条件

- 对 $\mathbf{w}$ 的偏导为零： $\frac{\partial L}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^3 \alpha_i y_i \mathbf{x}_i$
- 对 b 的偏导为零： $\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^3 \alpha_i y_i = 0$
- 互补松弛条件： $\alpha_i [y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1] = 0$

步骤 3：对偶问题代入 KKT 条件，得到对偶优化问题：

$$\max_{\boldsymbol{\alpha}} \quad W(\boldsymbol{\alpha}) = \sum_{i=1}^3 \alpha_i - \frac{1}{2} \sum_{i=1}^3 \sum_{j=1}^3 \alpha_i \alpha_j y_i y_j (\mathbf{x}_i^T \mathbf{x}_j)$$

$$\text{s.t.} \quad \sum_{i=1}^3 \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, 2, 3$$

步骤 4：计算内积矩阵计算所有样本对的内积：

$\mathbf{x}_i^T \mathbf{x}_j$	A	B	C
A	0	0	0
B	0	2	2
C	0	2	4

步骤 5：约束条件因为 A 为正类（ $y_A = +1$ ），B 和 C 为负类（ $y_B = y_C = -1$ ），所以约束条件为：

$$\alpha_A - \alpha_B - \alpha_C = 0$$

即： $\alpha_A = \alpha_B + \alpha_C$

例题

解答（续）：

2. 拉格朗日对偶问题（续）：

步骤 6：支持向量与非零 α_i 的条件

- 支持向量：满足 $y_i(\mathbf{w}^T \mathbf{x}_i + b) = 1$ 的样本（位于间隔边界上）
- 非零 α_i ：只有支持向量对应的 $\alpha_i > 0$ ，其他样本的 $\alpha_i = 0$ （KKT 条件中的互补松弛条件）
- 如果 $\alpha_i > 0$ ，则 $y_i(\mathbf{w}^T \mathbf{x}_i + b) = 1$ ，该样本是支持向量
- 如果 $\alpha_i = 0$ ，则该样本不是支持向量，对分类超平面无影响

3. 最优分离超平面方程：

方法：几何分析与约束验证

通过几何分析，最优超平面应该最大化间隔，且位于正负类样本之间。考虑超平面方程： $-x_1 - x_2 + 1 = 0$ （即 $\mathbf{w} = [-1, -1]^T$ ， $b = 1$ ），等价形式为： $x_1 + x_2 = 1$ 。

验证约束条件：

- 样本 A： $y_A(\mathbf{w}^T \mathbf{x}_A + b) = 1 \times (0 + 0 + 1) = 1 \geq 1$ （满足，等号成立）
- 样本 B： $y_B(\mathbf{w}^T \mathbf{x}_B + b) = (-1) \times (-1 - 1 + 1) = (-1) \times (-1) = 1 \geq 1$ （满足，等号成立）
- 样本 C： $y_C(\mathbf{w}^T \mathbf{x}_C + b) = (-1) \times (-2 - 0 + 1) = (-1) \times (-1) = 1 \geq 1$ （满足，等号成立）

所有样本都满足约束条件，且等号成立，说明所有样本都是支持向量。

计算各样本到超平面的距离：

- A 到超平面距离： $\frac{|0+0-1|}{\sqrt{(-1)^2+(-1)^2}} = \frac{1}{\sqrt{2}}$
- B 到超平面距离： $\frac{|1+1-1|}{\sqrt{2}} = \frac{1}{\sqrt{2}}$
- C 到超平面距离： $\frac{|2+0-1|}{\sqrt{2}} = \frac{1}{\sqrt{2}}$

所有样本到超平面的距离都相等，满足间隔最大化。

最终结果：

$$\mathbf{w} = [-1, -1]^T, \quad b = 1$$

最优超平面方程： $-x_1 - x_2 + 1 = 0$ ，或等价形式： $x_1 + x_2 = 1$

4. 分类间隔的宽度：

对于硬间隔 SVM，间隔宽度公式为：

$$\text{间隔宽度} = \frac{2}{\|\mathbf{w}\|}$$

计算：

$$\|\mathbf{w}\| = \sqrt{(-1)^2 + (-1)^2} = \sqrt{2}$$

因此：

$$\text{间隔宽度} = \frac{2}{\sqrt{2}} = \sqrt{2} \approx 1.414$$

5.3 软间隔与正则化

5.3.1 软间隔的基本思想

问题：实际数据往往不是线性可分的，或者存在噪声样本，硬间隔 SVM 无法处理。

软间隔 SVM：允许一些样本违反间隔约束，但引入惩罚项来控制违反程度。

5.3.2 软间隔的优化问题

$$\min_{\mathbf{w}, b, \xi} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i \quad (17)$$

$$\text{s.t.} \quad y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, N \quad (18)$$

$$\xi_i \geq 0, \quad i = 1, 2, \dots, N \quad (19)$$

其中 ξ_i 是松弛变量 (slack variable), $C > 0$ 是惩罚参数。

理解:

- ξ_i 表示第 i 个样本违反间隔约束的程度
- 如果 $\xi_i = 0$, 样本满足硬间隔约束
- 如果 $\xi_i > 0$, 样本违反间隔约束, 位于间隔内或错误一侧
- C 控制对误分类的惩罚程度: C 越大, 惩罚越大, 间隔越“硬”; C 越小, 允许更多违反, 间隔越“软”

5.3.3 对偶问题

软间隔 SVM 的对偶问题:

$$\max_{\alpha} \quad \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) \quad (20)$$

$$\text{s.t.} \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (21)$$

$$0 \leq \alpha_i \leq C, \quad i = 1, 2, \dots, N \quad (22)$$

与硬间隔 SVM 的区别: α_i 的上界从 $+\infty$ 变为 C 。

5.3.4 支持向量的分类

在软间隔 SVM 中, 支持向量分为三类:

- $\alpha_i = 0$: 非支持向量, 在间隔边界之外
- $0 < \alpha_i < C$: 支持向量, 位于间隔边界上 ($\xi_i = 0$)
- $\alpha_i = C$: 支持向量, 违反间隔约束 ($\xi_i > 0$), 可能被误分类

5.3.5 正则化视角

正则化解释: 软间隔 SVM 的目标函数可以理解为:

$$\min_{\mathbf{w}, b} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \max(0, 1 - y_i(\mathbf{w} \cdot \mathbf{x}_i + b))$$

其中第二项是 hinge 损失函数 (合页损失):

$$L_{\text{hinge}}(y, f(\mathbf{x})) = \max(0, 1 - yf(\mathbf{x}))$$

理解:

- 第一项 $\frac{1}{2}\|\mathbf{w}\|^2$ 是 L2 正则化项, 控制模型复杂度
- 第二项是经验风险 (hinge 损失), 控制分类误差
- C 是正则化参数, 平衡模型复杂度和经验风险
- 这是结构风险最小化的典型例子

5.4 核方法

5.4.1 核技巧的基本思想

问题: 对于非线性可分的数据, 可以通过将数据映射到高维空间使其线性可分。

核技巧: 不显式地计算高维映射 $\phi(\mathbf{x})$, 而是通过核函数 $K(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i) \cdot \phi(\mathbf{x}_j)$ 直接计算内积。

优势:

- 避免显式计算高维映射, 计算复杂度低
- 可以在无限维空间中工作
- 只需定义核函数, 不需要知道具体的映射函数

5.4.2 常用核函数

多项式核:

$$K(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i \cdot \mathbf{x}_j + 1)^d$$

其中 d 是多项式的次数。

高斯核 (RBF 核):

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$$

其中 $\gamma > 0$ 是参数, 控制高斯函数的宽度。

Sigmoid 核:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i \cdot \mathbf{x}_j + \theta)$$

理解:

- 多项式核: 适合多项式关系的数据
- 高斯核: 最常用的核函数, 可以将数据映射到无限维空间, γ 越大, 决策边界越复杂 (可能过拟合)
- 不同核函数适用于不同的数据分布

5.4.3 非线性 SVM 的决策函数

使用核函数后, 决策函数变为:

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i K(\mathbf{x}_i, \mathbf{x}) + b^* \right)$$

对偶问题的目标函数变为:

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j)$$

理解：只需将原来的内积 $\mathbf{x}_i \cdot \mathbf{x}_j$ 替换为核函数 $K(\mathbf{x}_i, \mathbf{x}_j)$ 即可，其他形式不变。

例题

[考点] 考点：核函数的计算

题目：给定两个样本点 $\mathbf{x}_1 = [1, 2]^T$ 和 $\mathbf{x}_2 = [3, 1]^T$ ，计算以下核函数的值：

1. 线性核： $K(\mathbf{x}_1, \mathbf{x}_2) = \mathbf{x}_1 \cdot \mathbf{x}_2$
2. 多项式核 ($d = 2$)： $K(\mathbf{x}_1, \mathbf{x}_2) = (\mathbf{x}_1 \cdot \mathbf{x}_2 + 1)^2$
3. 高斯核 ($\gamma = 0.5$)： $K(\mathbf{x}_1, \mathbf{x}_2) = \exp(-\gamma \|\mathbf{x}_1 - \mathbf{x}_2\|^2)$

解答：

步骤 1：计算内积和距离

- $\mathbf{x}_1 \cdot \mathbf{x}_2 = 1 \times 3 + 2 \times 1 = 5$
- $\|\mathbf{x}_1 - \mathbf{x}_2\|^2 = \|[-2, 1]^T\|^2 = 4 + 1 = 5$

步骤 2：计算各核函数

- 线性核： $K = 5$
- 多项式核： $K = (5 + 1)^2 = 36$
- 高斯核： $K = \exp(-0.5 \times 5) = e^{-2.5} \approx 0.082$

核函数必须满足的条件：

- Mercer 条件：对于任意有限个样本，由 $K(\mathbf{x}_i, \mathbf{x}_j)$ 构成的矩阵必须是半正定的
- 对称性： $K(\mathbf{x}_i, \mathbf{x}_j) = K(\mathbf{x}_j, \mathbf{x}_i)$

参数 C 的影响：

- C 过大：对误分类惩罚大，间隔变窄，可能过拟合
- C 过小：对误分类惩罚小，间隔变宽，可能欠拟合
- 最优 C ：通过交叉验证选择

例题

题目：核函数与软间隔分析。已知 SVM 的对偶形式为：

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j)$$

约束： $\sum_i \alpha_i y_i = 0$, $0 \leq \alpha_i \leq C$ 。

1. 若使用高斯核 $K(\mathbf{x}_i, \mathbf{x}_j) = e^{-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2}$ ，说明此核在特征空间的非线性映射性质。
2. 分析参数 C 过大或过小时对应“欠惩罚”和“过惩罚”的几何后果。
3. 给出硬间隔与软间隔 SVM 的几何差别示意（可用文字或符号说明支持向量位置变化）。
4. 说明核函数必须满足的两个条件。

解答：

1. 高斯核的非线性映射性质：

- 将数据映射到无限维特征空间，使得原本线性不可分的数据变得线性可分
- 当 $\mathbf{x}_i$ 和 $\mathbf{x}_j$ 距离较远时， $K(\mathbf{x}_i, \mathbf{x}_j) \approx 0$ ；距离较近时， $K(\mathbf{x}_i, \mathbf{x}_j) \approx 1$
- γ 越大，高斯函数越窄，决策边界越复杂（可能过拟合）

2. 参数 C 的影响：

- C 过大（过惩罚）：对误分类惩罚大，间隔变窄，决策边界复杂，可能过拟合
- C 过小（欠惩罚）：对误分类惩罚小，间隔变宽，决策边界简单，可能欠拟合

3. 硬间隔与软间隔的几何差别：

- 硬间隔：所有样本都在间隔边界之外，支持向量位于间隔边界上
- 软间隔：允许一些样本违反间隔约束，支持向量分为三类：非支持向量、边界上的支持向量、违反约束的支持向量

4. 核函数必须满足的条件：

- Mercer 条件：由 $K(\mathbf{x}_i, \mathbf{x}_j)$ 构成的矩阵必须是半正定的
- 对称性： $K(\mathbf{x}_i, \mathbf{x}_j) = K(\mathbf{x}_j, \mathbf{x}_i)$

5.5 模型小结

模型：分类超平面 $f(\mathbf{x}) = \text{sign}(\mathbf{w} \cdot \mathbf{x} + b)$ ，通过支持向量确定。

策略（准则）：

- 硬间隔：最大化几何间隔
- 软间隔：最小化 $\frac{1}{2} \|\mathbf{w}\|^2 + C \sum \xi_i$ （结构风险最小化）

算法：

- 原问题：凸二次规划问题
- 对偶问题：通过 Lagrange 对偶求解
- 核方法：使用核函数处理非线性问题

SVM 的特点：

- 优点：理论基础扎实，泛化能力强，只依赖支持向量（稀疏性），可以使用核函数处理非线性问题
- 缺点：对大规模数据计算复杂，对参数 C 和核函数参数敏感，不直接提供概率输出

6 第 6 讲决策树

[考点] 考点：P36 页，贷款申请样本数据，决策树构建，二维样本降一维

6.1 基本流程

6.1.1 决策树的基本模型

基本思想：基于规则的思维模式，人类在进行决策时会基于一些既有规则，通过 if-then 式推导实现最终决策。决策树学习如何从训练数据中提取潜在判断规则。

决策树的组成：

- **根结点 (root)：**最上面的结点
- **内部结点 (internal node)：**也叫决策结点，代表一个问题或决策，对应一个属性测试
- **叶结点 (leaf node)：**代表一种可能的分类结果
- **分支 (branch)：**连接结点的边，对应属性取值

决策树的生成过程：基于自顶向下的贪心算法 (greedy algorithm) 构建，常用递归实现。在每个结点选择当前状态下分类效果最好的属性进行分类，然后继续这个过程，直到能够准确分类训练样本，或者所有属性都已被用过。

贪心算法：每一步都采取在当前状态下最优的选择，希望导致全局最优。贪心法解决问题的效率很高，它从局部最优解出发，每一步选择都是当前看似最佳的选择。

6.1.2 决策树生成算法

给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$ 和属性集 $A = \{a_1, a_2, \dots, a_d\}$ 。

决策树生成函数 $\text{TreeGenerate}(D, A)$ ：

递归终止条件：

1. D 中样本全属于同一类别 C ：将结点标记为 C 类叶结点
2. $A = \emptyset$ 或 D 中样本在 A 上取值相同：将结点标记为叶结点，类别标记为 D 中样本数最多的类
3. 分支对应的样本子集 D_v 为空：将分支结点标记为叶结点，类别标记为 D 中样本最多的类

递归过程：

1. 从 A 中选择最优划分属性 a^*
2. 对 a^* 的每一个值 a_v^* ：
 - 为结点生成一个分支
 - 令 D_v 表示 D 中在 a^* 上取值为 a_v^* 的样本子集
 - 如果 D_v 为空，标记为叶结点；否则，以 $\text{TreeGenerate}(D_v, A \setminus \{a^*\})$ 为分支结点

理解：决策树通过递归地选择最优属性进行划分，将特征空间划分为若干区域，每个区域对应一个叶结点（类别）。

6.2 划分选择

6.2.1 信息熵

信息熵 (Entropy)：度量样本集合纯度的一种指标。假设当前样本集合 D 中第 k 类样本所占的比例为 p_k ($k = 1, 2, \dots, |\mathcal{Y}|$)，则 D 的信息熵定义为：

$$\text{Ent}(D) = - \sum_{k=1}^{|\mathcal{Y}|} p_k \log_2 p_k$$

理解：

- 信息熵越小，样本集合的纯度越高
- $\text{Ent}(D)$ 的最小值为 0，当 D 中所有样本属于同一类别时取到

- $\text{Ent}(D)$ 的最大值为 $\log_2 |\mathcal{Y}|$ ，当 D 中各类别样本比例相等时取到
- 信息熵反映了样本集合的不确定性

6.2.2 信息增益 (ID3 算法)

信息增益 (Information Gain): 使用属性 a 对样本集 D 进行划分所获得的信息增益:

$$\text{Gain}(D, a) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$$

其中 V 是属性 a 的可能取值数， D^v 是 D 中在属性 a 上取值为 a^v 的样本子集。

最优划分属性: 选择信息增益最大的属性作为划分属性:

$$a^* = \underset{a \in A}{\operatorname{argmax}} \text{Gain}(D, a)$$

理解:

- 信息增益表示使用属性 a 进行划分后，样本集合纯度的提升
- 信息增益越大，说明使用该属性划分后，样本集合的纯度提升越大
- ID3 算法使用信息增益作为划分准则

例子: 在贷款申请问题中，计算“是否有房子”属性的信息增益。如果划分后，有房子的样本全部批准贷款，没房子的样本需要进一步判断，则信息增益较大，该属性是好的划分属性。

信息增益的缺点: 信息增益偏向于选择取值较多的属性（因为取值越多，划分越细，每个子集的纯度可能更高）。例如，如果使用“身份证号”作为属性，每个样本的取值都不同，信息增益会很大，但这样的划分没有意义。

6.2.3 信息增益率 (C4.5 算法)

属性 a 的固有值 (Intrinsic Value):

$$\text{IV}(a) = - \sum_{v=1}^V \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$$

信息增益率 (Information Gain Ratio):

$$\text{Gain_ratio}(D, a) = \frac{\text{Gain}(D, a)}{\text{IV}(a)}$$

最优划分属性:

$$a^* = \underset{a \in A}{\operatorname{argmax}} \text{Gain_ratio}(D, a)$$

理解:

- 信息增益率通过除以属性的固有值，惩罚取值较多的属性
- C4.5 算法使用信息增益率作为划分准则

- 信息增益率可能偏向于选择取值较少的属性，因此 C4.5 算法通常先选择信息增益高于平均值的属性，再从这些属性中选择信息增益率最大的

6.2.4 基尼指数 (CART 算法)

基尼值 (Gini Value): 假设当前样本集合 D 中第 k 类样本所占的比例为 p_k ，则 D 的基尼值定义为：

$$\text{Gini}(D) = \sum_{k=1}^{|\mathcal{Y}|} \sum_{k' \neq k} p_k p_{k'} = 1 - \sum_{k=1}^{|\mathcal{Y}|} p_k^2$$

理解：

- 基尼值反映了从 D 中随机抽取两个样本，其类别标记不一致的概率
- 基尼值越小，样本集合的纯度越高
- $\text{Gini}(D)$ 的最小值为 0，当 D 中所有样本属于同一类别时取到

基尼指数 (Gini Index): 使用属性 a 对样本集 D 进行划分的基尼指数：

$$\text{Gini_index}(D, a) = \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Gini}(D^v)$$

最优划分属性：

$$a^* = \underset{a \in A}{\operatorname{argmin}} \text{Gini_index}(D, a)$$

理解：

- CART 算法使用基尼指数作为划分准则
- 基尼指数的计算比信息熵更简单（不需要对数运算）
- 基尼指数和信息熵都可以度量样本集合的纯度，在实际应用中效果相近

6.2.5 三种划分准则的对比

- **ID3:** 信息增益，偏向取值较多的属性
- **C4.5:** 信息增益率，惩罚取值较多的属性，但可能偏向取值较少的属性
- **CART:** 基尼指数，计算简单，效果与信息熵相近

6.3 剪枝处理

6.3.1 剪枝的基本思想

问题: 决策树容易过拟合，即对训练数据拟合得很好，但对未知数据泛化能力差。

剪枝 (Pruning): 主动去掉一些分支来降低过拟合的风险。

剪枝的类型:

- **预剪枝 (Pre-pruning):** 在决策树生成过程中，对每个结点在划分前进行估计，若当前结点的划分不能带来决策树泛化性能提升，则停止划分
- **后剪枝 (Post-pruning):** 先从训练集生成一棵完整的决策树，然后自底向上地对非叶结点进行考察，若将该结点对应的子树替换为叶结点能带来决策树泛化性能提升，则将该子树替换为叶结点

理解：

- 预剪枝可以降低过拟合风险，但可能欠拟合（提前停止划分）
- 后剪枝通常比预剪枝保留更多的分支，泛化性能更好，但训练时间更长
- 剪枝通过损失函数加上正则化项来控制模型复杂度
- 剪枝的核心是**性能不变或提升时简化模型**：如果某个节点的划分不能提升分类正确率，这个划分就是冗余的，可以剪掉

剪枝原则总结：

- 如果剪枝后正确率**不变或提升**，则可以剪枝
- 如果剪枝后正确率**下降**，则**不能剪枝**
- 后剪枝从底向上逐层判断，剪掉那些对性能没有贡献的子树
- 剪枝的目的是在保持性能的前提下简化模型，提高泛化能力

6.4 连续与缺失值

6.4.1 连续值处理

问题：决策树通常处理离散属性，但实际数据中常包含连续属性。

连续属性离散化：采用二分法（bi-partition）对连续属性进行处理。

方法：

1. 给定样本集 D 和连续属性 a ，假定 a 在 D 上出现了 n 个不同的取值，将这些值从小到大排序： $\{a^1, a^2, \dots, a^n\}$
2. 候选划分点集合： $T_a = \left\{ \frac{a^i + a^{i+1}}{2} \mid 1 \leq i \leq n-1 \right\}$
3. 对每个候选划分点 $t \in T_a$ ，计算信息增益（或基尼指数）
4. 选择使信息增益最大的划分点 t 作为属性 a 的最优划分点

理解：连续属性 a 被转换为一个二元属性，划分点为 t 。划分后， $a \leq t$ 的样本归入一个分支， $a > t$ 的样本归入另一个分支。

6.4.2 缺失值处理

问题：实际数据中常有缺失值，需要处理属性值缺失的样本。

基本思路：

- 如何在属性值缺失的情况下进行划分属性选择？
- 给定划分属性，若样本在该属性上的值缺失，如何对样本进行划分？

处理策略：

- 在划分属性选择时，只使用在该属性上没有缺失值的样本
- 在样本划分时，将缺失值的样本同时划入所有子结点，并赋予不同的权重（权重等于各子结点的样本比例）

理解：这样处理可以充分利用所有样本，不会因为缺失值而丢弃样本。

6.5 决策树用于回归

6.5.1 回归树的基本思想

问题：决策树不仅可以用于分类，还可以用于回归。

回归树：将特征空间划分为若干区域 $R_1, R_2, \dots, R_M$ ，每个区域对应一个输出值 c_m 。

回归树的预测：对于输入 $\mathbf{x}$ ，如果 $\mathbf{x} \in R_m$ ，则预测输出为 c_m 。

6.5.2 CART 回归树的划分准则

最优划分属性与划分点：对于属性 a 和划分点 s ，定义两个区域：

$$R_1(a, s) = \{\mathbf{x} \mid a(\mathbf{x}) \leq s\}, \quad R_2(a, s) = \{\mathbf{x} \mid a(\mathbf{x}) > s\}$$

最优输出值：每个区域的输出值为该区域内样本的平均值：

$$\hat{c}_1 = \frac{1}{|R_1|} \sum_{x_i \in R_1} y_i, \quad \hat{c}_2 = \frac{1}{|R_2|} \sum_{x_i \in R_2} y_i$$

代价函数（最小平方误差）：

$$L(a, s) = \sum_{x_i \in R_1(a, s)} (y_i - \hat{c}_1)^2 + \sum_{x_i \in R_2(a, s)} (y_i - \hat{c}_2)^2$$

最优划分：

$$a^*, s^* = \operatorname{argmin}_{a, s} L(a, s)$$

理解：

- 回归树通过最小化平方误差来选择最优划分
- 对每个属性，需要遍历所有可能的划分点
- 对于连续属性，划分点通常是相邻两个取值的中间值
- 对于离散属性，划分点对应不同的取值组合

6.5.3 回归树的构建过程

步骤：

1. 对每个属性 a ，遍历所有可能的划分点 s
2. 计算划分后的代价函数 $L(a, s)$
3. 选择使 $L(a, s)$ 最小的属性 a^* 和划分点 s^*
4. 递归地对两个子区域 $R_1(a^*, s^*)$ 和 $R_2(a^*, s^*)$ 重复上述过程
5. 直到满足停止条件（如区域内的样本数小于阈值，或区域内的方差小于阈值）

理解：回归树的构建过程与分类树类似，都是递归地选择最优划分，区别在于划分准则（分类树使用信息增益/基尼指数，回归树使用平方误差）。

6.6 决策树构建例题（考点：贷款申请问题）

问题描述：根据贷款申请人的特征判断是否批准贷款。给定训练数据集如下：

编号	年龄	是否有房子	是否有工作	是否批准贷款
1	青年	否	否	否
2	青年	否	否	否
3	青年	是	否	是
4	青年	是	是	是
5	青年	否	否	否
6	中年	否	否	否
7	中年	否	是	是
8	中年	是	是	是
9	中年	是	否	是
10	中年	否	否	否
11	老年	否	否	否
12	老年	否	是	是
13	老年	是	是	是
14	老年	是	否	是
15	老年	否	否	否

数据统计：共 15 个样本，其中批准贷款（是）9 个，不批准贷款（否）6 个。

核心概念回顾：

- 信息熵： $\text{Ent}(D) = -\sum_{k=1}^{|Y|} p_k \log_2 p_k$ ，度量样本集合的纯度（不确定性），熵越小越纯净
- 信息增益： $\text{Gain}(D, a) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$ ，表示使用属性 a 划分后纯度的提升
- 最优属性选择： $a^* = \underset{a \in A}{\operatorname{argmax}} \text{Gain}(D, a)$

步骤 1：计算根结点的信息熵

根结点包含所有 15 个样本。统计各类别：

- 批准（是）：9 个， $p_{\text{是}} = \frac{9}{15} = 0.6$
- 不批准（否）：6 个， $p_{\text{否}} = \frac{6}{15} = 0.4$

计算信息熵：

$$\text{Ent}(D) = -\left(\frac{9}{15} \log_2 \frac{9}{15} + \frac{6}{15} \log_2 \frac{6}{15}\right) = 0.971$$

步骤 2：计算各属性的信息增益

2.1 计算“是否有房子”属性的信息增益

属性“是否有房子”有两个取值：是、否。

统计每个取值下的样本分布：

- 有房子（是）：6 个样本（编号 3,4,8,9,13,14），全部批准贷款
 - 批准（是）：6 个， $p_{\text{是}} = 1$ ；不批准（否）：0 个， $p_{\text{否}} = 0$
 - 信息熵： $\text{Ent}(D^{\text{是}}) = -(1 \times \log_2 1 + 0) = 0$ （定义 $0 \times \log_2 0 = 0$ ）
- 没房子（否）：9 个样本（编号 1,2,5,6,7,10,11,12,15）
 - 批准（是）：3 个（编号 7,12）， $p_{\text{是}} = \frac{3}{9} = \frac{1}{3}$
 - 不批准（否）：6 个， $p_{\text{否}} = \frac{6}{9} = \frac{2}{3}$
 - 信息熵： $\text{Ent}(D^{\text{否}}) = -\left(\frac{1}{3} \log_2 \frac{1}{3} + \frac{2}{3} \log_2 \frac{2}{3}\right) = 0.918$

计算信息增益：

$$\text{Gain}(D, \text{是否有房子}) = 0.971 - \left[\frac{6}{15} \times 0 + \frac{9}{15} \times 0.918\right] = 0.420$$

2.2 计算“是否有工作”属性的信息增益

属性“是否有工作”有两个取值：是、否。

统计每个取值下的样本分布：

- 有工作（是）：5 个样本（编号 4,7,8,12,13），全部批准贷款
 - 信息熵： $\text{Ent}(D^{\text{是}}) = 0$
- 没工作（否）：10 个样本（编号 1,2,3,5,6,9,10,11,14,15）
 - 批准（是）：4 个（编号 3,9,14）， $p_{\text{是}} = 0.4$
 - 不批准（否）：6 个， $p_{\text{否}} = 0.6$
 - 信息熵： $\text{Ent}(D^{\text{否}}) \approx 0.971$

计算信息增益：

$$\text{Gain}(D, \text{是否有工作}) = 0.971 - \left[\frac{5}{15} \times 0 + \frac{10}{15} \times 0.971 \right] = 0.324$$

2.3 计算“年龄”属性的信息增益

属性“年龄”有三个取值：青年、中年、老年。

简要计算：

- 青年：5 个样本，2 个批准，3 个不批准， $\text{Ent}(D^{\text{青年}}) \approx 0.971$
- 中年：5 个样本，3 个批准，2 个不批准， $\text{Ent}(D^{\text{中年}}) \approx 0.971$
- 老年：5 个样本，4 个批准，1 个不批准， $\text{Ent}(D^{\text{老年}}) \approx 0.722$

计算信息增益：

$$\text{Gain}(D, \text{年龄}) = 0.971 - \left[\frac{5}{15} \times 0.971 + \frac{5}{15} \times 0.971 + \frac{5}{15} \times 0.722 \right] = 0.082$$

步骤 3：比较信息增益，选择最优属性

三个属性的信息增益对比：

属性	信息增益
是否有房子	0.420
是否有工作	0.324
年龄	0.082

结论：“是否有房子”的信息增益最大（0.420），因此选择“是否有房子”作为根结点的划分属性。

步骤 4：递归构建决策树

选择“是否有房子”作为根结点后：

- 左分支（有房子）：6 个样本全部批准贷款，信息熵为 0，这是叶结点，类别为“是”
- 右分支（没房子）：9 个样本中，3 个批准，6 个不批准，需要继续划分

对右分支（没房子，9 个样本）继续构建：

- 当前子集信息熵： $\text{Ent}(D^{\text{否}}) = 0.918$
- 计算剩余属性（年龄、是否有工作）的信息增益
- 经过计算，“是否有工作”的信息增益更大（约 0.458）
- 选择“是否有工作”作为划分属性
- 有工作 → 批准贷款（叶结点），没工作 → 不批准贷款（叶结点）

最终决策树结构（文字描述）：

- 根节点：[是否有房子？]

- 左分支 (是): $\rightarrow$ [批准贷款] (叶节点)
- 右分支 (否): $\rightarrow$ [是否有工作?]
- * 左分支 (是): $\rightarrow$ [批准贷款] (叶节点)
- * 右分支 (否): $\rightarrow$ [不批准贷款] (叶节点)

决策规则:

1. 如果有房子 $\rightarrow$ 批准贷款
2. 如果没房子但有工作 $\rightarrow$ 批准贷款
3. 如果没房子且没工作 $\rightarrow$ 不批准贷款

理解要点:

- 决策树的构建是递归的贪心过程, 每一步选择当前最优属性
- 信息增益反映了使用某属性划分后, 样本集合纯度的提升程度
- 信息熵为 0 的节点是叶节点 (所有样本属于同一类别), 不需要继续划分
- 当所有属性都用完或满足其他终止条件时, 递归结束

补充: 使用 C4.5 算法 (信息增益率) 计算贷款问题

步骤 1: 计算固有值 (Intrinsic Value)

固有值公式: $IV(a) = - \sum_{v=1}^V \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$

- "是否有房子" 的固有值: $IV(\text{是否有房子}) = - \left[\frac{6}{15} \log_2 \frac{6}{15} + \frac{9}{15} \log_2 \frac{9}{15} \right] = 0.971$
- "是否有工作" 的固有值: $IV(\text{是否有工作}) = - \left[\frac{5}{15} \log_2 \frac{5}{15} + \frac{10}{15} \log_2 \frac{10}{15} \right] = 0.918$
- "年龄" 的固有值: $IV(\text{年龄}) = - \left[3 \times \frac{5}{15} \log_2 \frac{5}{15} \right] = 1.585$

步骤 2: 计算信息增益率

信息增益率公式: $\text{Gain_ratio}(D, a) = \frac{\text{Gain}(D, a)}{IV(a)}$

- "是否有房子": $\text{Gain_ratio} = \frac{0.420}{0.971} = 0.433$
- "是否有工作": $\text{Gain_ratio} = \frac{0.324}{0.918} = 0.353$
- "年龄": $\text{Gain_ratio} = \frac{0.082}{1.585} = 0.052$

结论: C4.5 算法选择信息增益率最大的"是否有房子" (0.433) 作为根节点, 与 ID3 结果相同。

理解: 固有值反映属性取值的复杂程度, 信息增益率通过除以固有值来惩罚取值较多的属性, 避免选择无意义的属性 (如"身份证号")。

补充: 使用 CART 算法 (基尼指数) 计算贷款问题

步骤 1: 计算根节点的基尼值

基尼值公式: $\text{Gini}(D) = 1 - \sum_{k=1}^{|D|} p_k^2$

$$\text{Gini}(D) = 1 - \left[\left(\frac{9}{15} \right)^2 + \left(\frac{6}{15} \right)^2 \right] = 1 - 0.52 = 0.48$$

步骤 2: 计算各属性的基尼指数

基尼指数公式: $\text{Gini_index}(D, a) = \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Gini}(D^v)$

- "是否有房子":
 - 有房子: $\text{Gini}(D^{\text{是}}) = 1 - (1^2 + 0^2) = 0$
 - 没房子: $\text{Gini}(D^{\text{否}}) = 1 - \left[\left(\frac{1}{3} \right)^2 + \left(\frac{2}{3} \right)^2 \right] = 0.444$
 - 基尼指数: $\text{Gini_index} = \frac{6}{15} \times 0 + \frac{9}{15} \times 0.444 = 0.267$
- "是否有工作":
 - 有工作: $\text{Gini}(D^{\text{是}}) = 0$
 - 没工作: $\text{Gini}(D^{\text{否}}) = 1 - (0.4^2 + 0.6^2) = 0.48$

- 基尼指数: $\text{Gini_index} = \frac{5}{15} \times 0 + \frac{10}{15} \times 0.48 = 0.32$
- ”年龄” (CART 是二叉树, 需要二元划分, 选择最优划分):
 - 划分 1: ”是否青年”
 - * 是青年: 5 个样本 (2 批准, 3 不批准), $\text{Gini}(D^{\text{是青年}}) = 1 - (0.4^2 + 0.6^2) = 0.48$
 - * 非青年: 10 个样本 (7 批准, 3 不批准), $\text{Gini}(D^{\text{非青年}}) = 1 - (0.7^2 + 0.3^2) = 0.42$
 - * 基尼指数: $\text{Gini_index}(D, \text{是否青年}) = \frac{5}{15} \times 0.48 + \frac{10}{15} \times 0.42 = 0.44$
 - 划分 2: ”是否中年”
 - * 是中年: 5 个样本 (3 批准, 2 不批准), $\text{Gini}(D^{\text{是中年}}) = 0.48$
 - * 非中年: 10 个样本 (6 批准, 4 不批准), $\text{Gini}(D^{\text{非中年}}) = 0.48$
 - * 基尼指数: $\text{Gini_index}(D, \text{是否中年}) = \frac{5}{15} \times 0.48 + \frac{10}{15} \times 0.48 = 0.48$
 - 划分 3: ”是否老年”
 - * 是老年: 5 个样本 (4 批准, 1 不批准), $\text{Gini}(D^{\text{是老年}}) = 1 - (0.8^2 + 0.2^2) = 0.32$
 - * 非老年: 10 个样本 (5 批准, 5 不批准), $\text{Gini}(D^{\text{非老年}}) = 1 - (0.5^2 + 0.5^2) = 0.5$
 - * 基尼指数: $\text{Gini_index}(D, \text{是否老年}) = \frac{5}{15} \times 0.32 + \frac{10}{15} \times 0.5 = 0.44$
 - 选择最小的基尼指数: $\text{Gini_index}(D, \text{年龄}) = \min(0.44, 0.48, 0.44) = 0.44$

结论: CART 算法选择基尼指数最小的”是否有房子” (0.267) 作为根节点, 与 ID3 和 C4.5 结果相同。

理解: 基尼值反映样本集合的纯度, 基尼指数是各子集基尼值的加权平均, 选择基尼指数最小的属性。CART 构建二叉树, 对多取值属性需要转换为二元划分。

例题

题目 (P36): 决策树构建与剪枝分析。给定以下训练数据集 (二维离散特征):

样本	天气	湿度	是否打球 (标签)
A	晴	高	否
B	晴	正常	是
C	阴	高	是
D	阴	正常	是
E	雨	高	否
F	雨	正常	是

1. 计算在主节点上按”天气”划分时的信息增益, 并判断是否是最优划分特征。
2. 画出对应的决策树结构 (可用文字层次描述代替图形)。
3. 若使用”基尼指数”作为划分标准, 比较与信息增益的划分结果是否一致。

解答:

1. 计算信息增益:

- 根节点信息熵: $\text{Ent}(D) = -\frac{4}{6} \log_2 \frac{4}{6} - \frac{2}{6} \log_2 \frac{2}{6} \approx 0.918$
- 按”天气”划分: 晴 (2 个样本, 1 是 1 否), 阴 (2 个样本, 全部是), 雨 (2 个样本, 1 是 1 否)
- 信息增益: $\text{Gain}(D, \text{天气}) = 0.918 - [\frac{2}{6} \times 1 + \frac{2}{6} \times 0 + \frac{2}{6} \times 1] = 0.251$
- 按”湿度”划分: 高 (3 个样本, 1 是 2 否), 正常 (3 个样本, 全部是)
- 信息增益: $\text{Gain}(D, \text{湿度}) = 0.918 - [\frac{3}{6} \times 0.918 + \frac{3}{6} \times 0] = 0.459$
- 因为 $\text{Gain}(D, \text{湿度}) > \text{Gain}(D, \text{天气})$, 所以”湿度”是最优划分特征

2. 决策树结构: 根节点选择”湿度”, 高分支下选择”天气”, 正常分支直接为”是”

3. 基尼指数比较:

- 根节点基尼值: $\text{Gini}(D) = 1 - (\frac{4}{6})^2 - (\frac{2}{6})^2 = 1 - \frac{16}{36} - \frac{4}{36} = \frac{16}{36} = 0.444$
- 按”天气”划分:
 - 晴: $\text{Gini}(D_{\text{晴}}) = 1 - (\frac{1}{2})^2 - (\frac{1}{2})^2 = 0.5$
 - 阴: $\text{Gini}(D_{\text{阴}}) = 1 - 1^2 - 0^2 = 0$
 - 雨: $\text{Gini}(D_{\text{雨}}) = 0.5$
 - 基尼指数: $\text{Gini_index}(D, \text{天气}) = \frac{2}{6} \times 0.5 + \frac{2}{6} \times 0 + \frac{2}{6} \times 0.5 = \frac{1}{3} = 0.333$
- 按”湿度”划分:
 - 高: $\text{Gini}(D_{\text{高}}) = 1 - (\frac{1}{3})^2 - (\frac{2}{3})^2 = 1 - \frac{1}{9} - \frac{4}{9} = \frac{4}{9} = 0.444$
 - 正常: $\text{Gini}(D_{\text{正常}}) = 0$
 - 基尼指数: $\text{Gini_index}(D, \text{湿度}) = \frac{3}{6} \times 0.444 + \frac{3}{6} \times 0 = 0.222$
- 比较: $\text{Gini_index}(D, \text{天气}) = 0.333$, $\text{Gini_index}(D, \text{湿度}) = 0.222$
- 因为基尼指数越小越好, 所以”湿度”仍然是最优划分特征, 与信息增益的结果一致

6.7 模型小结

模型: 核心问题是最优属性划分, 通过递归地选择最优属性, 将特征空间划分为若干区域。

策略 (准则):

- 分类: 使用样本不纯度度量 (信息增益、信息增益率、基尼指数)
- 回归: 使用最小平方误差

算法: 贪心算法, 深度优先生成决策树。

决策树的特点:

- 优点: 易于理解和解释, 对缺失值不敏感, 模型训练和执行效率高, 可以处理数值型和

标称型数据

- 缺点：容易过拟合，采用贪心策略可能得不到全局最优树，对噪声敏感，模型复杂度（VC 维）高

决策树的概率视角：

- 决策树学习是由训练数据集直接估计后验概率
- 决策树的一条路径对应于划分中的一个单元
- 各叶结点上的条件概率往往偏向某一个类，决策分类时将该结点的实例分到条件概率大的那一类中
- 建议：把决策树分类与朴素贝叶斯分类联系起来学习

7 第 7 讲集成学习

7.1 个体与集成

7.1.1 集成学习的基本概念

定义：集成学习（Ensemble Learning）通常是指利用多个同种类的学习器来对一个问题进行学习，其核心是提高学习器的泛化能力。在处理分类问题时也被称为多分类器系统（multi-classifier system）。

基本思想：一个集成由多个个体学习器构成，个体学习器分别在训练数据上训练获得，它们可以是决策树、神经网络或其他算法。

基学习器：

- **同质集成（Homogeneous Ensemble）：**集成中只包含同种类型的个体学习器，此时个体学习器也被称为“基学习器（base learner）”，相应的学习算法称为“基学习方法”
- **异质集成（Heterogeneous Ensemble）：**个体学习器由不同的学习方法生成，不存在“基学习方法”，个体学习器一般不称为“基学习器”

7.1.2 集成学习的组合方式

多专家组合（Multiexpert Combination）：让基学习器并行工作。

- **全局方法（Global/Fusion）：**给定一个样本输入，所有的基学习器都产生一个输出，并且所有这些输出都要使用。通过平均、投票或堆叠来产生最终结果。例如：Bagging、Stacking
- **局部方法（Local/Selection）：**如混合专家（mixture of expert），有一个门控模型考察输入，并选择一个或几个学习器来产生输出

多级组合（Multistage Combination）：让基学习器按复杂度递增排序，构成一个串行的组合，其中后一个基学习器在前一个基学习器预测不够准确的样本上进行训练，或者对前一个学习器的预测残差、梯度进行调整。例如：Boosting

7.1.3 投票分类器

硬投票分类器（Hard Voting Classifier）：聚合每个分类器的预测，然后将得票最多的结果作为预测类别。

为什么能提高准确率：假设创建了一个包含 1000 个分类器的集成，每个分类器都只有 51% 的几率是正确的（几乎没比随机猜测强多少）。如果以简单多数投票的类别作为预测结果，可以期待的准确率高达 75%：

$$P(\text{正确}) = \sum_{k=501}^{1000} C_{1000}^k p^k (1-p)^{1000-k} \approx 0.75$$

其中 $p = 0.51$ 是单个分类器的准确率。

前提条件:

- 所有的分类器都是完全独立的，彼此的错误毫不相关
- 显然这是不可能的，因为它们都是在相同的数据上训练的
- 它们很可能会犯相同的错误，所以集成的准确率会有所降低
- 因此，集成学习的关键是增加个体学习器的多样性（diversity）

7.1.4 集成学习可能带来的好处

1. 统计分析方面: 虽然在同一训练集上可以学习训练性能最好的分类器，但是这些分类器在未来数据中的性能则是很难保证的。为了降低这种单一选择的风险，结合多学习器就是一种合理的选择。

2. 算法求解方面: 很多学习算法使用梯度下降法，往往会陷入到局部极小点，其泛化性能可能很低。通过分类器集成，可以降低陷入糟糕的局部极小点的风险。

3. 模型表达方面: 某些学习任务的真实的最佳分类器可能不在当前学习算法所考虑的模型空间中，此时使用单学习器肯定是无效。通过集成多个学习器，比如分类器的线性组合，就有可能接近真实的分类器。

7.2 Boosting

7.2.1 Boosting 的基本思想

基本思想: Boosting 是一种多级组合方法，让基学习器按复杂度递增排序，构成一个串行的组合。每个后继学习器都对其前驱学习器做出一些改进，因此个体学习器之间存在强依赖关系，必须串行生成。

工作流程:

1. 先从初始训练集训练出一个基学习器
2. 根据基学习器的表现对训练样本分布进行调整，使得先前基学习器做错的训练样本在后续受到更多关注
3. 基于调整后的样本分布来训练下一个基学习器
4. 重复进行，直到基学习器数目达到事先指定的值 T
5. 最终将这 T 个基学习器进行加权结合

理解: Boosting 通过关注错误样本，逐步改进模型性能。每个新的基学习器都试图修正前面学习器的错误。

7.2.2 AdaBoost 算法

AdaBoost (Adaptive Boosting): 最著名的 Boosting 算法，通过改变训练样本的权重来训练不同的基学习器。

算法流程:

1. 初始化训练样本的权重分布: $D_1(i) = \frac{1}{m}, i = 1, 2, \dots, m$
2. 对 $t = 1, 2, \dots, T$:
 - 使用权重分布 D_t 训练基学习器 h_t
 - 计算 h_t 在训练集上的错误率: $\epsilon_t = \sum_{i=1}^m D_t(i) \mathbb{I}(h_t(\mathbf{x}_i) \neq y_i)$
 - 如果 $\epsilon_t > 0.5$, 则停止 (基学习器太差)
 - 计算基学习器的权重: $\alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t}$

- 更新样本权重: $D_{t+1}(i) = \frac{D_t(i)}{Z_t} \exp(-\alpha_t y_i h_t(\mathbf{x}_i))$, 其中 Z_t 是归一化因子
3. 输出最终分类器: $H(\mathbf{x}) = \text{sign}\left(\sum_{t=1}^T \alpha_t h_t(\mathbf{x})\right)$

基学习器权重:

$$\alpha_t = \frac{1}{2} \ln \frac{1 - \epsilon_t}{\epsilon_t}$$

理解:

- 错误率 ϵ_t 越小, α_t 越大, 说明该基学习器越重要
- 当 $\epsilon_t = 0$ 时, $\alpha_t \rightarrow +\infty$ (完美分类器)
- 当 $\epsilon_t = 0.5$ 时, $\alpha_t = 0$ (随机猜测, 无贡献)
- 当 $\epsilon_t > 0.5$ 时, $\alpha_t < 0$ (比随机猜测还差, 应该停止)

样本权重更新:

$$D_{t+1}(i) = \frac{D_t(i)}{Z_t} \exp(-\alpha_t y_i h_t(\mathbf{x}_i))$$

其中 $Z_t = \sum_{i=1}^m D_t(i) \exp(-\alpha_t y_i h_t(\mathbf{x}_i))$ 是归一化因子。

理解:

- 如果 $h_t(\mathbf{x}_i) = y_i$ (分类正确), 则 $y_i h_t(\mathbf{x}_i) > 0$, $\exp(-\alpha_t y_i h_t(\mathbf{x}_i)) < 1$, 样本权重减小
- 如果 $h_t(\mathbf{x}_i) \neq y_i$ (分类错误), 则 $y_i h_t(\mathbf{x}_i) < 0$, $\exp(-\alpha_t y_i h_t(\mathbf{x}_i)) > 1$, 样本权重增大
- 这样, 错误分类的样本在下一轮训练中会受到更多关注

例题

题目：AdaBoost 权重更新与样本分布变化。给定一个二分类数据集：

样本	x_i	标签 y_i
1	A	+1
2	B	+1
3	C	-1
4	D	-1

第一个弱分类器 $h_1(x)$ 的预测如下：

样本	$h_1(x_i)$
A	+1
B	-1
C	-1
D	+1

已知错误率 $\varepsilon_1 = 0.25$ 。

1. 计算弱分类器权重： $\alpha_1 = \frac{1}{2} \ln \frac{1-\varepsilon_1}{\varepsilon_1}$ 。
2. 计算新的样本分布 $D_2(i)$ 。
3. 请分析哪些样本的权重会上升？这意味着 AdaBoost 下一轮学习时会偏向哪些样本？解释其原因。

解答：

1. 弱分类器权重： $\alpha_1 = \frac{1}{2} \ln \frac{1-0.25}{0.25} = \frac{1}{2} \ln 3 \approx 0.549$
2. 样本权重更新：
 - 初始权重： $D_1(i) = 0.25$ （所有样本权重相等）
 - 更新公式： $D_{t+1}(i) = \frac{D_t(i)}{Z_t} \exp(-\alpha_t y_i h_t(x_i))$
 - 计算过程（未归一化）：
 - 样本 A： $y = +1, h_1(A) = +1$, 分类正确, $y \cdot h_1 = +1$, 权重： $0.25 \times \exp(-0.549) = 0.25 \times 0.577 \approx 0.144$
 - 样本 B： $y = +1, h_1(B) = -1$, 分类错误, $y \cdot h_1 = -1$, 权重： $0.25 \times \exp(+0.549) = 0.25 \times 1.732 \approx 0.433$
 - 样本 C： $y = -1, h_1(C) = -1$, 分类正确, $y \cdot h_1 = +1$, 权重： $0.25 \times \exp(-0.549) = 0.25 \times 0.577 \approx 0.144$
 - 样本 D： $y = -1, h_1(D) = +1$, 分类错误, $y \cdot h_1 = -1$, 权重： $0.25 \times \exp(+0.549) = 0.25 \times 1.732 \approx 0.433$
 - 归一化因子： $Z_1 = 0.144 + 0.433 + 0.144 + 0.433 = 1.154$
 - 归一化后： $D_2(1) = \frac{0.144}{1.154} \approx 0.125$, $D_2(2) = \frac{0.433}{1.154} \approx 0.375$, $D_2(3) = \frac{0.144}{1.154} \approx 0.125$, $D_2(4) = \frac{0.433}{1.154} \approx 0.375$
3. 权重变化分析：
 - 样本 B 和 D 的权重上升（从 0.25 增加到 0.375），因为它们在 h_1 中被错误分类
 - 样本 A 和 C 的权重下降（从 0.25 减少到 0.125），因为它们在 h_1 中被正确分类
 - 下一轮学习器会重点关注这些”困难样本”（B 和 D），试图修正 h_1 的错误
 - 这是 AdaBoost”自适应”的体现：通过增加错误样本的权重，让后续学习器更关注这些样本

7.3 Bagging 与随机森林

7.3.1 Bagging 的基本思想

Bagging (Bootstrap Aggregating): 一种并行式集成学习方法，每个个体学习器使用的算法是相同的，但是在不同的样本集上进行训练。因此个体学习器之间不存在强的计算依赖关系，可并行学习，最后再进行结果集成。

工作流程:

1. 对训练集进行 T 轮自助采样 (bootstrap sampling)，得到 T 个采样集
2. 基于每个采样集训练一个基学习器
3. 对分类任务使用简单投票法，对回归任务使用简单平均法

自助采样 (Bootstrap Sampling):

- 给定包含 m 个样本的数据集，进行 m 次有放回的随机采样
- 每个样本被采到的概率为 $1 - (1 - \frac{1}{m})^m \approx 1 - e^{-1} \approx 0.632$
- 未被采到的样本约占 36.8%，可以用作验证集 (包外估计, out-of-bag estimate)

理解:

- Bagging 通过样本扰动来增加个体学习器的多样性
- 每个基学习器在不同的样本子集上训练，降低了过拟合风险
- 对数据样本的扰动敏感的基学习器 (如决策树、神经网络) 适合使用 Bagging
- 对数据样本的扰动不敏感的基学习器 (如线性学习器、支持向量机、朴素贝叶斯、k 近邻) 使用 Bagging 效果不明显

例题

题目: Bagging 模型方差与集成优点。某回归问题中，单个基学习器的输出方差为 $\text{Var}(T_i) = 1.2$ ，不同学习器之间的预测相关系数为 $\rho = 0.2$ 。共有 $N = 50$ 个学习器。

1. 计算集成预测输出的总体方差: $\text{Var}(T) = \rho \text{Var}(T_i) + \frac{1-\rho}{N} \text{Var}(T_i)$ 。
2. 若改为 $N = 200$ 个学习器，新的方差是多少?
3. 结合计算结果，Bagging 模型减少方差的机制是什么? 为何当学习器越多、相关性越低时效果越好?

解答:

1. **计算方差 ($N = 50$):**

$$\text{Var}(T) = 0.2 \times 1.2 + \frac{1-0.2}{50} \times 1.2 = 0.24 + 0.0192 = 0.2592$$

2. **计算方差 ($N = 200$):**

$$\text{Var}(T) = 0.2 \times 1.2 + \frac{1-0.2}{200} \times 1.2 = 0.24 + 0.0048 = 0.2448$$

3. **机制分析:**

- 第一项 $\rho \text{Var}(T_i)$: 由于学习器相关性导致的方差，无法通过增加 N 减少
- 第二项 $\frac{1-\rho}{N} \text{Var}(T_i)$: 由于学习器独立性可以减小的方差，随 N 增大而减小
- 学习器越多: 第二项越小，总体方差减小
- 相关性越低: 第一项越小，且第二项的减小效果更明显
- 两者结合可以最大程度地减少集成模型的方差

7.3.2 随机森林 (Random Forest)

随机森林: Bagging 的一个扩展变体, 在以决策树为基学习器构建 Bagging 集成的基础上, 进一步在决策树的训练过程中引入了随机属性选择。

基本思想:

- 传统决策树在选择划分属性时, 是在当前结点的属性集合中选择一个最优属性
- 随机森林在决策树的训练过程中, 对每个结点, 先从该结点的属性集合中随机选择一个包含 k 个属性的子集, 然后再从这个子集中选择一个最优属性用于划分
- 参数 k 控制了随机性的引入程度: $k = d$ (属性总数) 时, 就是传统决策树; $k = 1$ 时, 则是随机选择一个属性用于划分
- 推荐值: $k = \log_2 d$ (分类) 或 $k = \sqrt{d}$ (回归)

随机森林的特点:

- 同时使用了数据样本扰动和输入属性扰动, 增强了多样性
- 训练速度快 (可以并行), 对大数据集适应性强
- 能够评估特征的重要性
- 对缺失值不敏感, 可以处理不平衡数据

7.4 多样性

7.4.1 多样性的重要性

集成多样性 (Diversity): 个体学习器之间的差异, 是集成学习方法的重要议题。

关键认识:

- 若结合完全相同的个体学习器, 显然不会有性能提升
- 要想在结合之后有性能提升, 个体学习器之间必须有差异
- 多样性至关重要, 却难以刻画: 目前还没有一个广泛接受的定义
- 个体学习器应当兼具精确性与多样性
- ”互补性” 比单纯的精度更重要, 集成高精度的个体学习器不如结合多样性更好的个体学习器性能好
- 集成学习依赖于个体学习器精度和多样性之间的权衡

7.4.2 多样性度量

成对多样性度量: 度量两个分类器之间的差异。

不一致度量 (Disagreement Measure):

$$\text{dis}_{i,j} = \frac{b+c}{m}$$

其中 b 是两个分类器预测不同且 h_i 正确的样本数, c 是两个分类器预测不同且 h_j 正确的样本数, m 是总样本数。

相关系数 (Correlation Coefficient):

$$\rho_{i,j} = \frac{ad - bc}{\sqrt{(a+b)(a+c)(c+d)(b+d)}}$$

其中 a 是两个分类器都正确的样本数, b 是 h_i 正确但 h_j 错误的样本数, c 是 h_i 错误但 h_j 正确的样本数, d 是两个分类器都错误的样本数。

Q 统计量:

$$Q_{i,j} = \frac{ad - bc}{ad + bc}$$

κ 统计量:

$$\kappa = \frac{p_1 - p_2}{1 - p_2}$$

其中 p_1 是两个分类器达成一致的的概率, p_2 是偶然达成一致的的概率。

理解:

- 若两个分类器在所有样本上都达成一致, 则 $\kappa = 1$
- 若它们仅是偶然达成一致, 则 $\kappa = 0$
- κ 通常取非负值, 仅在两个分类器达成一致甚至低于偶然性的情况下取负值

7.4.3 多样性增强

常见的增强个体学习器的多样性的方法:

- 数据样本扰动: 基于采样法 (Bagging 中的自助采样法、AdaBoost 中的序列采样)
- 输入属性扰动: 随机子空间算法 (random subspace), 从原始属性集中随机选择一个子集
- 输出表示扰动: 翻转法 (Flipping Output)、输出调剂法 (Output Smearing)、ECOC 法
- 算法参数扰动: 负相关法, 不同的多样性增强机制同时使用

随机子空间算法:

1. 对每个基学习器, 从原始属性集中随机选择一个包含 d' 个属性的子集 $\mathcal{F}_t$
2. 将训练集 D 映射到子空间: $D_t = \text{Map}_{\mathcal{F}_t}(D)$
3. 在子空间 D_t 上训练基学习器 h_t
4. 最终预测: $H(\mathbf{x}) = \arg \max_{y \in \mathcal{Y}} \sum_{t=1}^T \mathbb{I}(h_t(\text{Map}_{\mathcal{F}_t}(\mathbf{x})) = y)$

理解:

- 不同的多样性增强机制可同时使用
- 例如随机森林中同时使用了数据样本扰动和输入属性扰动
- 有些方法甚至同时使用了更多机制

7.5 比较和总结

7.5.1 主要集成方法的对比

提升 (Boosting):

- 级联式训练个体学习器, 每个后继学习器都对其前驱学习器做出一些改进
- 个体学习器之间存在强依赖关系, 必须串行生成
- 样本权重自适应更新, 关注错误样本
- 弱学习器权重根据错误率计算
- 泛化误差: 通过降低偏差 (bias) 来提升性能

装袋 (Bagging):

- 每个个体学习器使用的算法是相同的, 但是在不同的样本集上进行训练
- 个体学习器之间不存在强的计算依赖关系, 可并行学习
- 训练集划分: 自助采样, 每个基学习器使用不同的样本子集
- 样本权重: 所有样本权重相等
- 弱学习器权重: 所有基学习器权重相等 (简单投票或平均)

- 泛化误差：通过降低方差（variance）来提升性能

堆叠（Stacking）：

- 初级学习器并行运行，级联次级学习器训练初级学习器权重
- 兼有 Bagging 和 Boosting 的特点
- 使用元学习器（meta-learner）来学习如何组合初级学习器的输出

7.5.2 主流集成学习方法

- **Bagging/随机森林**：最常见的集成学习，通过样本和属性扰动增强多样性
- **AdaBoost**：样本权重自适应更新，经典的 Boosting 算法
- **GBDT/CatBoost/GBM**：梯度提升决策树，使用梯度下降优化
- **XGBoost**：通用的梯度提升策略，在 GBDT 基础上优化
- **Stacking**：初级学习器/次级学习器，使用元学习器组合
- **Blending**：和 Stacking 类似（自学内容）

7.5.3 模型小结

核心思想：通过结合多个个体学习器来提高泛化性能，关键在于增加个体学习器的多样性。

成功的关键：

- 个体学习器应当兼具精确性与多样性
- ”互补性”比单纯的精度更重要
- 集成学习依赖于个体学习器精度和多样性之间的权衡

适用场景：

- 对数据样本扰动敏感的基学习器（决策树、神经网络）适合使用 Bagging
- 对数据样本扰动不敏感的基学习器（线性学习器、SVM、朴素贝叶斯、k 近邻）使用 Bagging 效果不明显
- Boosting 通常能显著提升弱学习器的性能

8 第 8 讲降维与度量学习

[考点] 考点：P62 页，矩阵 + 特征向量

8.1 基本概念

8.1.1 降维的定义与目的

降维（Dimensionality Reduction）：将原高维空间嵌入到一个合适的低维子空间中，接着在低维空间中进行学习任务。

降维的目的：

- 降低计算复杂度
- 减少存储空间
- 去除冗余特征，提取主要信息
- 数据可视化（降到 2 维或 3 维）
- 缓解”维数灾难”（curse of dimensionality）

对特征的要求：

1. 具有很大的识别信息量：特征应具有很好的可分性，使分类器容易判别
2. 具有可靠性：去掉模棱两可，似是而非，对判别作用不大的特征
3. 具有尽可能强的独立性：特征之间的强相关性并没有增加分类信息，反而给问题的数值求解带来病态条件

4. 数量尽可能少，同时损失的信息尽量小

8.1.2 特征提取与特征选择

原始特征：通过直接测量得到的特征称为原始特征。

特征提取 (Feature Extraction)：通过映射（变换）的方法把高维的特征向量转为低维的特征向量。映射 $A: X \rightarrow Y$ ，其中 X 是高维空间， Y 是低维空间。

特征选择 (Feature Selection)：从原始特征中挑选出一些最有代表性、分类性能好的特征，以达到降低特征空间维数的目的。 D 个特征 $\rightarrow d$ 个特征 ($d < D$)。

区别：

- 特征提取：通过映射变换，产生新的特征（可能是原始特征的线性或非线性组合）
- 特征选择：从原始特征中选择子集，不产生新特征

8.1.3 特征类别

1. **物理特征 (观测型特征)：**比较直接、人们容易感知的特征。虽然容易感知，却未必能非常有效地表征分类对象。

2. **结构特征 (几何型特征)：**反映对象外观轮廓或逻辑结构的一类特征，既包括对象组分之间的具象的几何邻接关系，也包括对象组分之间抽象的相互作用关系。结构特征的表达能力一般要高于物理特征，对对象的尺寸往往不太敏感。

3. **符号特征 (编号型特征)：**为了表征观察对象而设立的特征，如学号。可以保证唯一性，但不容易被人感知。

8.1.4 用于分类的模式特征的特点

类内有凝聚性：选择的特征对同一类应具有稳定性。由于模式类是由具有相似特性的若干个样本构成的，因此它们同属一类，首要前提是特性相似，反映在取值分布上，应该有较稳定的凝聚性。

类间有差异性：选择的特征对不同的类应该有可辨识的差异。若不同类的模式的特征值差异很小，则说明所选择的特征对于不同的类没有什么差异，作为分类的依据时，容易使不同的类产生混淆，使误识率增大。一般来讲，特征的类间差异应该大于类内差异。

8.2 主成分分析 (PCA)

8.2.1 PCA 的基本思想

主成分分析 (Principal Component Analysis, PCA)：一种常用的无监督线性降维方法，通过寻找数据中方差最大的方向（主成分）来进行降维。

基本思想：

- 将高维数据投影到低维空间，使得投影后的数据方差最大
- 保留数据中的主要信息，去除冗余信息
- 主成分是原始特征的线性组合

理解：PCA 试图找到一个低维超平面，使得所有样本到这个超平面的距离（重构误差）最小，或者说，使得样本在这个超平面上的投影的方差最大。

8.2.2 协方差矩阵与特征值分解

数据矩阵：设样本集 $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m]$ ，其中 $\mathbf{x}_i \in \mathbb{R}^d$ 。

中心化：对每个特征减去均值， $\mathbf{x}'_i = \mathbf{x}_i - \boldsymbol{\mu}$ ，其中 $\boldsymbol{\mu} = \frac{1}{m} \sum_{i=1}^m \mathbf{x}_i$ 。

协方差矩阵：

$$\mathbf{C} = \frac{1}{m} \mathbf{X} \mathbf{X}^T = \frac{1}{m} \sum_{i=1}^m \mathbf{x}_i \mathbf{x}_i^T$$

特征值分解 (P62 核心内容):

$$\mathbf{C} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^T$$

其中 $\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_d)$ 是对角矩阵, $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$ 是特征值,
 $\mathbf{V} = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_d]$ 是特征向量矩阵, $\mathbf{v}_i$ 是对应于 λ_i 的特征向量。

理解:

- 协方差矩阵 $\mathbf{C}$ 是 $d \times d$ 的对称矩阵
- 特征值 λ_i 表示第 i 个主成分的方差
- 特征向量 $\mathbf{v}_i$ 表示第 i 个主成分的方向
- 特征向量之间相互正交 ($\mathbf{v}_i^T \mathbf{v}_j = 0, i \neq j$)
- 特征向量通常是单位向量 ($\|\mathbf{v}_i\| = 1$)

8.2.3 PCA 的求解 (P62 关键步骤)

目标: 将 d 维数据降到 d' 维 ($d' < d$), 选择前 d' 个最大的特征值对应的特征向量。

投影矩阵:

$$\mathbf{W} = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_{d'}] \in \mathbb{R}^{d \times d'}$$

其中 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_{d'}$ 是前 d' 个最大特征值对应的特征向量 (按特征值从大到小排序)。

降维后的数据:

$$\mathbf{Z} = \mathbf{W}^T \mathbf{X} \in \mathbb{R}^{d' \times m}$$

即 $\mathbf{z}_i = \mathbf{W}^T \mathbf{x}_i$, 其中 $\mathbf{z}_i$ 是 $\mathbf{x}_i$ 在低维空间中的表示。

重构误差: 原始数据 $\mathbf{x}_i$ 与重构数据 $\mathbf{W} \mathbf{z}_i$ 之间的误差。PCA 最小化所有样本的重构误差之和。

方差贡献率:

$$\text{贡献率} = \frac{\sum_{i=1}^{d'} \lambda_i}{\sum_{i=1}^d \lambda_i}$$

表示前 d' 个主成分保留的方差比例。

理解:

- 选择前 d' 个最大的特征值, 意味着保留方差最大的 d' 个方向
- 特征值越大, 说明该方向上的数据变化越大, 包含的信息越多
- 通常选择 d' 使得方差贡献率达到某个阈值 (如 80% 或 90%)

8.2.4 PCA 的计算步骤

步骤 1: 数据预处理 (中心化)

$$\mathbf{x}'_i = \mathbf{x}_i - \boldsymbol{\mu}, \quad \boldsymbol{\mu} = \frac{1}{m} \sum_{i=1}^m \mathbf{x}_i$$

步骤 2: 计算协方差矩阵

$$\mathbf{C} = \frac{1}{m} \mathbf{X} \mathbf{X}^T$$

步骤 3: 特征值分解

$$\mathbf{C} \mathbf{v}_i = \lambda_i \mathbf{v}_i, \quad i = 1, 2, \dots, d$$

步骤 4: 选择主成分

- 对特征值排序: $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d$
- 选择前 d' 个最大特征值对应的特征向量
- 构造投影矩阵: $\mathbf{W} = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_{d'}]$

步骤 5: 降维

$$\mathbf{Z} = \mathbf{W}^T \mathbf{X}$$

理解: PCA 的整个过程就是通过对协方差矩阵进行特征值分解, 找到数据的主要变化方向, 然后将数据投影到这些方向上。

例题

例 1：从数据计算协方差矩阵（简单示例）

题目：给定 3 个 2 维样本： $\mathbf{x}_1 = [1, 2]^T$ ， $\mathbf{x}_2 = [2, 3]^T$ ， $\mathbf{x}_3 = [3, 1]^T$ 。计算协方差矩阵。

解答：

步骤 1：数据中心化

计算均值向量：

$$\boldsymbol{\mu} = \frac{1}{3}[\mathbf{x}_1 + \mathbf{x}_2 + \mathbf{x}_3] = \frac{1}{3} \begin{bmatrix} 1+2+3 \\ 2+3+1 \end{bmatrix} = \frac{1}{3} \begin{bmatrix} 6 \\ 6 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}$$

中心化后的数据：

$$\mathbf{x}'_1 = \begin{bmatrix} 1-2 \\ 2-2 \end{bmatrix} = \begin{bmatrix} -1 \\ 0 \end{bmatrix}, \quad \mathbf{x}'_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad \mathbf{x}'_3 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

步骤 2：计算协方差矩阵

$$\boldsymbol{\Sigma} = \frac{1}{m-1} \sum_{i=1}^m \mathbf{x}'_i (\mathbf{x}'_i)^T = \frac{1}{m-1} \mathbf{X}' \mathbf{X}'^T$$

其中 $\mathbf{X}'$ 是中心化后的数据矩阵（每列是一个样本）。

数据矩阵（每列是一个样本）：

$$\mathbf{X}' = \begin{bmatrix} -1 & 0 & 1 \\ 0 & 1 & -1 \end{bmatrix}$$

计算协方差矩阵：

$$\boldsymbol{\Sigma} = \frac{1}{3-1} \mathbf{X}' \mathbf{X}'^T = \frac{1}{2} \begin{bmatrix} -1 & 0 & 1 \\ 0 & 1 & -1 \end{bmatrix} \begin{bmatrix} -1 & 0 \\ 0 & 1 \\ 1 & -1 \end{bmatrix}$$

计算矩阵乘法：

$$\mathbf{X}' \mathbf{X}'^T = \begin{bmatrix} (-1)^2 + 0^2 + 1^2 & (-1) \times 0 + 0 \times 1 + 1 \times (-1) \\ 0 \times (-1) + 1 \times 0 + (-1) \times 1 & 0^2 + 1^2 + (-1)^2 \end{bmatrix} = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$$

因此：

$$\boldsymbol{\Sigma} = \frac{1}{2} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & -0.5 \\ -0.5 & 1 \end{bmatrix}$$

理解：协方差矩阵是对称矩阵，对角线元素是各维度的方差，非对角线元素是不同维度之间的协方差。

例题

例 2: PCA 主成分方向与投影（给定协方差矩阵）

题目：给定协方差矩阵：

$$\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}$$

1. 求特征值与特征向量。
2. 指出主成分方向，并计算方差贡献率。
3. 对样本 $\mathbf{x} = [2, 1]^T$ ，计算其在第一主成分上的投影。
4. 如果仅保留第一主成分，原始二维信息会损失多少？此损失代表什么含义？

解答：

1. 求特征值与特征向量：

步骤 1：特征方程

$$\det(\Sigma - \lambda \mathbf{I}) = 0$$

$$\det \begin{bmatrix} 4 - \lambda & 2 \\ 2 & 3 - \lambda \end{bmatrix} = 0$$

步骤 2：计算行列式

$$\det \begin{bmatrix} a & b \\ c & d \end{bmatrix} = ad - bc$$

$$(4 - \lambda)(3 - \lambda) - 2 \times 2 = 0$$

$$\lambda^2 - 7\lambda + 8 = 0$$

步骤 3：求解特征值

$$\lambda = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

代入： $a = 1$, $b = -7$, $c = 8$ ，得： $\lambda_1 = 5.562$, $\lambda_2 = 1.438$

例题

解答（续）：

1. (续) 步骤 4：求解特征向量

对每个特征值 λ_i ，求解 $(\Sigma - \lambda_i \mathbf{I})\mathbf{v}_i = \mathbf{0}$ ，然后单位化：

$$\mathbf{v}_{\text{unit}} = \frac{\mathbf{v}}{\|\mathbf{v}\|}, \quad \|\mathbf{v}\| = \sqrt{v_1^2 + v_2^2}$$

$$\text{对于 } \lambda_1 = 5.562: \mathbf{v}_1 = \begin{bmatrix} 0.788 \\ 0.615 \end{bmatrix}$$

$$\text{对于 } \lambda_2 = 1.438: \mathbf{v}_2 = \begin{bmatrix} 0.615 \\ -0.788 \end{bmatrix}$$

1. 主成分方向与方差贡献率：

$$\text{第一主成分: } \mathbf{v}_1 = \begin{bmatrix} 0.788 \\ 0.615 \end{bmatrix} \quad (\lambda_1 = 5.562)$$

$$\text{第二主成分: } \mathbf{v}_2 = \begin{bmatrix} 0.615 \\ -0.788 \end{bmatrix} \quad (\lambda_2 = 1.438)$$

方差贡献率公式：

$$\text{贡献率} = \frac{\lambda_i}{\lambda_1 + \lambda_2 + \cdots + \lambda_d}$$

总方差： $\lambda_1 + \lambda_2 = 7$ 第一主成分贡献率： $\frac{5.562}{7} = 79.5\%$ ，第二主成分贡献率： $\frac{1.438}{7} = 20.5\%$

2. 样本在第一主成分上的投影：

投影公式：

$$\text{投影} = \mathbf{v}_1^T \mathbf{x}$$

代入数据：

$$\mathbf{v}_1^T \mathbf{x} = [0.788 \quad 0.615] \begin{bmatrix} 2 \\ 1 \end{bmatrix} = 2.191$$

3. 信息损失分析：

信息损失公式：

$$\text{信息损失} = 1 - \frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{\lambda_2}{\lambda_1 + \lambda_2}$$

代入数据：

$$\text{信息损失} = \frac{1.438}{7} = 20.5\%$$

含义：被丢弃的第二主成分包含的方差比例为 20.5%，表示原始二维数据在第二主成分方向上的变化信息被丢弃。

例题

例 3: PCA 完整计算流程 (从数据到降维)

题目: 将二维样本数据降至一维。数据矩阵:

$$\mathbf{X} = \begin{bmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{bmatrix}$$

解答:

已知条件 (步骤 1 和 2 的计算见例 1 和例 2):

协方差矩阵: $\mathbf{C} = \begin{bmatrix} \frac{6}{5} & \frac{4}{5} \\ \frac{4}{5} & \frac{2}{5} \end{bmatrix}$

特征值: $\lambda_1 = 2, \lambda_2 = \frac{2}{5}$

特征向量: $\mathbf{v}_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}, \mathbf{v}_2 = \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$

步骤 3: 对角化验证

$$\mathbf{W}^T \mathbf{C} \mathbf{W} = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} \frac{6}{5} & \frac{4}{5} \\ \frac{4}{5} & \frac{2}{5} \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & \frac{2}{5} \end{bmatrix}$$

验证成功, 对角元素为特征值。

步骤 4: 降维投影

选择第一主成分: $\mathbf{w}_1 = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$

投影计算:

$$\mathbf{Z} = \mathbf{w}_1^T \mathbf{X} = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix} \begin{bmatrix} -1 & -1 & 0 & 2 & 0 \\ -2 & 0 & 0 & 1 & 1 \end{bmatrix}$$

$$\mathbf{Z} = \begin{bmatrix} -\frac{3}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 & \frac{3}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{bmatrix}$$

方差贡献率: $\frac{\lambda_1}{\lambda_1 + \lambda_2} = \frac{2}{2 + \frac{2}{5}} = \frac{5}{6} \approx 83.33\%$

考试要点 (P62):

- 给定数据矩阵, 计算协方差矩阵 $\mathbf{C}$
- 对协方差矩阵进行特征值分解: $\mathbf{C}\mathbf{v}_i = \lambda_i\mathbf{v}_i$
- 按特征值从大到小排序, 选择前 d' 个特征向量
- 构造投影矩阵 $\mathbf{W}$, 计算降维后的数据 $\mathbf{Z} = \mathbf{W}^T \mathbf{X}$
- 计算方差贡献率

8.2.5 矩阵 + 特征向量 (考点重点)

关键计算: 给定数据矩阵, 求协方差矩阵的特征值和特征向量。

示例: 给定 m 个 d 维样本 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$, 计算 PCA 的投影矩阵。

计算流程:

1. 构造数据矩阵: $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m] \in \mathbb{R}^{d \times m}$
2. 中心化: $\mathbf{X}' = \mathbf{X} - \boldsymbol{\mu} \mathbf{1}^T$, 其中 $\boldsymbol{\mu}$ 是均值向量
3. 计算协方差矩阵: $\mathbf{C} = \frac{1}{m-1} \mathbf{X}' \mathbf{X}'^T \in \mathbb{R}^{d \times d}$ (注: $m-1$ 为无偏估计)
4. 特征值分解: $\mathbf{C}\mathbf{V} = \mathbf{V}\boldsymbol{\Lambda}$, 得到特征值 λ_i 和特征向量 $\mathbf{v}_i$
5. 排序: 按特征值从大到小排序

6. 选择：取前 d' 个特征向量构成投影矩阵 $\mathbf{W}$

理解：PCA 的核心就是矩阵的特征值分解。特征向量定义了主成分的方向，特征值表示该方向上的方差大小。

8.3 线性判别分析（LDA）用于降维

8.3.1 LDA 降维的基本思想

线性判别分析（Linear Discriminant Analysis, LDA）：一种有监督的线性降维方法，在分类任务中使用。

与 PCA 的区别：

- PCA 是无监督的，目标是最大化投影后的方差
- LDA 是有监督的，目标是最大化类间散度与类内散度之比
- PCA 不考虑类别信息，LDA 利用类别信息

LDA 的目标：寻找一个投影方向 $\mathbf{w}$ ，使得投影后：

- 类间散度（between-class scatter）最大
- 类内散度（within-class scatter）最小

8.3.2 LDA 的数学形式

类间散度矩阵 S_b ：

$$S_b = \sum_{i=1}^c n_i (\boldsymbol{\mu}_i - \boldsymbol{\mu})(\boldsymbol{\mu}_i - \boldsymbol{\mu})^T$$

其中 c 是类别数， n_i 是第 i 类的样本数， $\boldsymbol{\mu}_i$ 是第 i 类的均值向量， $\boldsymbol{\mu}$ 是总体均值向量。

类内散度矩阵 S_w ：

$$S_w = \sum_{i=1}^c \sum_{\mathbf{x} \in X_i} (\mathbf{x} - \boldsymbol{\mu}_i)(\mathbf{x} - \boldsymbol{\mu}_i)^T = \sum_{i=1}^c S_i$$

其中 X_i 是第 i 类的样本集合， S_i 是第 i 类的协方差矩阵。

Fisher 准则：

$$J(\mathbf{w}) = \frac{\mathbf{w}^T S_b \mathbf{w}}{\mathbf{w}^T S_w \mathbf{w}}$$

目标：最大化 $J(\mathbf{w})$ 。

最优解：

$$S_w^{-1} S_b \mathbf{w} = \lambda \mathbf{w}$$

即求解广义特征值问题，选择前 d' 个最大特征值对应的特征向量作为投影方向。

投影矩阵： $\mathbf{W} = [\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_{d'}]$ ，降维后的数据： $\mathbf{Z} = \mathbf{W}^T \mathbf{X}$ 。

理解：LDA 通过求解广义特征值问题来找到最优投影方向，这些方向能够最好地区分不同类别。

8.4 多维标度 (MDS)

8.4.1 MDS 的基本思想

多维标度 (Multidimensional Scaling, MDS): 一种经典的距离保持降维方法，目标是保持样本间的距离不变。

基本思想: 给定样本间的距离矩阵，在低维空间中重构样本的位置，使得低维空间中的距离尽可能接近原始距离。

目标函数:

$$\min_{\mathbf{z}_1, \dots, \mathbf{z}_m} \sum_{i < j} (d_{ij} - \|\mathbf{z}_i - \mathbf{z}_j\|)^2$$

其中 d_{ij} 是原始空间中样本 i 和样本 j 之间的距离， $\|\mathbf{z}_i - \mathbf{z}_j\|$ 是低维空间中的距离。

8.4.2 MDS 的计算流程

输入: 样本集 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$ 和低维空间维数 d' 。

步骤 1: 计算样本的距离矩阵 $\mathbf{D}$ ，其中 $D_{ij} = \|\mathbf{x}_i - \mathbf{x}_j\|$ 。

步骤 2: 由距离矩阵 $\mathbf{D}$ 构造降维后新样本的内积矩阵 $\mathbf{B} = \mathbf{Z}^T \mathbf{Z}$ 。

步骤 3: 对 $\mathbf{B}$ 矩阵做特征值分解: $\mathbf{B} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^T$ 。

步骤 4: 取最大的 d' 个特征值构成对角矩阵 $\tilde{\mathbf{\Lambda}}$ ，对应的特征向量构成矩阵 $\tilde{\mathbf{V}}$ 。

输出:

$$\mathbf{Z} = \tilde{\mathbf{\Lambda}}^{\frac{1}{2}} \tilde{\mathbf{V}}^T \in \mathbb{R}^{d' \times m}$$

理解: MDS 保留了原样本间的距离，非常适合做数据可视化，比如知觉图 (perceptual mapping) 一般都基于 MDS 绘制。

8.5 流形学习

8.5.1 流形学习的基本思想

流形 (Manifold): 在数学中，流形是一个局部类似于欧几里得空间的拓扑空间。

流形学习 (Manifold Learning): 假设高维数据实际上位于一个低维流形上，流形学习的目标是发现这个低维流形结构。

基本假设: 虽然数据在高维空间中，但实际上数据的内在维数 (intrinsic dimensionality) 可能很低，数据点分布在一个低维流形上。

8.5.2 常见的流形学习方法

等距映射 (Isomap):

- 保持测地距离 (geodesic distance) 不变
- 使用图的最短路径来近似测地距离
- 然后使用 MDS 进行降维

拉普拉斯特征映射 (Laplacian Eigenmaps, LE):

- 基于图的拉普拉斯矩阵
- 保持局部邻域关系
- 最小化相邻样本在低维空间中的距离

局部线性嵌入 (Locally Linear Embedding, LLE):

- 假设每个样本可以由其邻居样本线性表示
- 在低维空间中保持这种局部线性关系
- 通过特征值分解求解

理解: 流形学习方法能够发现数据的非线性结构, 适用于数据分布复杂的场景。

8.6 度量学习

8.6.1 度量学习的基本思想

度量学习 (Metric Learning): 学习一个合适的距离度量函数, 使得在该度量下, 相似样本之间的距离较小, 不相似样本之间的距离较大。

问题背景: 传统的欧氏距离可能不适合特定的任务, 通过学习任务相关的距离度量可以提高性能。

马氏距离 (Mahalanobis Distance):

$$d_M(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{(\mathbf{x}_i - \mathbf{x}_j)^T \mathbf{M} (\mathbf{x}_i - \mathbf{x}_j)}$$

其中 $\mathbf{M}$ 是正定矩阵, 称为度量矩阵。

理解:

- 当 $\mathbf{M} = \mathbf{I}$ 时, 马氏距离退化为欧氏距离
- 当 $\mathbf{M} = \Sigma^{-1}$ (协方差矩阵的逆) 时, 考虑特征的方差和相关性
- 通过学习最优的 $\mathbf{M}$, 可以得到任务相关的距离度量

8.7 模型小结

降维方法分类:

- 按监督性: 监督式 (LDA) vs 非监督式 (PCA、MDS、流形学习)
- 按线性性: 线性降维 (PCA、LDA) vs 非线性降维 (流形学习、核 PCA)

核心数学工具:

- 矩阵特征值分解: PCA、MDS、流形学习方法的核心
- 广义特征值问题: LDA 的核心
- 矩阵运算: 协方差矩阵、散度矩阵的计算

选择原则:

- 如果数据是线性的, 使用 PCA 或 LDA
- 如果数据有类别标签, 优先考虑 LDA
- 如果数据有复杂的非线性结构, 使用流形学习
- 如果需要可视化, 考虑 MDS 或 t-SNE

9 第 9 讲聚类

[考点] 考点: P35 页, K 均值聚类问题

9.1 聚类任务

9.1.1 聚类的基本概念

聚类 (Clustering): 按照某个特定标准 (如距离) 把一个数据集分割成不同的类或簇, 使得同一个簇内的数据对象的相似性尽可能大, 同时不在同一个簇中的数据对象的差异性

也尽可能地大。

基本思想：物以类聚，对未知类别的样本集根据样本之间的相似程度分类，相似的归为一类，不相似的归为另一类。

形式化定义：假定样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$ 包含 m 个无标记样本，每个样本 $\mathbf{x}_i = (x_{i1}; x_{i2}; \dots; x_{in})$ 是一个 n 维的特征向量，聚类算法将样本集 D 划分成 k 个不相交的簇 $\{C_l | l = 1, 2, \dots, k\}$ ，其中 $C_{l'} \cap_{l' \neq l} C_l = \emptyset$ ，且 $D = \bigcup_{l=1}^k C_l$ 。

簇标记：用 $\lambda_j \in \{1, 2, \dots, k\}$ 表示样本 $\mathbf{x}_j$ 的簇标记 (cluster label)，即 $\mathbf{x}_j \in C_{\lambda_j}$ 。聚类的结果可用包含 m 个元素的簇标记向量 $\boldsymbol{\lambda} = \{\lambda_1, \lambda_2, \dots, \lambda_m\}$ 来表示。

理解：

- 聚类试图将数据集中的样本划分为若干个通常是不相交的子集，每个子集称为一个簇
- 每个簇可能对应于一些潜在的概念（类别），但这些概念对聚类算法而言事先是未知的
- 聚类过程仅能自动形成簇结构，簇所对应的概念语义需由使用者来把握和命名

9.1.2 聚类分析的三要素

1. 相似性测度：用于衡量同类样本的类似性和不同类样本的差异性。常用的测度有：距离、夹角余弦等。

2. 聚类准则：为了评价聚类效果的优劣，需要定义准则函数（常用的准则是误差平方和准则）。

3. 聚类算法：有了相似性测度和准则函数后，聚类就变成了使准则函数取极值的优化算法问题。

理解：在相同的相似性测度下，对同样的数据，一般而言是可以给出多种聚类结果的。需要通过准则函数来评价聚类效果的优劣。

9.1.3 聚类与分类的区别

- **聚类 (Clustering)：**把相似的数据划分到一起，具体划分时并不关注该类的标签，目标是把相似的数据聚合到一起，属于无监督学习方法
- **分类 (Classification)：**把不同的数据划分开，其过程是通过训练数据集获得一个分类器，再通过分类器去预测未知数据，属于有监督学习方法

聚类的作用：聚类既可以作为一个单独过程（用于找寻数据内在的分布结构），也可作为分类等其他学习任务的前驱过程。

9.2 性能度量

9.2.1 性能度量的基本概念

聚类性能度量：亦称为聚类“有效性指标” (validity index)。

两方面作用：

1. 对于聚类结果，我们根据某些性能度量来评估聚类好坏
2. 若明确了度量方法，可直接将其作为优化目标，从而得到符合要求的聚类结果

直观目标：簇内的样本尽可能相似，簇间的样本尽可能有差异。

9.2.2 外部指标

外部指标 (External Index)：将聚类结果与某个“参考模型” (ground truth) 进行比较。

常用外部指标：

- Jaccard 系数 (Jaccard Coefficient, JC)
- FM 指数 (Fowlkes and Mallows Index, FMI)

- Rand 指数 (Rand Index, RI)
- 调整 Rand 指数 (Adjusted Rand Index, ARI)

理解：外部指标需要知道真实的簇标记，适用于有标准答案的场景。

9.2.3 内部指标

内部指标 (Internal Index)：直接考察聚类结果，不使用任何参考模型。

常用内部指标：

1. 簇内相似度：

- 平均距离： $\text{avg}(C) = \frac{2}{|C|(|C|-1)} \sum_{1 \leq i < j \leq |C|} \text{dist}(\mathbf{x}_i, \mathbf{x}_j)$
- 簇内样本间的平均距离越小，簇内相似度越高

2. 簇间相似度：

- 簇间距离： $\text{dist}(C_i, C_j) = \min_{\mathbf{x} \in C_i, \mathbf{z} \in C_j} \text{dist}(\mathbf{x}, \mathbf{z})$ (单链接)
- 簇间样本间的最小距离越大，簇间相似度越低 (即簇间差异越大)

3. DB 指数 (Davies-Bouldin Index, DBI)：

$$\text{DBI} = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{\text{avg}(C_i) + \text{avg}(C_j)}{\text{dist}(C_i, C_j)} \right)$$

DBI 越小越好，表示簇内相似度高，簇间差异大。

4. Dunn 指数 (Dunn Index, DI)：

$$\text{DI} = \min_{1 \leq i \leq k} \left\{ \min_{j \neq i} \left(\frac{\text{dist}(C_i, C_j)}{\max_{1 \leq l \leq k} \text{diam}(C_l)} \right) \right\}$$

其中 $\text{diam}(C)$ 是簇 C 内样本间的最远距离。DI 越大越好。

理解：内部指标不需要真实标签，适用于无监督场景，但可能不如外部指标直观。

9.3 距离计算

9.3.1 距离度量的性质

距离函数： $\text{dist}(\cdot, \cdot)$ 是距离度量函数，通常满足：

1. 非负性： $\text{dist}(\mathbf{x}_i, \mathbf{x}_j) \geq 0$
2. 同一性： $\text{dist}(\mathbf{x}_i, \mathbf{x}_j) = 0$ 当且仅当 $\mathbf{x}_i = \mathbf{x}_j$
3. 对称性： $\text{dist}(\mathbf{x}_i, \mathbf{x}_j) = \text{dist}(\mathbf{x}_j, \mathbf{x}_i)$
4. 直递性 (三角不等式)： $\text{dist}(\mathbf{x}_i, \mathbf{x}_j) \leq \text{dist}(\mathbf{x}_i, \mathbf{x}_k) + \text{dist}(\mathbf{x}_k, \mathbf{x}_j)$

9.3.2 常用距离度量

闵可夫斯基距离 (Minkowski Distance)：

$$\text{dist}_{\text{mk}}(\mathbf{x}_i, \mathbf{x}_j) = \left(\sum_{u=1}^n |x_{iu} - x_{ju}|^p \right)^{\frac{1}{p}}$$

特殊情况：

- $p = 1$ ：曼哈顿距离 (Manhattan Distance) $d_1(\mathbf{x}_i, \mathbf{x}_j) = \sum_{u=1}^n |x_{iu} - x_{ju}|$
- $p = 2$ ：欧氏距离 (Euclidean Distance) $d_2(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{\sum_{u=1}^n (x_{iu} - x_{ju})^2}$

- $p \rightarrow \infty$: 切比雪夫距离 (Chebyshev Distance) $d_\infty(\mathbf{x}_i, \mathbf{x}_j) = \max_u |x_{iu} - x_{ju}|$

其他距离:

- **VDM 距离**: 用于有序属性
- **混合距离**: 同时包含有序属性和无序属性的距离度量

理解: 不同的距离度量适用于不同的数据类型和应用场景。对于数值型数据, 通常使用欧氏距离; 对于高维稀疏数据, 可以使用余弦相似度。

9.4 原型聚类

9.4.1 原型聚类的基本思想

原型聚类(Prototype-based Clustering): 假设聚类结构能通过一组原型(prototype)刻画。通常情况下, 算法先对原型进行初始化, 然后对原型进行迭代更新求解。

常见的原型聚类算法:

- k -均值算法 (k -means)
- 学习向量量化 (Learning Vector Quantization, LVQ)
- 高斯混合聚类 (Mixture-of-Gaussian)

9.4.2 k -均值算法 (考点重点)

k -均值算法 (k -means): 是原型聚类中最著名的算法, 也是最常用的聚类算法之一。

算法目标: 最小化平方误差 (Sum of Squared Errors, SSE):

$$E = \sum_{i=1}^k \sum_{\mathbf{x} \in C_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2$$

其中 $\boldsymbol{\mu}_i = \frac{1}{|C_i|} \sum_{\mathbf{x} \in C_i} \mathbf{x}$ 是簇 C_i 的均值向量 (原型)。

算法流程:

1. **初始化**: 从样本集中随机选择 k 个样本作为初始均值向量 $\{\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \dots, \boldsymbol{\mu}_k\}$
2. **分配步骤**: 对每个样本 $\mathbf{x}_j$, 计算它到各均值向量的距离, 将其分配到距离最近的簇: $C_i = \{\mathbf{x}_j | \lambda_j = i\} = \{\mathbf{x}_j | \|\mathbf{x}_j - \boldsymbol{\mu}_i\|^2 = \min_{1 \leq l \leq k} \|\mathbf{x}_j - \boldsymbol{\mu}_l\|^2\}$
3. **更新步骤**: 重新计算每个簇的均值向量: $\boldsymbol{\mu}'_i = \frac{1}{|C_i|} \sum_{\mathbf{x} \in C_i} \mathbf{x}$
4. **判断是否收敛**: 如果所有的均值向量都没有发生变化 (或变化很小), 则算法收敛, 输出聚类结果; 否则, 返回步骤 2

理解:

- k -均值算法通过迭代优化, 不断更新簇的均值向量和样本分配
- 每次迭代都会减小目标函数 E 的值 (或至少不增加)
- 算法保证收敛, 但可能收敛到局部最优解
- 不同的初始均值向量可能导致不同的聚类结果

9.4.3 k -均值算法的优缺点

优点:

- 算法简单, 易于实现
- 计算效率高, 时间复杂度为 $O(tkmn)$, 其中 t 是迭代次数, k 是簇数, m 是样本数, n 是特征维数
- 对于球形簇效果很好
- 可扩展性好, 适用于大规模数据集

缺点:

- 需要预先指定簇数 k
- 对初始值敏感，不同的初始均值向量可能导致不同的结果
- 可能收敛到局部最优解
- 只适用于球形簇，对非球形簇效果不好
- 对噪声和异常值敏感
- 假设各簇的大小相近、密度相似

9.4.4 k -均值聚类例题（考点：P35）

例题

题目（P35）：K-Means 聚类迭代与收敛分析。一维数据集： $x = \{1, 2, 3, 10, 11, 12\}$ 。
初始化： $\mu_1 = 2, \mu_2 = 10$ 。

1. 执行两次完整的 K-Means 迭代，每次写出簇分配与新的中心。
2. 说明两步后算法是否收敛。
3. 若初始中心改为 $\mu_1 = 3, \mu_2 = 12$ ，结果会怎样变化？为什么 K-Means 对初始化敏感？

解答：

1. **第一次迭代：**
 - 分配：样本 1,2,3 到簇 1（距离 $\mu_1 = 2$ 更近）；样本 10,11,12 到簇 2（距离 $\mu_2 = 10$ 更近）
 - 更新： $\mu'_1 = \frac{1+2+3}{3} = 2, \mu'_2 = \frac{10+11+12}{3} = 11$
2. **第二次迭代：**
 - 分配：样本 1,2,3 到簇 1；样本 10,11,12 到簇 2（未变化）
 - 更新： $\mu''_1 = 2$ （未变化）， $\mu''_2 = 11$ （未变化）
3. **收敛判断：**算法已收敛，因为簇分配和中心都未变化
4. **初始化敏感性：**K-Means 只能找到局部最优解，不同初始值可能导致不同结果。如果初始中心改为 $\mu_1 = 3, \mu_2 = 12$ ，第一次迭代后仍会收敛到相同结果

解题步骤总结：

1. 初始化 k 个均值向量
2. 分配样本到最近的簇：计算距离，选择最近的簇
3. 更新均值向量：计算每个簇的样本均值
4. 判断收敛：如果中心未变化，则收敛
5. 计算目标函数： $E = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$

考试要点（P35）：

- 给定样本数据和初始均值向量，执行 k -均值算法
- 计算每个样本到各均值向量的距离，分配到最近的簇
- 更新每个簇的均值向量
- 判断是否收敛（均值向量是否变化）
- 计算最终的目标函数值 E

例题

例 2: K-Means 算法完整迭代过程

题目: 20 个二维样本, $X = [0,0]$ 到 $X = [3,2]$ (左下角), $X = [6,6]$ 到 $X = [9,9]$ (右上角)。K=2, 初始中心: $Z(1)=[0,0]$, $Z(1)=[1,0]$ 。

解答:

中心更新公式:

$$Z_j(t+1) = \frac{1}{N_j} \sum_{X \in S_j(t)} X$$

第一次迭代:

步骤 1: 分配样本计算各样本到中心的欧氏距离, 前 8 个样本分配到簇 1 ($S(1)=X_1, \dots, X_8$), 后 12 个样本分配到簇 2 ($S(1)=X_9, \dots, X_{20}$)。

步骤 2: 更新中心对于簇 1, 计算新中心:

$$Z_1(2) = \frac{1}{8} \sum_{i=1}^8 X_i = \frac{1}{8} \begin{bmatrix} 0+1+0+1+2+1+2+3 \\ 0+0+1+1+1+2+2+2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0.5 \end{bmatrix}$$

对于簇 2, 类似计算得: $Z_2(2) = [5.67, 5.33]^T$

第二次迭代: 使用新中心 $Z(2)$ 和 $Z(2)$ 重新分配, 簇分配变为前 8 个样本到簇 1, 后 12 个样本到簇 2。更新中心: $Z_1(3) = [1.25, 1.13]^T$, $Z_2(3) = [7.67, 7.33]^T$ 。

第三次迭代: 簇分配不变, 中心不变, 算法收敛。最终: $Z_1 = [1.25, 1.13]^T$, $Z_2 = [7.67, 7.33]^T$ 。

理解: 初始中心选择影响收敛速度, 但算法最终会收敛到合理的聚类结果。中心更新公式计算的是簇内所有样本的均值向量。

9.5 密度聚类

9.5.1 密度聚类的基本思想

密度聚类 (Density-based Clustering): 基于密度的聚类方法, 假设聚类结构能通过样本分布的紧密程度确定。

基本思想:

- 样本分布的密度可以大于某个阈值的区域划分为一个簇
- 簇可以在具有任意形状的空间中
- 可以发现任意形状的簇, 对噪声和异常值有较好的鲁棒性

DBSCAN 算法:

- 基于密度的聚类算法
- 核心对象: 在其 ϵ -邻域内至少包含 MinPts 个样本的样本
- 密度直达、密度可达、密度相连的概念
- 可以发现任意形状的簇

9.6 层次聚类

9.6.1 层次聚类的基本思想

层次聚类 (Hierarchical Clustering): 在不同层次对数据集进行划分, 从而形成树形的聚类结构。

两种策略:

- 自底向上 (Agglomerative): AGNES 算法, 先将每个样本看作一个簇, 然后不断合并

最相似的簇

- 自顶向下 (Divisive): DIANA 算法, 先将所有样本看作一个簇, 然后不断分裂

9.6.2 AGNES 算法

AGNES (AGglomerative NESting): 一种采用自底向上聚合策略的层次聚类算法。

算法流程:

1. 初始化: 把每个样本归为一簇, 计算每两个簇之间的距离 (也就是样本与样本之间的相似度)
2. 合并: 寻找各个簇之间最近的两个簇, 把他们归为一类 (簇的总数减少一个)
3. 更新距离: 重新计算新生成的这个簇与各个旧簇之间的相似度
4. 重复: 重复步骤 2 和 3 直到所有样本点都归为一簇, 结束

类间距离度量:

单链接 (Single-linkage): 取类间最小距离

$$d_{\min}(C_i, C_j) = \min_{x \in C_i, z \in C_j} \text{dist}(x, z)$$

全链接 (Complete-linkage): 取类间最大距离

$$d_{\max}(C_i, C_j) = \max_{x \in C_i, z \in C_j} \text{dist}(x, z)$$

均链接 (Average-linkage): 取类间两两的平均距离

$$d_{\text{avg}}(C_i, C_j) = \frac{1}{|C_i||C_j|} \sum_{x \in C_i} \sum_{z \in C_j} \text{dist}(x, z)$$

理解:

- 单链接的包容性极强 (只要两个簇中有任意两个样本距离很近就合并)
- 全链接则只要存在缺点就坚决不合并 (要求两个簇中所有样本对的距离都很小)
- 均链接则是从全局出发顾全大局的一种度量

9.6.3 层次聚类的特点

优点:

- 层次聚类算法不要求指定聚类的数量, 可以选择哪个聚类看起来最好
- 该算法对距离度量的选择不敏感
- 当底层数据具有层次结构时, 可以恢复层次结构
- 可以给出聚类过程的树状表示图 (树状图, dendrogram)

缺点:

- 层次聚类的优点是以低效率为代价的, 通常具有 $O(n^3)$ 的时间复杂度
- 与 k -means 和高斯混合模型的线性复杂度不同
- 对噪声和异常值敏感

例题

层次聚类例题（最短距离准则）

题目：6 个五维样本， $X = [0, 3, 1, 2, 0]$ ， $X = [1, 3, 0, 1, 0]$ ， $X = [3, 3, 0, 0, 1]$ ， $X = [1, 1, 0, 2, 0]$ ， $X = [3, 2, 1, 2, 1]$ ， $X = [4, 1, 1, 1, 0]$ 。按最短距离准则聚类。

解答：

距离更新公式（最短距离准则）：

$$d(G_{ij}, G_k) = \min\{d(G_i, G_k), d(G_j, G_k)\}$$

初始状态：每个样本一个簇，计算距离矩阵 $D(0)$ 。

示例计算 $D(0)$ ： $D_{12}(0) = \frac{\|X_1 - X_2\|}{\sqrt{(0-1)^2 + (3-3)^2 + (1-0)^2 + (2-1)^2 + (0-0)^2}} = \sqrt{3}$

距离矩阵 $D(0)$ 中最小距离为 $\sqrt{3}$ （G 与 G 之间），合并 G 和 G 得 G (1)。

第一次合并后的距离更新：使用最短距离更新公式计算新簇 G (1) 与其他簇的距离。

示例计算 $D(G(1), G(1))$ ：

$$d(G_{12}(1), G_3(1)) = \min\{d(G_1(0), G_3(0)), d(G_2(0), G_3(0))\} = \min\{\sqrt{15}, \sqrt{6}\} = \sqrt{6}$$

更新后的距离矩阵 $D(1)$ 中最小距离为 $\sqrt{4}$ （G 与 G 之间），合并得 G (2)。

后续合并：

- 第二次合并：合并 G 和 G，更新 $D(2)$ ，最小距离 $\sqrt{5}$ （G 与 G 之间）
- 第三次合并：合并 G 和 G，得 G (3)，更新 $D(3)$

停止条件：若阈值 $T = \sqrt{5}$ ， $D(3)$ 最小距离 $\sqrt{6} > T$ ，聚类结束。

最终结果：G = X, X, X，G = X，G = X, X

理解：最短距离准则下，新簇与另一个簇的距离等于原来两个簇与该簇距离的最小值。若无阈值，算法会一直合并直到所有样本为一类。

9.7 模型小结

聚类方法分类：

- 原型聚类： k -均值、LVQ、高斯混合聚类
- 密度聚类：DBSCAN
- 层次聚类：AGNES、DIANA

k -均值算法（考点重点）：

- 目标函数：最小化平方误差 $E = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$
- 算法流程：初始化 → 分配 → 更新 → 判断收敛 → 输出
- 关键计算：计算样本到均值向量的距离，更新均值向量

选择原则：

- 如果数据是球形的，簇数已知，使用 k -均值
- 如果数据有层次结构，使用层次聚类
- 如果数据有任意形状的簇，使用密度聚类
- 如果不知道簇数，可以先尝试层次聚类或使用肘部法则确定 k

10 第 10 讲神经网络

10.1 神经元模型

10.1.1 基本结构

神经元 (Neuron): 人工神经网络的基本单元, 模拟生物神经元的结构和功能。

基本组成:

- **输入:** 接收来自其他神经元的信号 $x_1, x_2, \dots, x_n$
- **权重:** 每个输入都有对应的权重 $w_1, w_2, \dots, w_n$
- **偏置:** b (可选)
- **激活函数:** $f(\cdot)$, 对加权和进行非线性变换
- **输出:** $y = f(\sum_{i=1}^n w_i x_i + b)$

数学表示:

$$y = f\left(\sum_{i=1}^n w_i x_i + b\right) = f(\mathbf{w}^T \mathbf{x} + b)$$

理解: 神经元将多个输入信号进行加权求和, 然后通过激活函数进行非线性变换, 产生输出。这种结构使得神经网络能够学习复杂的非线性映射。

10.1.2 激活函数

激活函数的作用:

- 引入非线性, 使神经网络能够学习非线性关系
- 控制输出的范围
- 决定神经元的激活状态

常用的激活函数:

- **Sigmoid 函数:** $f(z) = \frac{1}{1+e^{-z}}$, 输出范围 $(0, 1)$, 常用于二分类
- **Tanh 函数:** $f(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$, 输出范围 $(-1, 1)$
- **ReLU 函数:** $f(z) = \max(0, z)$, 最常用的激活函数, 计算简单, 缓解梯度消失
- **Softmax 函数:** 用于多分类, 将 k 个线性组合映射到 k 个类别的概率分布

10.2 感知机与多层网络

10.2.1 感知机 (Perceptron)

感知机: 最简单的神经网络, 由单个神经元构成, 只能处理线性可分问题。

结构: 输入层 $\rightarrow$ 输出层 (单个神经元)

局限性: 感知机只能解决线性可分问题, 无法解决异或 (XOR) 等非线性问题。

理解: 感知机的决策边界是线性的, 对于非线性问题, 需要多层网络。

10.2.2 多层前馈神经网络

多层网络: 包含输入层、隐藏层 (一个或多个) 和输出层的神经网络。

前馈神经网络 (Feedforward Neural Network):

- 信息从输入层流向输出层, 没有反馈连接
- 每层神经元只接收来自前一层的输入
- 通过多层非线性变换, 可以学习复杂的非线性关系

万能近似定理 (Universal Approximation Theorem): 具有至少一个隐藏层的前

馈神经网络，只要隐藏层有足够多的神经元，就可以以任意精度近似任何连续函数。

理解：多层网络通过组合多个非线性变换，可以表示非常复杂的函数，这是深度学习的基础。

10.3 误差逆传播算法（BP 算法）

10.3.1 BP 算法的基本思想

误差逆传播算法（Backpropagation, BP）：训练多层神经网络的主要算法。

基本思想：

1. **前向传播：**输入样本，逐层计算各层神经元的输出
2. **计算误差：**比较网络输出与真实标签，计算误差
3. **反向传播：**将误差从输出层向输入层反向传播，计算各层参数的梯度
4. **参数更新：**使用梯度下降法更新网络参数（权重和偏置）

理解：BP 算法通过链式法则（chain rule）计算损失函数对每个参数的梯度，然后使用梯度下降法优化参数。

参数更新规则：

$$w_{ij}^{(l)} \leftarrow w_{ij}^{(l)} - \eta \frac{\partial E}{\partial w_{ij}^{(l)}}$$

其中 η 是学习率， E 是损失函数。

主要问题：

- **梯度消失：**在深层网络中，梯度可能变得非常小，导致参数更新缓慢，深层网络难以训练
- **梯度爆炸：**梯度可能变得非常大，导致训练不稳定，权重更新过大
- **局部最优：**可能陷入局部最优解，而非全局最优
- **过拟合：**神经网络模型复杂，容易过拟合训练数据，泛化能力差

10.4 神经网络的特性和挑战

神经网络的优点：

- **强大的表达能力：**多层网络可以学习非常复杂的非线性关系
- **自动特征学习：**不需要手工设计特征，可以从原始数据中自动学习特征表示
- **端到端学习：**可以直接从输入到输出进行端到端的训练

神经网络的缺点：

- **黑盒模型：**难以解释模型的决策过程，可解释性差
- **需要大量数据：**通常需要大量标注数据才能训练出好的模型
- **计算资源需求大：**训练深层网络需要大量的计算资源和时间
- **超参数敏感：**网络结构、学习率等超参数对性能影响很大，需要仔细 tuning

缓解过拟合的方法：

- **正则化：**L1 正则化、L2 正则化，限制权重的大小
- **Dropout：**训练时随机丢弃部分神经元，减少模型复杂度
- **早停（Early Stopping）：**在验证集性能不再提升时提前停止训练
- **数据增强：**通过数据变换增加训练样本的多样性

理解：神经网络虽然强大，但也面临训练困难、过拟合等问题，需要结合各种技术手段来解决。

11 第 11 讲强化学习

11.1 强化学习问题基本设置

11.1.1 强化学习的基本概念

强化学习 (Reinforcement Learning, RL): 智能体 (agent) 在与环境的交互过程中, 通过试错 (trial and error) 来学习最优策略, 以最大化累积奖励。

基本要素:

- **智能体 (Agent):** 进行学习和决策的主体
- **环境 (Environment):** 智能体所处的世界
- **状态 (State):** $s \in S$, 智能体感知到的环境的描述
- **动作 (Action):** $a \in A$, 智能体能采取的行为
- **奖励 (Reward):** r , 环境对智能体动作的反馈
- **策略 (Policy):** $\pi(a|s)$, 在状态 s 下选择动作 a 的概率

理解: 强化学习是一个多步决策过程, 智能体通过不断与环境交互, 根据获得的奖励信号调整策略, 最终学会在什么状态下采取什么动作能够获得最大的累积奖励。

11.1.2 马尔可夫决策过程 (MDP)

马尔可夫决策过程 (Markov Decision Process, MDP): 强化学习常用 MDP 来描述。

MDP 的组成:

- **状态空间 S :** 所有可能状态的集合
- **动作空间 A :** 所有可能动作的集合
- **状态转移概率:** $P(s'|s, a)$, 在状态 s 下采取动作 a 后转移到状态 s' 的概率
- **奖励函数:** $R(s, a)$ 或 $R(s, a, s')$, 在状态 s 下采取动作 a (或转移到 s') 获得的奖励
- **折扣因子:** $\gamma \in [0, 1]$, 用于计算累积奖励

马尔可夫性质: 未来状态只依赖于当前状态和动作, 与历史状态无关:

$$P(s_{t+1}|s_t, a_t, s_{t-1}, a_{t-1}, \dots) = P(s_{t+1}|s_t, a_t)$$

理解: MDP 提供了一个数学框架来描述强化学习问题, 使得我们可以使用动态规划等方法求解最优策略。

11.1.3 强化学习的目标

累积奖励 (Return):

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

其中 γ 是折扣因子, 用于平衡即时奖励和未来奖励的重要性。

值函数 (Value Function):

- **状态值函数 $V^\pi(s)$:** 在策略 π 下, 从状态 s 开始的期望累积奖励
- **动作值函数 $Q^\pi(s, a)$:** 在策略 π 下, 在状态 s 下采取动作 a 后的期望累积奖励

最优策略: 使期望累积奖励最大的策略 π^* 。

理解: 强化学习的目标是找到最优策略, 使得智能体在长期交互中获得最大的累积奖励。

11.2 K-摇臂赌博机

K-摇臂赌博机 (K-armed Bandit): 最简单的强化学习问题, 只有一个状态, 智能体需要从 K 个动作中选择一个, 获得即时奖励。

核心问题: 探索与利用 (Exploration vs Exploitation) 的平衡

- **探索 (Exploration)**: 尝试未知的动作, 收集更多信息
- **利用 (Exploitation)**: 选择当前已知最好的动作, 最大化即时奖励
- **平衡策略**: ϵ -贪心策略 (以 ϵ 概率随机探索, 以 $1 - \epsilon$ 概率选择最优动作)

理解: K-摇臂赌博机是强化学习的基础问题, 体现了探索与利用的核心矛盾。

11.3 有模型学习与无模型学习

有模型学习: 环境的动态特性 (状态转移概率和奖励函数) 已知, 可以使用动态规划方法求解最优策略。

无模型学习: 不需要知道环境的动态特性, 直接从经验中学习。主要方法包括:

- **蒙特卡罗方法**: 通过完整的回合来估计值函数, 需要等到回合结束才能更新
- **时序差分学习 (TD)**: 结合了蒙特卡罗方法和动态规划的思想, 可以在每一步后立即更新
- **Q 学习**: 经典的时序差分学习算法, 学习动作值函数 $Q(s, a)$

值函数近似: 当状态空间或动作空间很大时, 使用参数化的函数 (如神经网络) 来近似值函数, 避免存储所有状态-动作对的值。

模仿学习: 通过观察专家的行为来学习策略, 而不是通过试错。可以加速强化学习过程。主要包括:

- **直接模仿学习**: 直接学习专家策略, 将专家行为作为监督信号
- **逆强化学习**: 从专家行为中推断奖励函数, 然后基于推断的奖励函数学习策略

11.4 强化学习与有监督学习的区别

主要区别:

- **奖励信号**: 强化学习的奖励信号可能延迟, 需要考虑长期累积奖励; 有监督学习有明确的标签
- **探索与利用**: 强化学习需要在探索新动作和利用已知好动作之间平衡
- **数据获取**: 强化学习通过与环境交互获得数据; 有监督学习使用标注好的数据集

在大语言模型中的应用优势:

- **多样性**: 强化学习可以更好地处理输出的多样性, 避免有监督学习对个别词元变化不敏感的问题
- **缓解幻觉**: 通过定制奖励函数, 将正确答案赋予高分, 将放弃回答赋予中低分, 将错误答案赋予负分, 使模型学会依赖内部知识选择放弃回答
- **多轮对话**: 强化学习可以更好地解决多轮对话奖励累积问题, 根据整个对话的背景及连贯性进行判断

11.5 基于人类反馈的强化学习 (RLHF)

RLHF 的目标: 将人工智能与人类价值观对齐, 使大语言模型输出满足 3H 原则:

- **帮助性 (Helpfulness)**: 模型输出对用户有帮助
- **真实性 (Honesty)**: 模型输出真实可靠
- **无害性 (Harmless)**: 模型输出不会造成伤害

RLHF 的两个主要步骤:

1. **奖励模型训练**：通过人类反馈标注的偏好数据来学习人类的偏好，判断模型回复的有用性和无害性
2. **近端策略优化 (PPO)**：使用强化学习算法对语言模型进行微调，根据奖励模型的反馈优化模型

PPO 算法涉及的四个模型：

- **策略模型 (Policy Model)**：生成模型回复
- **奖励模型 (Reward Model)**：输出奖励分数来评估回复质量的好坏
- **评论模型 (Critic Model)**：预测回复的好坏，可以在训练过程中实时调整模型，选择对未来累积收益最大的行为
- **参考模型 (Reference Model)**：提供 SFT 模型的备份，使模型不会出现过于极端的变化，维持模型稳定性

PPO 算法的实施流程：

1. **环境采样**：策略模型基于给定输入生成一系列的回复，奖励模型对这些回复进行打分获得奖励
2. **优势估计**：利用评论模型预测生成回复的未来累积奖励，并借助广义优势估计 (GAE) 算法估计优势函数
3. **优化调整**：使用优势函数来优化和调整策略模型，同时利用参考模型确保更新的策略不会有太大的变化

11.6 模型小结

强化学习的特点：

- 多步决策过程，需要考虑长期累积奖励
- 通过试错学习，需要平衡探索与利用
- 适用于序列决策问题，如游戏、机器人控制、对话系统等

主要方法：

- **有模型学习**：基于动态规划的寻优
- **免模型学习**：蒙特卡罗方法、时序差分学习
- **值函数近似**：处理连续状态空间
- **模仿学习**：加速强化学习过程
- **RLHF**：基于人类反馈的强化学习，用于大语言模型训练

综合例题：银行信用风险评估

例题

题目：机器学习综合题。某银行希望利用机器学习模型自动评估客户的信用风险。每位客户的特征如下：

特征	类型	说明
收入水平	高/中/低	分类特征
年龄	连续型	单位：岁
是否有房	是/否	分类特征
历史违约次数	连续型	次
信用风险标签	0= 低风险, 1= 高风险	模型预测目标

银行提供了如下 6 组训练样本（简化数据）：

编号	收入水平	年龄	是否有房	违约次数	信用风险
1	高	45	是	0	0
2	低	23	否	2	1
3	中	32	否	1	1
4	高	36	是	0	0
5	中	40	否	0	0
6	低	29	否	1	1

- 请给出：将“收入水平”（高/中/低）和“是否有房”（是/否）转换为数值的合理编码方式（例如 0/1 或 One-Hot 等形式）；编码后第 2 条样本的特征向量应为何？（按顺序：收入、年龄、是否有房、违约次数）。
- 若模型首先考虑以“收入水平”作为划分属性（高、中、低），求此划分的信息增益。请写出计算过程，并说明最终是否选择“收入水平”作为首个划分节点。
- 假设二分类问题中，采用支持向量方法，当惩罚系数 C 较大时，会对模型的间隔与误分类率产生怎样的影响？简要说明。
- 考虑一个简化的两层前馈神经网络：输入层节点 2（收入编码与违约次数），隐藏层节点 2（使用 Sigmoid 激活函数），输出层节点 1（使用 Sigmoid 输出，表示高风险概率）。已知： $\mathbf{x} = [1, 2]^T$, $\mathbf{W}_1 = \begin{bmatrix} 0.5 & -0.4 \\ 0.3 & 0.1 \end{bmatrix}$, $\mathbf{b}_1 = [0, 0]^T$, $\mathbf{W}_2 = [0.6, -0.2]$, $b_2 = 0$ 。请计算：隐藏层输出 $\mathbf{h} = \sigma(\mathbf{W}_1 \mathbf{x} + \mathbf{b}_1)$ ；最终输出 $y = \sigma(\mathbf{W}_2^T \mathbf{h} + b_2)$ （其中 $\sigma(a) = \frac{1}{1+e^{-a}}$ ，保留两位小数）。
- 结合本任务特征特点与数据量（仅约 100 条样本），分析：若仅能选择决策树/SVM/神经网络三种之一，你会选择哪种？请从数据规模、特征类型、模型可解释性三方面说明理由。

解答：

1. 特征编码：

- “收入水平”：One-Hot 编码（高 $\rightarrow [1, 0, 0]$ ，中 $\rightarrow [0, 1, 0]$ ，低 $\rightarrow [0, 0, 1]$ ）
- “是否有房”：二值编码（是 $\rightarrow 1$ ，否 $\rightarrow 0$ ）
- 第 2 条样本特征向量： $\mathbf{x}_2 = [0, 0, 1, 23, 0, 2]^T$ （One-Hot 编码）或 $\mathbf{x}_2 = [0, 23, 0, 2]^T$ （数值编码：高 = 2，中 = 1，低 = 0）

2. 信息增益计算：

- 根节点信息熵： $\text{Ent}(D) = -\frac{3}{6} \log_2 \frac{3}{6} - \frac{3}{6} \log_2 \frac{3}{6} = 1$
- 按“收入水平”划分：高（全部低风险），中（1 高风险 1 低风险），低（全部高风险）
- 信息增益： $\text{Gain}(D, \text{收入水平}) = 1 - [\frac{2}{6} \times 0 + \frac{2}{6} \times 1 + \frac{2}{6} \times 0] = \frac{2}{3} = 0.667$
- 信息增益较大，“收入水平”是一个好的划分属性，可以作为首个划分节点

例题

解答（续）：

3. 参数 C 的影响：

- C 较大时：对误分类惩罚大，间隔变窄，训练集误分类率降低，但可能过拟合，测试集误分类率可能增加
- 支持向量可能增多，决策边界更复杂

4. 神经网络前向传播：

- 隐藏层： $\mathbf{h} = \sigma(\mathbf{W}_1 \mathbf{x} + \mathbf{b}_1) = \sigma([-0.3, 0.5]^T) \approx [0.43, 0.62]^T$
- 输出层： $y = \sigma(\mathbf{W}_2^T \mathbf{h} + b_2) = \sigma(0.132) \approx 0.53$

5. 模型选择：推荐决策树

- 数据规模：100 条样本较小，决策树适合（可通过剪枝防止过拟合），神经网络容易过拟合
- 特征类型：混合类型（分类 + 连续），决策树天然支持，SVM 和神经网络需要特征全部数值化
- 可解释性：银行需要向客户解释拒绝贷款的原因，决策树可解释性最好，SVM 和神经网络是”黑盒”