

机器学习第一次作业

1. 机器学习基本概念

(1) 请简述以下几种机器学习范式的区别，并各举一例：

监督学习 (Supervised Learning)、无监督学习 (Unsupervised Learning)、

半监督学习 (Semi-supervised Learning)、强化学习 (Reinforcement

Learning)

(2) 在机器学习建模过程中，一般包括哪些主要步骤？

1. (1) 监督学习：用有标签的数据训练模型，如 roberta, gptzero.
无监督学习：用无标签的数据训练模型，如 GAN.
半监督学习：部分有标签，或通过自动化手段标注数据，如
对比学习、蒸馏。
强化学习：定义奖励函数，探索规则等，让模型从试错中
学习，如 DPO, GRPO.
(2) 大致可以分为 问题定义，数据收集，数据预处理，EDA，
特征工程，模型选择、训练、评估、测试、部署各阶段。

2. 模型评估与选择

某二分类模型在测试集上的混淆矩阵如下：

	预测正类	预测负类
实际正类	45	5
实际负类	15	35

请计算以下指标 (保留两位小数)：准确率 (Accuracy)、精确率 (Precision)、

召回率 (Recall)、F1 值 (F1-score)

2. 总样本数 = 100, $\therefore$ Accuracy = $\frac{TP+TN}{100} = 0.8$,
Precision = $\frac{TP}{TP+FP} = 0.75$, Recall = $\frac{TP}{TP+FN} = 0.9$.
F1 = $2 \times \frac{P \times R}{P+R} = 0.82$.

3. 交叉验证与模型选择

你在一个回归问题上使用了两种模型：线性回归 (LR) 与支持向量回归 (SVR)。

使用 5 折交叉验证得到平均 MSE 如下：

模型	Fold1	Fold2	Fold3	Fold4	Fold5	平均 MSE
LR	25	28	27	30	26	?
SVR	20	23	22	21	20	?

(1) 计算两种模型的平均 MSE，并判断哪一个更优。

(2) 简述交叉验证的主要作用。

3. (1) LR 的平均 MSE = $\frac{1}{5}(25+28+27+30+26) = 27.2$,
SVR 的平均 MSE = $\frac{1}{5}(20+23+22+21+20) = 21.2$.
 $\therefore$ SVR_{mean-MSE} < LR_{mean-MSE}, $\therefore$ SVR 更优
(2) 交叉验证的作用是，将训练集划分为多个 fold 进行验证，
提升模型在未知数据上的泛化性能，减少单次划分偏差。

4. 线性回归参数求解 (最小二乘法)

已知简单线性回归模型为： $y = w_0 + w_1x + \varepsilon$ ，其中， ε 为误差项。现有一组样本

数据如下：

x (自变量)	1	2	3	4	5
y (因变量)	2	4	5	4	5

请使用**最小二乘法**求解模型参数 w_0 (截距) 和 w_1 (斜率), 并写出关键计算步骤。

4. 利用最小二乘法, 算出均值 $\bar{x} = \frac{1}{5} \sum_{i=1}^5 x_i = 3$, $\bar{y} = \frac{1}{5} (2+4+4+5+5) = 4$; 算出斜率, $w_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = 0.6$, 因此, 截距 $w_0 = \bar{y} - w_1 \bar{x} = 2.2$. $\therefore w_0 = 2.2, w_1 = 0.6$.

5. 岭回归正则化效果分析

已知某多元线性回归问题中, 特征矩阵 X 存在多重共线性 (如两个特征高度相关)。若分别使用普通线性回归和岭回归 (Ridge Regression) 建模, 回答以下问题:

- (1) 多重共线性会对普通线性回归的参数估计产生什么影响? (从参数稳定性、方差角度说明)
- (2) 岭回归通过引入正则化项 $\lambda \sum_{j=1}^p w_j^2$ ($\lambda \geq 0$, p 为特征数) 解决该问题, 简述正则化项的作用。
- (3) 当正则化参数 λ 分别取以下值时, 分析对岭回归模型参数 w_j 和模型泛化能力的影响: $\lambda = 0$; λ 趋近于正无穷。

5. 多重共线性意味着两个或多个特征高度线性相关, 导致设计矩阵 $X^T X$ 接近奇异矩阵, 因此模型对样本扰动敏感, 参数估计产生偏差。
(2) 岭回归的正则化项, 是在优化目标中加入 $\lambda \|w\|_2^2$ 的正则项, 过大的 w_i 会被惩罚, 降低参数方差, 提升稳定性。
(3) ① $\lambda = 0$, 等于没有进行正则化, 参数 w_i 不稳定, 模型易过拟合, 泛化性下降; ② $\lambda \rightarrow +\infty$, 惩罚过大, $w_i \rightarrow 0$, 模型能力差, 欠拟合严重, 泛化能力差。

6. 贝叶斯分类器计算

假设一个二分类问题（类别 C_1 与 C_2 ），观测特征为 x 。已知如下信息：

项目	C_1	C_2
先验概率 $P(C_i)$	0.6	0.4
条件概率 $P(x C_i)$	0.5	0.2

请根据贝叶斯定理计算后验概率 $P(C_1|x)$ 和 $P(C_2|x)$ ，并判断样本属于哪一类。

$$\begin{aligned}
 & \text{6. 由题, } P(x) = P(x|C_1)P(C_1) + P(x|C_2)P(C_2) = 0.38. \\
 & P(C_1|x) = \frac{P(x|C_1)P(C_1)}{P(x)} = \frac{0.3}{0.38} \approx 0.79. \\
 & P(C_2|x) = \frac{P(x|C_2)P(C_2)}{P(x)} = \frac{0.08}{0.38} \approx 0.21 \\
 & \text{因此样本属于 } C_1 \text{ 类.}
 \end{aligned}$$

7. 朴素贝叶斯分类器原理分析

- (1) 简述朴素贝叶斯 (Naïve Bayes) 分类器的基本假设。
- (2) 说明这一假设的优缺点。
- (3) 其常见变体有哪些？

7. (1) 贝叶斯模型的基本假设是，特征条件独立性，即给定类别标签，所有特征间相互独立。

(2) 其优点为：

- ① 计算简单，联合概率只用连乘，训练只用计数
- ② 对数据量要求低，不易过拟合。
- ③ 推理速度快，计算量低。

缺点：

- ① 现实中，其独立性假设不一定成立，强相关特征会导致估计概率太高。
- ② 对异常值、冗余特征敏感。

(3) 其变体有：

- ① 高斯朴素贝叶斯：假设特征连续，服从正态分布。
- ② 多项式朴素贝叶斯：用于离散计数，比如词频。
- ③ 伯努利朴素贝叶斯：用于二元特征，如同出现/未出现。