

机器学习第三次作业

1. 硬间隔 SVM 的最优超平面计算


给定二维样本集：

样本	特征 (x_1, x_2)	标签 y
A	(0, 0)	+1
B	(1, 1)	-1
C	(2, 0)	-1

- (1) 写出线性可分 SVM 的优化目标函数（原始形式）。
- (2) 画出这些点在平面上的分布，并给出直观的分界线方向。
- (3) 将该问题化为拉格朗日对偶问题，求出支持向量与对偶变量 α_i 的非零条件。
- (4) 求出最优分离超平面方程 $w^T x + b = 0$ 。
- (5) 计算分类间隔的宽度。

第三次作业

1. 硬间隔 SVM 的优化目标是 $\min_{w, b} \frac{1}{2} \|w\|^2$, 对于 $y_i(w^T x_i + b) \geq 1, \forall i$



(3) 将其化为拉格朗日对偶问题：

$$\max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$$

$$\alpha_i \geq 0, \sum_{i=1}^n \alpha_i y_i = 0$$

非零条件为 $y_i(w^T x_i + b) = 1$
 $\alpha_i > 0$ 对应支持向量, $\alpha_i = 0$ 对应非支持向量

(4) 将 A、B、C 代入 (3) 中式子, 得 $\alpha_1 - \alpha_2 - \alpha_3 \geq 0$, 即 $\alpha_1 = \alpha_2 + \alpha_3$
我们需要最大化的目标函数为 $(\alpha_1 + \alpha_2 + \alpha_3) - (\alpha_1^2 + 2\alpha_2\alpha_3 + 2\alpha_3^2)$
利用 $\alpha_1 = \alpha_2 + \alpha_3$, 转化目标函数为 $-\alpha_2^2 - 2\alpha_2\alpha_3 - 2\alpha_3^2 + 2\alpha_2 + 2\alpha_3$

解得 $\alpha_1=1, \alpha_2=1, \alpha_3=0$. 因此, $\alpha=(1,1,0)$. $w=(-1,-1)$, $b=1$
 $\therefore$ 最优分离超平面为 $x_1+x_2-1=0$.
 (5) 分类间隔宽度 $= \frac{2}{\|w\|} = \frac{2}{\sqrt{2}} = \sqrt{2}$.

2. 核函数与软间隔分析

已知 SVM 的对偶形式为:

$$\max_{\alpha} \sum_{\&} \alpha_{\&} - \frac{1}{2} \sum_{\&} \sum_{\&'} \alpha_{\&} \alpha_{\&'} y_{\&} y_{\&'} K(x_{\&}, x_{\&'})$$

约束: $\sum_{\&} \alpha_{\&} y_{\&} = 0, 0 \leq \alpha_{\&} \leq C$

(1) 若使用高斯核 $K(x, x') = e^{-\frac{1}{2C}\|x - x'\|^2}$ ，说明此核在特征空间的非线性映射性质；

质；

(2) 分析参数 C 过大或过小时对应“欠惩罚”和“过惩罚”的几何后果；

(3) 给出硬间隔与软间隔 SVM 的几何差别示意（可用文字或符号说明支持向量位置变化）；

(4) 说明核函数必须满足的两个条件。

2、(1) 高斯核的非线性映射性质为将原始低维空间的样本映射到无穷维的特征空间。

(2) 过惩罚：对应 C 过大，会导致 margin 变窄，决策边界扭曲，进而导致过拟合。

欠惩罚：会导致 margin 变宽，决策边界过于简单，造成欠拟合。

(3) 硬间隔：要求所有样本都必须被正确分类，且位于间隔边界以外，支持向量必须严格位于间隔边界上；而软间隔则相反，允许样本分类错误，支持向量可出现在间隔边界上、间隔内或错误的一侧。

(4) 函数 $k(x, z)$ 要成为核函数，就要对应特征空间中的内积，则必须满足 2 个条件：

① 对称性： $\forall x, z, k(x, z) = k(z, x)$ 。

② 半正定性： $\forall [x_1, x_2, \dots, x_n]$ (有限个样本集)，其对应的 Gram 矩阵必须是半正定矩阵。

3. 决策树构建与剪枝分析

给定以下训练数据集（二维离散特征）：

样本	天气	湿度	是否打球(标签)
A	晴	高	否
B	晴	正常	是

C	阴	高	是
D	阴	正常	是
E	雨	高	否
F	雨	正常	是

(1) 计算在主节点上按“天气”划分的信息增益，并判断是否是最优划分特征。

(2) 画出对应的决策树结构（可用文字层次描述代替图形）。

(3) 若使用“基尼指数”作为划分标准，比较与信息增益的划分结果是否一致。

(4) 简述决策树容易过拟合的原因，并说明两种剪枝方法（预剪枝/后剪枝）的思路。

思路。

3. (1) 按天气划分的信总增益, $G(D, \text{天气}) = H(D) - H(D|\text{天气})$. 信总熵
 $H(D) = -\sum p \log_2(p) = -(\frac{4}{6} \log_2 \frac{4}{6} + \frac{2}{6} \log_2 \frac{2}{6}) \approx 0.918$.
 $H(D|\text{天气}) = \frac{1}{3} \times 1 + \frac{1}{3} \times 0 + \frac{1}{3} \times 1 = \frac{2}{3} \approx 0.667$.
 $\therefore G(D, \text{天气}) = H(D) - H(D|\text{天气}) = 0.251$. 经计算,
 $G(D, \text{湿度}) = 0.459 > G(D, \text{天气}) = 0.251$. $\therefore$ 天气不是最优特征划分,
而是湿度.

(2) 由(1), 根节点选择湿度. 结构.

(3) 用基尼指数划分, 则天气的指标:

$$\text{Gini}(D) = 1 - (\frac{4}{6})^2 - (\frac{2}{6})^2 \approx 0.644$$

$$\text{Gini}(D, \text{天气}) = \frac{1}{3} \approx 0.33$$

$$\text{Gini}(D, \text{湿度}) = 0.222$$

$\therefore 0.33 > 0.22$, $\therefore$ 基尼指数也会选择“湿度”作为划分标准. $\therefore$ 结果与信息增益一致.

(4) 原因: ① 决策树的复杂度过高, 不加以限制总会用非常具体的规则拟合训练集中的每个样本. ② 存在噪声或者错误标注的数据, 决策树强制将其另表正名导致泛化能力下降.

剪枝: ① 预剪枝: 在决策树生成过程中, 在划分前估计每个节点. 如果该划分不能提升性能则终止.

② 后剪枝: 先训练一棵完整的决策树, 然后自底向上考察各节点. 若将孩子节点替换为叶节点有助于提升泛化性, 则进行剪枝.

4. 强化学习: 价值迭代与策略改进

给定两个状态的 MDP:

状态	动作	奖励	下一状态
----	----	----	------

s_1	a_1	4	s_2
s_2	a_1	1	s_1

折扣因子 $\gamma = 0.5$, 初始 $V_{+(s_1)} = V_{+(s_2)} = 0$ 。

- (1) 写出价值迭代更新公式。
- (2) 分别计算 V_0, V_1, V_2 。
- (3) 判断策略是否随迭代发生变化;
- (4) 解释价值迭代与策略迭代的关系与收敛特征。

4. (1) 价值迭代基于贝尔曼最优方程, 公式为 $V_{k+1}(s) = \max_a (R(s, a) + \gamma V_k(s'))$.
 $\because$ 只有一个动作 a_1 , $\therefore$ 对本题, 对 s_1 , 公式为 $V_{k+1}(s_1) = 4 + 0.5 \times V_k(s_2)$,
 对 s_2 , 为 $V_{k+1}(s_2) = 1 + 0.5 \times V_k(s_1)$.
 (2) 由 (1) 中公式, $V_0(s_1) = 0$, $V_0(s_2) = 0$, $\gamma = 0.5$, 得 $V_1(s_1) = 4$, $V_1(s_2) = 1$,
 $V_1 = (4, 1)$, 同理 $V_2 = (4.5, 3)$, $V_3 = (5.5, 3.25)$.
 (3) 策略不随迭代变化, 因为策略是通过选择使动作价值 $Q(s, a)$ 最大的动作而确定的, 但本题中每个状态仅有 1 个动作.
 (4) 策略迭代包括策略评估和策略改进两步; 价值迭代则是其一种特殊形式, 只进行一步“策略评估”, 就立即进行改进.
 价值迭代是渐近收敛, 策略迭代则通常可在有限步中收敛, 迭代步数较少.

5. 单隐藏层网络的反向传播计算

一个简单神经网络结构如下:

输入层 (2 维) → 隐藏层 (2 个神经元, Sigmoid 激活) → 输出层 (1 个神经元, 线性输出)

输入: $x = [1, 0]^T$; 期望输出: $y = 0.8$

网络参数: $W_1 = \begin{bmatrix} 0.1 & 0.4 \\ 0.2 & 0.3 \end{bmatrix}$, $b_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$, $W_2 = \begin{bmatrix} 0.7 & 0.5 \end{bmatrix}$, $b_2 = 0.1$

学习率: $\eta = 0.1$

(1) 写出前向传播过程, 计算各层输出;

(2) 以平方误差 $L = \frac{1}{2} (y_{\text{pred}} - y)^2$ 为损失, 推导对所有参数的梯度;

(3) 若将激活函数改为 ReLU, 说明梯度表达式怎样简化, 且在何种输入下可

能出现 “神经元失活 (dead neuron)”。

5. (1) ① 隐藏层输出: $z_1 = W_1 x + b_1 = \begin{bmatrix} 0.1 & 0.4 \\ 0.2 & 0.3 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0.1 \\ 0.2 \end{bmatrix}$.
 ② 激活函数输出: $h = \sigma(z_1) = \begin{bmatrix} 0.5250 \\ 0.5498 \end{bmatrix}$.
 ③ 输出: $y_{\text{pred}} = W_2 h + b_2 = \begin{bmatrix} 0.7 & 0.5 \end{bmatrix} \begin{bmatrix} 0.5250 \\ 0.5498 \end{bmatrix} + 0.1 = 0.7424$.
 (2) $L = \frac{1}{2} (y_{\text{pred}} - y)^2$. 根据链式法则, $\frac{\partial L}{\partial y_{\text{pred}}} = y_{\text{pred}} - y$.
 记 $\delta_2 = y_{\text{pred}} - y$. $\frac{\partial L}{\partial W_2} = \frac{\partial L}{\partial y_{\text{pred}}} \cdot \frac{\partial y_{\text{pred}}}{\partial W_2} = \delta_2 \cdot h^T$
 $\frac{\partial L}{\partial b_2} = \frac{\partial L}{\partial y_{\text{pred}}} \cdot \frac{\partial y_{\text{pred}}}{\partial b_2} = \delta_2$. 再计算对隐藏层的, σ Sigmoid 的导数
 $\sigma'(z) = \sigma(z)(1 - \sigma(z))$. $\therefore \delta_1 = \frac{\partial L}{\partial z_1} = \left(\frac{\partial L}{\partial z_2} \cdot \frac{\partial z_2}{\partial h} \right) \odot \frac{\partial h}{\partial z_1} =$
 $(W_2^T \delta_2) \odot (h \odot (1 - h))$. $\therefore \frac{\partial L}{\partial W_1} = \delta_1 \cdot x^T$. $\frac{\partial L}{\partial b_1} = \delta_1$
 代入数据, 得 $\frac{\partial L}{\partial W_2} = [-0.030, -0.032]$. $\frac{\partial L}{\partial b_2} = -0.058$.
 $\frac{\partial L}{\partial W_1} = \begin{bmatrix} -0.010 & 0 \\ -0.007 & 0 \end{bmatrix}$. $\frac{\partial L}{\partial b_1} = \begin{bmatrix} -0.010 \\ -0.007 \end{bmatrix}$.
 (4) ReLU = $f(z) = \max(0, z)$. 即 $f'(z) = \begin{cases} 1, & z > 0 \\ 0, & z \leq 0 \end{cases}$.
 相比于 Sigmoid 的导数 $h \odot (1 - h)$, 导数大幅简化.
 若输出 $z > 0$, 则导数为上层误差的直接传递; 若 $z \leq 0$, 则导数为 0, 且断传播. 因此, 若对所有样本, 某神经元的前输出均有 $Wx + b \leq 0$, 则其无法传递梯度, 成为死神经元.

6. 机器学习综合题

某银行希望利用机器学习模型自动评估客户的信用风险。每位客户的特征如下：

特征	类型	说明
收入水平	高/中/低	分类特征
年龄	连续型	(单位：岁)
是否有房	是/否	分类特征
历史违约次数	连续型	(次)
信用风险标签	0=低风险，1=高风险	模型预测目标

银行提供了如下 6 组训练样本（简化数据）：

编号	收入水平	年龄	是否有房	违约次数	信用风险
1	高	45	是	0	0
2	低	23	否	2	1
3	中	32	否	1	1
4	高	36	是	0	0
5	中	40	否	0	0
6	低	29	否	1	1

(1) 请给出：将“收入水平”（高/中/低）和“是否有房”（是/否）转换为数值的合理编码方式（例如 0/1 或 One-Hot 等形式）；编码后第 2 条样本的特征向量应为何？（按顺序：收入、年龄、是否有房、违约次数）。

(2) 若模型首先考虑以“收入水平”作为划分属性（高、中、低），求此划分的信息增益。请写出计算过程，并说明最终是否选择“收入水平”作为首个划分节点（可定性判断）。

(3) 假设二分类问题中，两个支持向量点的函数间隔分别为 1 与-1，当惩罚系数 C 较大时，会对模型的间隔与误分类率产生怎样的影响？简要说明。

(4) 考虑一个简化的两层前馈神经网络：

输入层节点：2（收入编码与违约次数）

隐藏层节点：2，使用 Sigmoid 激活函数

输出层节点：1，使用 Sigmoid 输出（表示高风险概率）

已知: $x = [1, 2]^T$, $W_1 = \begin{bmatrix} 0.5 & -0.4 \\ 0.3 & 0.1 \end{bmatrix}$, $b_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$, $W_2 = \begin{bmatrix} 0.6 & 0 \\ 0 & -0.2 \end{bmatrix}$, $b_2 = 0$

请计算: 隐藏层输出 $h = \sigma(W_1 x + b_1)$; 最终输出 $y = \sigma(W_2 h + b_2)$.

(其中 $\sigma(a) = \frac{1}{1 + e^{-a}}$, 保留两位小数即可)

(5) 结合本任务特征特点与数据量 (仅约 100 条样本), 分析: 若仅能选择 决策树/SVM/神经网络 三种之一, 你会选择哪种? 请从数据规模、特征类型、模型可解释性, 三方面说明理由。

6. (1) 收入水平: 有高/中/低三类, 有顺序, 适合转换为序列编码。
是否有房: 二分类特征, 使用 0/1 编码。样本 2 的特征为

$x = [\text{收入}, \text{年租金}, \text{房的所有}, \text{违约}] = [1, 23, 0, 2]$.

(2) 计算“收入”水平划分的信息增益: $G(D, \text{收入}) = H(D) - H(D|\text{收入})$
 $= 1 - (\frac{1}{3} \times 0 + \frac{1}{3} \times 1 + \frac{1}{3} \times 0) \approx 0.667 \text{ bit}$. $\therefore$ 信息增益很高, $\therefore$ 选择收入水平作为首个划分结点。

(3) C 较大时, 模型会倾向于尽可能不错分样本, 使得分类间隔变窄。在训练集上误分类率下降, 容易过拟合。

(4) $h = \sigma(W_1 x + b_1) = \sigma\left(\begin{bmatrix} 0.5 & -0.4 \\ 0.3 & 0.1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix}\right) \approx \begin{bmatrix} 0.43 \\ 0.62 \end{bmatrix}$.
 $y = \sigma(W_2 h + b_2) = \sigma\left(\begin{bmatrix} 0.6 & 0 \\ 0 & -0.2 \end{bmatrix} \begin{bmatrix} 0.43 \\ 0.62 \end{bmatrix} + 0\right) \approx 0.134 \approx 0.13$.

(5) 我会选择决策树。因为: ① 模型可解释性强, 方便银行进行信用评估时给出具体原因, 满足监管部门要求。而 NN 和 SVM 是黑盒模型, 难以解释。② 只有 100 条左右数据, 量极小, 而 NN 需要大量数据训练才能收敛, SVM 结果不直观, 只有 DT 能在这种极少样本的情况下给出直观结果。③ 特征类型方面, 数据是分类与连续特征的混合, DT 天然支持处理混合类型特征, 无需额外预处理; 而 SVM 和 NN 对特征尺度敏感, 需进行归一化等预处理。