

机器学习第二次作业

1. AdaBoost 权重更新与样本分布变化

给定一个二分类数据集：

样本	x_i	标签 y_i
1	A	+1
2	B	+1
3	C	-1
4	D	-1

第一个弱分类器 $h_1(x)$ 的预测如下：

样本	$h_1(x_i)$
A	+1
B	+1
C	-1
D	+1

- (1) 计算弱分类器权重： $\alpha_1 = \frac{1}{2} \ln \frac{1-\epsilon_1}{\epsilon_1}$
- (2) 计算新的样本分布 $D_2(i)$ 。
- (3) 请分析哪些样本的权重会上升？这意味着 AdaBoost 下一轮学习时会偏向哪些样本？解释其原因。

1. (1) 权重 $\alpha_1 = \frac{1}{2} \ln \frac{1-\epsilon_1}{\epsilon_1} = \frac{1}{2} \ln \frac{3}{1} = \frac{1}{2} \ln 3$

(2) 对于 4 个样本, $D_1(i) = \frac{1}{4}$, $i = 1, 2, 3, 4$.

$\therefore D_{t+1}(i) = \frac{D_t \exp(-\alpha_t y_i h_t(x_i))}{Z_t}$ 计算 $y_i h_t(x_i)$:

	y_i	$h_1(x_i)$	$y_i h_1(x_i)$	弱分类器
A	1	1	1	✓
B	1	+1	+1	✓
C	-1	-1	1	✓
D	-1	1	-1	✗

$\therefore D_2(A) = D_1(A) \cdot \exp(-\alpha_1 \cdot y_A \cdot h_1(x_A))$, 同理得 $D_2(B)$

归一化后 $D_2(A) = D_2(B) = D_2(C) = \frac{1}{6}$, $D_2(D) = \frac{1}{2}$.

(3) 由 (2) 可知, D 样本的权重会上升. AdaBoost 下一轮学习会偏向被错误分类的样本 (D). 因为 AdaBoost 的核心思想是关注错误分类的样本, 使后续的弱分类器能更好地处理这些难样本.

2. Bagging 模型方差与集成优点

某回归问题中, 单个基学习器的输出方差为 $\text{Var}(T_i) = 1.2$, 不同学习器之间的预测相关系数为 $\rho = 0.2$. 共有 $N = 50$ 个学习器。

(1) 计算集成预测输出的总体方差: $\text{Var}(\bar{T}) = \rho \text{Var}(T_i) + \frac{1-\rho}{N} \text{Var}(T_i)$

(2) 若改为 $N = 200$ 个学习器, 新的方差是多少?

(3) 结合计算结果, Bagging 模型减少方差的机制是什么? 为何当学习器越多、相关性越低时效果越好?

$$\begin{aligned}
 2. (1) \text{Var}(\bar{T}) &= p \cdot \text{Var}(T_i) + \frac{1-p}{N} \text{Var}(T_c) \\
 &= 0.2 \times 1.2 + \frac{0.8}{50} \times 1.2 \\
 &= 0.2592
 \end{aligned}$$

$$\begin{aligned}
 (2) \text{ 改为 } N=200 \text{ 个学习器, 新的方差为 } \text{Var}(\bar{T}') &= 0.2 \times 1.2 + \frac{0.8}{200} \times 1.2 \\
 &= 0.2448.
 \end{aligned}$$

(3) 机制: Bagging 通过平均多个基学习器的预测结果来减少方差. 其方差公式 $\text{Var}(\bar{T}) = p \cdot \text{Var}(T_i) + \frac{1-p}{N} \cdot \text{Var}(T_c)$, 相关性项为 $p \cdot \text{Var}(T_i)$, 平均效应项为 $\frac{1-p}{N} \cdot \text{Var}(T_c)$, 两项分别随 p 减小, N 增大而减小, 从而使总体方差减小.

3. PCA 主成分方向与投影

给定协方差矩阵: $\Sigma = \begin{bmatrix} 4 & 2 \\ 2 & 3 \end{bmatrix}$

- (1) 求特征值与特征向量。
- (2) 指出主成分方向, 并计算方差贡献率。
- (3) 对样本 $x = [2, 1]^T$, 计算其在第一主成分上的投影。
- (4) 如果仅保留第一主成分, 原始二维信息会损失多少? 此损失代表什么含义?

3. (1) 由题意, 解特征方程: $\begin{vmatrix} 4-\lambda & 2 \\ 2 & 3-\lambda \end{vmatrix} = (\lambda-3)(\lambda-4) - 4 = 0$,
 $\therefore \lambda^2 - 7\lambda + 8 = 0$. 解得 $\lambda_1 = \frac{7+\sqrt{17}}{2}$, $\lambda_2 = \frac{7-\sqrt{17}}{2}$ 对于 λ_1 ,
 得特征向量方向为 $v_1 = \begin{bmatrix} \frac{1+\sqrt{17}}{4} \\ 1 \end{bmatrix}$, 归一化后得 $u_1 \approx \begin{bmatrix} 0.788 \\ 0.615 \end{bmatrix}$.
 同理 $u_2 = \begin{bmatrix} -0.615 \\ 0.788 \end{bmatrix}$
 (2) 由(1)得第一、二主成分方向. 总方差 $\lambda_1 + \lambda_2 = 7$. $\therefore$ 第一主成分贡献率为 $\frac{\lambda_1}{7} \approx 79.45\%$. 第二主成分则为 $\frac{\lambda_2}{7} = 20.55\%$.
 (3) 投影值 $x \cdot u_1 = 2 \times 0.788 + 1 \times 0.615 = 2.191$
 (4) 仅保留第一主成分的误差损失为 $1 - \frac{\lambda_1}{7} = 20.55\%$.
 表示原始数据中第二主成分方向上的变异被舍弃.

4. 马氏距离及其与欧氏距离比较

类内协方差矩阵:

$$S = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

两个样本: $x_1 = [2, 1]^T$, $x_2 = [4, 3]^T$

(1) 计算马氏距离: $d_M(x_1, x_2) = \sqrt{(x_1 - x_2)^T S^{-1} (x_1 - x_2)}$

(2) 同时计算欧氏距离 $d_E(x_1, x_2)$.

(3) 比较两种距离的差别: 为什么马氏距离能更合理地度量样本间的相似性? 它捕捉了数据的什么结构特征?

4. (1) $x_1 - x_2 = \begin{bmatrix} -2 \\ -2 \end{bmatrix}$, $S^{-1} = \begin{bmatrix} \frac{3}{5} & -\frac{1}{5} \\ -\frac{1}{5} & \frac{2}{5} \end{bmatrix}$. $\therefore$ 马氏距离 $d_m(x_1, x_2) = \sqrt{(x_1 - x_2)^T S^{-1} (x_1 - x_2)} = \sqrt{[-2, -2] \begin{bmatrix} \frac{3}{5} & -\frac{1}{5} \\ -\frac{1}{5} & \frac{2}{5} \end{bmatrix} \begin{bmatrix} -2 \\ -2 \end{bmatrix}} = \sqrt{2.4} \approx 1.55$.

(2) 欧氏距离 $d_E(x_1, x_2) = \sqrt{(2-4)^2 + (1-3)^2} = 2\sqrt{2} \approx 2.83$

(3) 马氏距离考虑了数据的协方差结构, 消除了量纲和相关性的影响, 更准确的反映了数据的真实分布.

5. K-Means 聚类迭代与收敛分析

一维数据集:

$$x = \{1, 2, 3, 10, 11, 12\}$$

初始化:

$$\mu_1 = 2, \quad \mu_2 = 10$$

- (1) 执行两次完整的 K-Means 迭代, 每次写出簇分配与新的中心。
- (2) 说明两步后算法是否收敛。
- (3) 若初始中心改为 $\mu_1 = 3, \mu_2 = 12$, 结果会怎样变化? 为什么 K-Means 对初始化敏感?

5. (1)

第1轮:

点	1	2	3	10	11	12
到中心的距离	1,9	2,8	1,7	8,0	9,1	10,2
簇标签	1	1	1	2	2	2

新中心 $C_1' = \frac{1+2+3}{3} = 2$, $C_2' = \frac{10+11+12}{3} = 11$.

第2轮:

点	1	2	3	10	11	12
到中心的距离	1,9	2,8	1,7	8,1	9,0	10,1
簇标签	1	1	1	2	2	2

新中心: $C_1^2 = \frac{1+2+3}{3} = 2$, $C_2^2 = \frac{10+11+12}{3} = 11$.

(4) 第2步中心与第1步相同, $\therefore$ 已收敛.

(3) 更改后结果不变, 仍是两轮后收敛到相同中心.

$\therefore$ K-means 的目标函数非凸, 有多个极小值; 且对初值敏感, 因此对初始值敏感.

6. 高斯混合模型 (GMM)

有两个一维高斯成分:

成分	权重 π_k	均值 μ_k	方差 σ_k^2
1	0.4	0	1
2	0.6	3	1

给定样本 $x = 1$.

(1) 写出每个成分的后验概率 (职责):

$$\gamma_k(x) = \frac{\pi_k \mathcal{N}(x|\mu_k, \sigma_k^2)}{\sum_{j=1}^2 \pi_j \mathcal{N}(x|\mu_j, \sigma_j^2)}$$

并代入数值计算。

(2) 求两成分的责任度比值 $\frac{\gamma_1(x)}{\gamma_2(x)}$ 。

(3) 分析哪个成分对该样本的解释更大？如果两个高斯方差变大，职责会发生什么变化？这说明了 GMM 的哪种鲁棒性问题？

6. (1) 计算 $\sum_{j=1}^2 \pi_j \mathcal{N}(x|\mu_j, \sigma_j^2) = 0.4 \cdot \mathcal{N}(x=1|0,1) + 0.6 \mathcal{N}(x=1|3,1)$
 $= 0.4 \times \frac{1}{\sqrt{2\pi}} e^{-0.5} + 0.6 \times \frac{1}{\sqrt{2\pi}} e^{-2} \approx 0.12918$
 其中 $\pi_1 \mathcal{N}(x|\mu_1, \sigma_1^2) \approx 0.09679$, $\pi_2 \mathcal{N}(x|\mu_2, \sigma_2^2) \approx 0.03239$.
 $\therefore \gamma_1(x) \approx 0.749$, $\gamma_2(x) \approx 0.251$. 责任度比值 $\frac{\gamma_1(x)}{\gamma_2(x)} \approx 2.98$.
 (2) $\therefore \gamma_1(x)$ 对该样本的解释更大. 若方差变大, 则权重分配会更加平均, 这暴露了 GMM 对初始值的鲁棒性缺陷: 若初始化时因异常值导致导致方差过大, 就会导致责任平均化且无法修复.